UNIVERSIDAD NACIONAL DE ASUNCION –
FACULTAD POLITECNICA — CARRERA DE INGENIERÍA INFORMÁTICA
MATERIA: DATA SCIENCE – PROYECTO INTEGRADOR

Acceso a internet en los hogares paraguayos

Fase 1 — Comprensión del problema, preparación de los datos y análisis exploratorio

Integrantes	**Gustavo Fabián Carballo Rojas** **Joel María Mendieta Candia**
Legajos	....

Fase	**Fase 1 (30 % del proyecto integrador)**
Fuente de datos	**Encuesta Permanente de Hogares Continua (EPHC) Anual 2025** **Instituto Nacional de Estadística (INE), Paraguay**
Unidad de análisis	**El hogar (n = 17.092)**
Fecha de entrega	**15 de septiembre de 2026**

Análisis realizado en Python (pandas, numpy, matplotlib, seaborn, scipy) sobre Jupyter Notebook. Todo el procesamiento es reproducible por código desde los archivos originales del INE, con rutas relativas y semilla aleatoria fijada.

Índice

1. Etapa 1 — Comprensión del problema 3
1.1 Contexto del problema 3
1.2 Pregunta de investigación 3
1.3 Objetivo general 3
1.4 Objetivos específicos 3
1.5 Justificación de la relevancia 3
1.6 Alcance y limitaciones previstas 4

2. Etapa 2 — Comprensión y selección de los datos 5
2.1 Inventario de los archivos disponibles 5
2.2 Diccionario de datos del conjunto original 5
2.3 Unidad de análisis y verificación de la clave primaria 5
2.4 Perfilado inicial 6
2.5 Evaluación de calidad 6
2.6 Selección justificada 6
2.7 Documentación de la fuente 6

3. Etapa 3 — Limpieza y transformación 8
3.1 Tratamiento de valores faltantes 8
3.2 Detección y tratamiento de duplicados 8
3.3 Valores atípicos e inconsistencias 8
3.4 Normalización de tipos y formatos 8
3.5 Creación de variables derivadas 8
3.6 Integración de fuentes 9
3.7 Bitácora de limpieza 9
3.8 Diccionario de datos del conjunto final 9

4. Etapa 4 — Análisis univariado y bivariado 11
4.1 Univariado — variables numéricas 11
4.2 Univariado — variables categóricas 11
4.3 Visualizaciones univariadas 11
4.4 Bivariado: numérica frente a numérica 12
4.5 Bivariado: numérica frente a categórica 13
4.6 Bivariado: categórica frente a categórica 13
4.7 Otras asociaciones exploradas 14

5. Etapa 5 — Análisis descriptivo y exploratorio integrado 15
5.1 Caracterización integrada del fenómeno 16
5.2 Patrones y anomalías identificados 17
5.3 Hipótesis preliminares para la Fase 2 17
5.4 Decisiones metodológicas para las fases siguientes 18
5.5 El factor de expansión y el alcance de las cifras 18

6. Conclusión de la Fase 1 19
6.1 Principales resultados 19
6.2 Respuesta parcial a la pregunta de investigación 19
6.3 Limitaciones detectadas en los datos 19
6.4 Hipótesis que se llevan a la Fase 2 19

7. Declaración de uso de asistentes de inteligencia artificial 20

8. Reproducibilidad y entregables 20

9. Referencias 20

Índice de figuras

Figuras 1 y 2. Distribución del ingreso per cápita mensual (histograma log y diagrama de caja) 12
Figura 3. Nivel educativo del jefe/a de hogar (barras) 12
Figura 4. Ingreso per cápita frente a años de estudio del jefe/a (dispersión) 13
Figura 5. Ingreso per cápita según acceso a internet (diagrama de caja) 13
Figura 6. Hogares con internet según decil de ingreso (tendencia) 15
Figura 7. Matriz de correlación de Spearman (mapa de calor) 15
Figura 8. Hogares con internet por departamento (barras) 16
Figura 9. Hogares con internet por nivel educativo y área (barras agrupadas) 16

Índice de tablas

Tablas 1 a 6 — Inventario, diccionario original, clave primaria, calidad, selección y fuente 5-7
Tablas 7 a 12 — Faltantes, atípicos, variables derivadas, integración, bitácora y diccionario final 8-10
Tablas 13 a 19 — Estadísticos descriptivos, frecuencias, correlaciones y tablas de contingencia 11-14
Tablas 20 y 21 — Estimaciones muestrales frente a expandidas; entregables 18-20

1. Etapa 1 — Comprensión del problema

1.1 Contexto del problema

El acceso a internet en el hogar dejó de ser un bien de consumo opcional para convertirse en una condición habilitante del ejercicio de otros derechos: la educación (plataformas escolares y universitarias), el empleo (búsqueda laboral, teletrabajo), el acceso a servicios públicos (trámites en línea, turnos de salud, gestiones tributarias) y la participación económica (banca digital, comercio electrónico). Un hogar sin conexión no queda solamente "desconectado": queda sistemáticamente más lejos de servicios que el resto de la sociedad ya asume como disponibles.

En Paraguay, la discusión pública sobre conectividad se organiza alrededor de dos brechas persistentes: la territorial, entre el área urbana y la rural, y la socioeconómica, entre hogares de distinto nivel de ingreso. Esas brechas son el objeto de programas concretos —planes de conectividad rural, provisión de internet en escuelas, digitalización de trámites del Estado— cuya focalización depende de saber con precisión *qué hogares* están quedando fuera y *qué características* comparten.

Los datos que utilizamos son producidos por el **Instituto Nacional de Estadística (INE)** a través de la **Encuesta Permanente de Hogares Continua (EPHC)**, el relevamiento oficial con el que el país mide condiciones de vida, pobreza, empleo e ingresos. El INE pregunta directamente a cada hogar si cuenta con conexión a internet y, en el mismo formulario, releva la composición del hogar, la educación y la ocupación de sus miembros y el ingreso familiar. Esos datos alimentan indicadores oficiales, el monitoreo de la pobreza y el seguimiento de los Objetivos de Desarrollo Sostenible. La decisión real que está en juego —y que este proyecto busca informar con evidencia— es **dónde y en qué tipo de hogar conviene priorizar la inversión en conectividad** para reducir la exclusión digital.

1.2 Pregunta de investigación

> **¿En qué medida el acceso a internet de los hogares paraguayos relevados por la EPHC Anual 2025 varía según el área de residencia, el nivel de ingreso per cápita y el nivel educativo del jefe/a de hogar, y es posible predecir si un hogar cuenta con conexión a partir de esas características?**

La pregunta cumple los criterios exigidos: es respondible con evidencia y no con opinión (todas sus variables están medidas en los microdatos), está acotada en el tiempo (relevamiento anual 2025) y en alcance (hogares cubiertos por la EPHC), y **admite una respuesta negativa**: es perfectamente posible que las diferencias observadas no resulten estadísticamente sostenibles o que el modelo de la Fase 3 no supere a una línea base trivial.

1.3 Objetivo general

> **Analizar** los factores socioeconómicos, educativos y geográficos asociados al acceso a internet en los hogares paraguayos, a partir de los microdatos de la EPHC Anual 2025, y **evaluar** en qué medida permiten predecir la disponibilidad de conexión en el hogar.

1.4 Objetivos específicos

1. **Caracterizar** la distribución del acceso a internet, del ingreso per cápita mensual, del nivel educativo del jefe/a de hogar y del tamaño del hogar en la muestra 2025, mediante estadística descriptiva univariada. (Fase 1, Etapas 4.1 a 4.3)
2. **Describir** cómo varía la proporción de hogares con internet según el área de residencia, el departamento, el decil de ingreso y la categoría ocupacional del jefe/a, mediante análisis bivariado y visualizaciones. (Fase 1, Etapas 4.4 a 4.7 y 5)
3. **Contrastar** estadísticamente si la proporción de hogares con internet difiere según el área de residencia, el nivel educativo del jefe/a y el nivel de ingreso, verificando los supuestos de cada prueba y reportando el tamaño del efecto. (objetivo de la **fase inferencial** — Fase 2)
4. **Construir y evaluar** un modelo de clasificación binaria que prediga si un hogar cuenta con acceso a internet a partir de área, ingreso, educación, edad y ocupación del jefe/a y tamaño del hogar, comparándolo contra una línea base. (objetivo de la **fase predictiva** — Fase 3)
5. **Discutir** los hallazgos en términos de brecha digital y de focalización de políticas de conectividad, explicitando los límites de lo que los datos permiten afirmar. (Fase 3 y presentación final)

1.5 Justificación de la relevancia

Identificar qué características distinguen a los hogares sin conexión permite pasar de un diagnóstico general ("hay brecha digital") a uno accionable ("la brecha se concentra en hogares rurales cuyo jefe/a no completó la educación básica y que se ubican en los deciles bajos de ingreso"). Esa diferencia es exactamente lo que separa una política universal y cara de una política focalizada y factible.

Los destinatarios naturales de la respuesta son el **Ministerio de Tecnologías de la Información y Comunicación (MITIC)** y la **CONATEL**, que diseñan y regulan los planes de conectividad; el **Ministerio de Educación y Ciencias (MEC)**, cuya oferta digital supone conectividad en el hogar; los **gobiernos departamentales y municipales**, que priorizan obras de infraestructura; y las organizaciones de desarrollo digital que necesitan definir su población objetivo. Además, el indicador de hogares conectados forma parte del seguimiento del ODS 17 sobre medios de implementación.

1.6 Alcance y limitaciones previstas

Qué incluye el análisis: los hogares particulares relevados por la EPHC Anual 2025, con el **hogar** como unidad de análisis y la tenencia declarada de internet como variable objetivo. Las características del jefe/a de hogar (edad, sexo, años de estudio, categoría ocupacional) se utilizan como atributos del hogar.

Qué queda explícitamente fuera:

- **La evolución temporal.** Se trabaja con un corte transversal de un único año; no es un panel ni una secuencia de relevamientos comparables, por lo que no se analizan tendencias entre años.
- **La causalidad.** El diseño es observacional: se podrán afirmar asociaciones, nunca que una variable *cause* el acceso a internet.
- **El uso individual de internet** por cada miembro del hogar, la **calidad o velocidad** de la conexión y el **gasto mensual** en el servicio, que no forman parte del subconjunto de variables seleccionado.

- **La cobertura de la propia encuesta.** La EPHC no releva viviendas colectivas ni población en situación de calle, y su diseño muestral no cubre con representatividad propia a Boquerón y Alto Paraguay ni a las comunidades indígenas. Las conclusiones no se extienden a esas poblaciones.
- **Las estimaciones poblacionales.** El análisis se desarrolla sobre proporciones muestrales sin ponderar; en la sección 5.5 se cuantifica la diferencia respecto de las estimaciones expandidas y se explica por qué.

2. Etapa 2 — Comprensión y selección de los datos

2.1 Inventario de los archivos disponibles

La EPHC Anual 2025 se distribuye como un conjunto de archivos planos separados por nivel de análisis, más el diccionario oficial de variables. Los cuatro archivos utilizados corresponden al mismo relevamiento (la variable `AÑO` toma el valor 2025 en la totalidad de los registros) y se vinculan entre sí por la clave compuesta `UPM + NVIVI + NHOGA`.

Archivo	Formato	Tamaño	Contenido	Unidad	Dimensiones
`REG01_EPHC_ANUAL_2025.csv`	CSV (`;`)	2,35 MB	Sección 2: características de la vivienda e inventario de bienes del hogar (incluye la pregunta sobre internet)	Hogar	17.092 × 60
`REG02_EPHC_ANUAL_2025.csv`	CSV (`;`)	27,01 MB	Secciones 1, 4, 5 y 6: características de la población, educación, salud, empleo e ingresos	Persona	55.934 × 213
`INGREFAM_EPHC_ANUAL_2025.csv`	CSV (`;`)	3,37 MB	Ingreso total y per cápita del hogar, líneas de pobreza, quintiles y deciles	Hogar	17.092 × 44
`diccionario_EPHC_ANUAL_2025.xls`	XLS	0,35 MB	Diccionario oficial del INE; documenta todas las preguntas del formulario	—	—

Tabla 1. Inventario de archivos. Período cubierto: relevamiento anual 2025. `REG01` e `INGREFAM` son de nivel hogar y se corresponden 1 a 1; `REG02` es de nivel persona y se relaciona N a 1 con los anteriores.

Una observación de consistencia: `REG01` e `INGREFAM` tienen exactamente la misma cantidad de filas (17.092), lo que confirma que describen el mismo universo de hogares. Las 55.934 filas de `REG02` equivalen a 3,27 personas por hogar en promedio, coherente con el tamaño medio calculado en la Etapa 4.

2.2 Diccionario de datos del conjunto original

De las 273 columnas disponibles entre los tres archivos de microdatos se seleccionaron 17 variables pertinentes a la pregunta de investigación. El diccionario se reconstruyó a partir del diccionario oficial del INE y de la inspección empírica de cada columna; los porcentajes de faltantes y los rangos fueron calculados sobre los datos reales.

Archivo	Variable	Descripción	Tipo	Unidad	Categorías / rango observado	% falt.
REG01	`UPM, NVIVI, NHOGA`	Clave compuesta del hogar (unidad primaria de muestreo, n.º de vivienda, n.º de hogar)	Identificador	—	17.092 combinaciones únicas	0,00
REG01	`DPTO`	Departamento de residencia	Categórica nominal	—	0 = Asunción … 15 = Pdte. Hayes/Resto (16 categorías)	0,00
REG01	`AREA`	Área de residencia	Categórica binaria	—	1 = Urbana, 6 = Rural	0,00
REG01	`TOTAL`	Cantidad de miembros del hogar	Numérica discreta	personas	1 – 26	0,00
REG01	`V23A1`	El hogar cuenta con computadora o notebook	Categórica binaria	—	1 = Sí (24,0 %), 6 = No (76,0 %)	0,00
REG01	`V23B`	**¿Tiene este hogar internet? — variable objetivo**	Categórica binaria	—	1 = Sí, 6 = No	0,00
REG01	`V23C1`	Tipo de conexión: cable o wifi	Categórica binaria	—	1 = Sí, 6 = No (pregunta filtrada)	37,88
REG01	`V23C2`	Tipo de conexión: módem USB	Categórica binaria	—	1 = Sí, 6 = No (pregunta filtrada)	37,88
REG01	`FACTOR`	Factor de expansión muestral del hogar	Numérica	hogares	7 – 1.080 (media 108)	0,00
REG02	`P03`	Relación de parentesco (se usa para filtrar al jefe/a de hogar)	Categórica nominal	—	1 = Jefe/a	0,00
REG02	`P02`	Edad del miembro del hogar	Numérica discreta	años	0 – 104	0,00
REG02	`P06`	Sexo	Categórica binaria	—	1 = Hombre, 6 = Mujer	0,00
REG02	`AÑOEST`	Años de estudio aprobados	Numérica discreta	años	0 – 18; 99 = No responde	5,76
REG02	`CATE_PEA`	Categoría ocupacional	Categórica nominal	—	1 = Empleado/a público/a … 6 = Doméstico/a	46,10
INGREFAM	`IPCM`	Ingreso per cápita mensual del hogar	Numérica continua	Gs. corrientes	65.433 - 282.911.159	0,00
INGREFAM	`QUINTILI`	Quintil de ingreso per cápita del hogar	Categórica ordinal	—	1 (más pobre) – 5 (más rico)	0,00
INGREFAM	`DECILI`	Decil de ingreso per cápita del hogar	Categórica ordinal	—	1 – 10	0,00

Tabla 2. Diccionario del subconjunto original seleccionado. Los porcentajes de `AÑOEST` y `CATE_PEA` corresponden al archivo completo de personas; una vez restringido a los jefes/as de hogar, `AÑOEST` no presenta nulos (sí 2 registros con el código 99) y `CATE_PEA` queda en 21,88 % de vacíos, que corresponden a jefes/as fuera de la población económicamente activa.

> **Sobre el 37,88 % de faltantes en `V23C1` y `V23C2`:** no es una falla de calidad sino *ausencia estructural por diseño del formulario*. Esas preguntas solo se formulan a los hogares que respondieron afirmativamente `V23B`. La verificación cruzada es exacta: los 6.474 registros vacíos coinciden uno a uno con los 6.474 hogares sin internet, sin una sola excepción. Ambas variables se conservan como información descriptiva del tipo de conexión, pero **quedan excluidas del modelado de la Fase 3**, porque conocer el tipo de conexión equivale a conocer la respuesta (fuga de información hacia la variable objetivo).

2.3 Unidad de análisis y verificación de la clave primaria

La unidad de análisis es el **hogar**. La verificación empírica de la clave arrojó:

Verificación	Resultado	Lectura
Duplicados de `UPM+NVIVI+NHOGA` en `REG01`	0	Clave primaria válida
Duplicados de `UPM+NVIVI+NHOGA` en `INGREFAM`	0	Clave primaria válida
Hogares en `REG01`	17.092	Universo de trabajo
Hogares con exactamente un jefe/a en `REG02` (`P03 = 1`)	17.092	Correspondencia 1 a 1 con `REG01`
Hogares con 0 o más de 1 jefe/a	0	Sin anomalías de parentesco

Tabla 3. Verificación de unicidad de la clave. Al filtrar `REG02` por jefe/a de hogar, cada hogar aporta exactamente una fila, lo que garantiza que la unión posterior no puede duplicar registros.

2.4 Perfilado inicial

- **Dimensiones:** 17.092 × 60 (`REG01`), 55.934 × 213 (`REG02`) y 17.092 × 44 (`INGREFAM`); 273 columnas en total.
- **Tipos detectados frente a tipos correctos:** `DPTO`, `AREA`, `TOTAL`, `V23A1` y `V23B` se leen como enteros, lo que es correcto porque las categóricas están codificadas numéricamente. La discrepancia relevante está en `IPCM`: el archivo `INGREFAM` usa **coma decimal** (por ejemplo `9470322,87750703`), de modo que, si no se declara el separador en la lectura, la columna se interpreta como texto y ningún cálculo numérico es posible. Se corrige en la Etapa 3.
- **Cardinalidad de las categóricas:** `DPTO` = 16 categorías (0 a 15), `AREA` = 2, `V23B` = 2, `V23A1` = 2. Ninguna variable presenta categorías fuera del dominio documentado ni códigos residuales inesperados.
- **Distribución preliminar de las numéricas:** `IPCM` presenta una media de 2.564.009 Gs. frente a una mediana de 1.697.341 Gs. y un máximo de 282.911.159 Gs., lo que anticipa una asimetría derecha muy pronunciada, confirmada en la Etapa 4. La edad del jefe/a se distribuye entre 15 y 104 años y el tamaño del hogar entre 1 y 26 personas.

2.5 Evaluación de calidad

Dimensión	Evaluación
Completitud	Alta. Las variables clave (`V23B`, `AREA`, `DPTO`, `TOTAL`, `IPCM`) no presentan un solo valor faltante. Los únicos vacíos son los estructurales de `V23C1`/`V23C2` (37,88 %), los de categoría ocupacional del jefe/a (21,88 %, equivalentes a "no aplica") y 2 registros con el código de no respuesta en años de estudio.
Consistencia	Alta. Clave única en las tres tablas, un único jefe/a por hogar, dominios de categorías respetados y correspondencia exacta entre el vacío de tipo de conexión y la condición de no tener internet.
Exactitud aparente	Buena, con salvedades. No hay ingresos negativos ni nulos (el mínimo es 65.433 Gs.) ni edades imposibles. Se detectan 2 jefes/as con más de 100 años (102 y 104) y 20 menores de 18 años: improbables pero posibles. El máximo de `IPCM`, 282,9 millones de Gs. per cápita mensuales, es un valor extremo que domina la media; sólo 16 hogares superan los 50 millones.
Actualidad	Relevamiento anual 2025, la versión más reciente disponible al momento de este trabajo.
Trazabilidad	Completa: archivos oficiales del INE con diccionario de variables publicado, documentados en 2.7.

Tabla 4. Evaluación de calidad del conjunto de datos.

2.6 Selección justificada

Se conservan 17 variables y se descartan 256. Cada descarte responde a un objetivo específico que esas variables no ayudan a alcanzar.

Se conserva	Vinculación con los objetivos	Se descarta	Motivo del descarte
`V23B`	Variable objetivo de todo el proyecto (OE 1 a 4)	Resto del inventario de bienes de `REG01` (`V2401` a `V2414`: radio, televisor, heladera, moto, etc.)	No vinculados a ningún objetivo específico; incluirlos desplazaría la pregunta hacia un análisis de bienestar material
`AREA`, `DPTO`	OE 2 (variación geográfica) y OE 3 (contraste urbano/rural)	Módulo completo de salud de `REG02`	Fuera del alcance declarado en 1.6
`IPCM`, `QUINTILI`, `DECILI`	OE 2 y OE 3 (gradiente de ingreso)	Resto de `INGREFAM`: ingresos desagregados por fuente, líneas de pobreza, índices FGT	El proyecto solo necesita el ingreso agregado del hogar y su posición relativa; la pobreza monetaria es una pregunta distinta
`AÑOEST`, `CATE_PEA`, `P02`, `P06` del jefe/a	OE 2, OE 3 y OE 4 (educación y ocupación como factores y predictores)	Las mismas variables para los demás miembros del hogar y el módulo detallado de empleo	La unidad de análisis es el hogar, no la persona; el jefe/a se usa como representante del hogar
`TOTAL`	OE 4 (control del tamaño del hogar)	Variables de materiales de vivienda (piso, paredes, techo, saneamiento)	Pertinentes para una pregunta sobre condiciones habitacionales, no sobre conectividad
`V23A1`, `V23C1`, `V23C2`	Contexto descriptivo del equipamiento y del tipo de conexión (OE 1)	Variables de identificación geográfica fina y metadatos de campo	Riesgo de reidentificación y ausencia de valor analítico al nivel de agregación de este trabajo
`FACTOR`	Permite estimar magnitudes poblacionales y cuantificar el sesgo del análisis sin ponderar (ver 5.5)	`FACPOB` y demás factores de expansión de nivel persona	La unidad de análisis es el hogar

Tabla 5. Selección justificada de variables. No se aplica recorte temporal porque el conjunto corresponde a un único corte anual.

2.7 Documentación de la fuente

Ítem	Detalle
Productor	Instituto Nacional de Estadística (INE), Paraguay
Conjunto	Encuesta Permanente de Hogares Continua (EPHC) – base anual 2025
URL del portal de microdatos	https://www.ine.gov.py/microdatos/ (carpeta EPHC_2025_ANUAL)
Documentación técnica	Catálogo ANDA del INE – https://anda.ine.gov.py
Archivos utilizados	`REG01_EPHC_ANUAL_2025.csv`, `REG02_EPHC_ANUAL_2025.csv`, `INGREFAM_EPHC_ANUAL_2025.csv`, `diccionario_EPHC_ANUAL_2025.xls`
Versión / corte	Base anual 2025, provista por la cátedra
Fecha de obtención	Septiembre de 2026
Cobertura	Nacional, excluidos Boquerón y Alto Paraguay, viviendas colectivas y comunidades indígenas; 17.092 hogares relevados, equivalentes a 1.846.580 hogares expandidos
Licencia y uso	Microdatos públicos y anonimizados de estadística oficial, bajo la Licencia de Uso de la Información Pública del Gobierno Paraguayo. Uso exclusivamente académico; el análisis se realiza a nivel agregado y no se intenta reidentificar hogares ni personas.
Unidades de medida	Ingresos en guaraníes corrientes (Gs.); edad y años de estudio en años cumplidos o aprobados; tamaño del hogar en personas.

Tabla 6. Documentación de la fuente.

3. Etapa 3 — Limpieza y transformación

Toda la limpieza está implementada por código en el notebook, que se ejecuta de principio a fin desde los archivos CSV originales y regenera el dataset final. **No se realizó ninguna edición manual de los datos.**

3.1 Tratamiento de valores faltantes

La cuantificación por columna sobre el subconjunto seleccionado muestra que **ninguna variable de interés analítico tiene faltantes aleatorios**. Los tres casos detectados tienen mecanismos de ausencia distintos y reciben tratamientos distintos:

Variable	Faltantes	Mecanismo de ausencia	Estrategia adoptada y justificación
`V23C1` , `V23C2`	6.474 (37,88 %)	Estructural por diseño del formulario: pregunta filtrada, solo se aplica a hogares con internet	**Conservación explícita.** No se imputa: el vacío significa "no aplica", no "dato desconocido". Se documenta y se excluye del modelado.
`CAT_OCUP_JEFE`	3.739 (21,88 %)	Estructural: el jefe/a está fuera de la población económicamente activa, por lo que no tiene categoría ocupacional	**Conversión en categoría propia** ("Inactivo/No aplica"). Imputar una categoría ocupacional a quien no trabaja introduciría información falsa; tratarlo como nulo perdería un grupo que representa más de una quinta parte de los hogares.
`ANIOS_ESTUDIO_JEFE`	2 (0,01 %)	No respuesta declarada: el INE la codifica con el valor 99, que pandas lee como un número válido	**Recodificación a nulo explícito y conservación de la fila.** Dejar el 99 habría contaminado gravemente cualquier media o correlación. No se elimina el hogar porque el resto de sus variables está completo; los 2 casos quedan fuera de los estadísticos de educación (n = 17.090) y sin categoría en `NIVEL_EDUC_JEFE` .

Tabla 7. Tratamiento de valores faltantes. Detectar el código 99 exige inspeccionar los valores únicos de la variable: no aparece como nulo en ningún conteo automático.

3.2 Detección y tratamiento de duplicados

Se verificaron duplicados exactos (fila completa idéntica) y parciales (misma clave de hogar). El resultado fue **0 duplicados** en las tres tablas y en ambos criterios, consistente con la verificación de unicidad de la clave de la sección 2.3. No se eliminó ningún registro por este motivo.

3.3 Valores atípicos e inconsistencias

Chequeo	Resultado	Decisión
Ingresos negativos o iguales a cero	0	Sin acción necesaria
Atípicos de `IPCM` por regla del rango intercuartílico (por encima de 5.578.099 Gs.)	1.182 hogares (6,9 %)	**Se conservan.** Son hogares de ingreso alto real, no errores de captura: no hay valores negativos ni nulos, la distribución es continua y sin saltos artificiales, y en escala logarítmica resulta aproximadamente simétrica (Figura 1). Eliminarlos sesgaría el análisis justamente en el tramo donde el acceso a internet se aproxima a la universalidad.
Jefes/as menores de 18 años	20 hogares	**Se conservan.** La jefatura adolescente es un fenómeno real que la encuesta releva deliberadamente; la edad mínima observada es 15 años, dentro del dominio válido.
Edad del jefe/a fuera del rango 15-100	2 hogares (102 y 104 años)	**Se conservan.** Improbables pero no imposibles, y sin incidencia sobre los resultados (2 casos sobre 17.092). Se dejan registrados para revisarlos si la Fase 3 los identifica entre los casos peor predichos.
Categorías con la misma semántica escritas de distinta forma	No se detectan	Las variables categóricas vienen codificadas numéricamente en origen, lo que elimina este problema. Las etiquetas de texto se crean en 3.5 de forma controlada.

Tabla 8. Detección de valores atípicos e inconsistencias.

La decisión de conservar los atípicos de ingreso tiene una consecuencia metodológica que se arrastra a todo el trabajo: se prioriza la **mediana** sobre la media, se grafica el ingreso en **escala logarítmica**, se prefiere la correlación de **Spearman** sobre la de Pearson (sección 4.4) y se planifican **pruebas no paramétricas** para la Fase 2.

3.4 Normalización de tipos y formatos

- **Separador decimal.** El archivo `INGREFAM` usa coma decimal, de modo que `IPCM` puede quedar tipificada como texto. La lectura declara explícitamente el separador y, antes de cualquier conversión adicional, se verifica el tipo resultante: la conversión de texto a número solo se aplica si la columna no quedó ya numérica, para que el resultado no dependa del entorno de ejecución. Tras la normalización, `IPCM` es `float64` , con media 2.564.009 Gs. y sin pérdida de registros.
- **Unificación de nombres de columna.** Los tres archivos presentan inconsistencias de mayúsculas y minúsculas en los encabezados (por ejemplo `añoest` frente a `AÑOEST`). Todos los nombres se normalizan a mayúsculas antes de la selección y la unión, para que el código no dependa de la grafía del archivo de origen.
- **Codificación de caracteres.** Los nombres de variables con eñe y tildes se leen correctamente en UTF-8; no fue necesaria conversión adicional. Sí se eliminó la marca de orden de bytes del primer encabezado.
- **Valores en blanco.** Se declararon las cadenas de espacios como nulos en la lectura, para que pandas no las tratara como categorías válidas.
- **Fechas.** No aplica: el conjunto no contiene variables de fecha, al tratarse de una base anual consolidada (`AÑO` es constante e igual a 2025).

3.5 Creación de variables derivadas

Variable derivada	Construcción	Justificación del criterio
`TIENE_INTERNET`	Recodificación de `V23B` : 1 → 1, 6 → 0	Variable objetivo. La codificación 0/1 permite calcular la proporción de hogares conectados como una media y es el formato que requiere la clasificación binaria de la Fase 3. Se verificó que no genera nulos, es decir que todos los valores originales pertenecían al dominio esperado.
`AREA_DESC` , `SEXO_JEFE_DESC`	1 → "Urbana"/"Hombre"; 6 → "Rural"/"Mujer"	Legibilidad de tablas y gráficos; evita errores de interpretación del código 6, que no significa una sexta categoría.

`DPTO_NOMBRE`	Mapeo de los 16 códigos a nombres de departamento	Legibilidad de las visualizaciones geográficas.
`NIVEL_EDUC_JEFE`	Categorización de `ANIOS_ESTUDIO_JEFE` en cuatro niveles: 0-5, 6-9, 10-12 y 13 o más años	**Puntos de corte justificados por la estructura del sistema educativo paraguayo:** 9 años de Educación Escolar Básica más 3 de Educación Media completan el bachillerato a los 12 años. Los cortes separan por lo tanto básica incompleta, básica completa, media completa y estudios superiores. No son cuartiles arbitrarios sino umbrales institucionales, interpretables para un decisor.
`CAT_OCUP_JEFE_DESC`	Mapeo de los 6 códigos ocupacionales; los vacíos se etiquetan como "Inactivo/No aplica"	Ver el tratamiento del faltante estructural en la Tabla 7.

Tabla 9. Variables derivadas. No se aplicó deflactación de montos porque todos los ingresos corresponden al mismo año y no se comparan períodos distintos.

3.6 Integración de fuentes

Se integraron las tres tablas mediante dos uniones sucesivas por la clave compuesta `UPM + NVIVI + NHOGA`, resolviendo previamente la diferencia de granularidad: `REG02` es de nivel persona y se redujo a nivel hogar filtrando por jefe/a de hogar antes de unir.

Paso	Operación	Filas antes	Filas después	Registros sin apareamiento
Reducción de granularidad	Filtro `P03 = 1` sobre `REG02`	55.934	17.092	—
Unión 1	`REG01` + jefes/as (LEFT JOIN)	17.092	17.092	0 (0,00 %)
Unión 2	resultado + ingresos (LEFT JOIN)	17.092	17.092	0 (0,00 %)

Tabla 10. Auditoría de la integración de fuentes.

Se eligió **LEFT JOIN** tomando `REG01` como tabla base porque es la que contiene la variable objetivo: cualquier hogar sin información de jefe/a o de ingreso debía conservarse y hacerse visible como faltante, en lugar de desaparecer del análisis sin dejar rastro. En la práctica el apareamiento fue total. La no duplicación se verifica mediante una aserción en el código que detiene la ejecución si el número de filas cambia respecto del punto de partida.

3.7 Bitácora de limpieza

#	Decisión	Registros afectados	Fundamento
1	Normalización de todos los nombres de columna a mayúsculas	273 columnas	Los tres archivos usan grafías distintas para los mismos campos; sin esto la unión por clave falla
2	Selección de 17 variables sobre 273 disponibles	273 → 17 columnas	Solo se retienen variables ligadas a un objetivo específico (Tabla 5)
3	Filtrado de `REG02` a jefes/as de hogar	55.934 → 17.092 filas	La unidad de análisis es el hogar; el jefe/a se usa como representante de sus características
4	Conversión de `IPCM` a numérico contemplando la coma decimal, con verificación previa del tipo	17.092 valores	El formato regional del archivo impedía cualquier cálculo; la verificación de tipo evita que el resultado dependa del entorno
5	Recodificación del código 99 ("No responde") de años de estudio a nulo explícito	2 valores	99 no es una cantidad de años válida; dejarlo distorsionaría medias, correlaciones y la categorización educativa
6	Conversión del vacío de categoría ocupacional en la categoría "Inactivo/No aplica"	3.739 hogares (21,88 %)	El vacío tiene significado propio (jefe/a fuera de la PEA), no es un dato perdido
7	Conservación de atípicos de ingreso alto	1.182 hogares (6,9 %)	Valores reales y plausibles, no errores de captura (Tabla 8)
8	Conservación de jefes/as menores de 18 años	20 hogares	Casos reales de jefatura adolescente relevados por la encuesta
9	Conservación de jefes/as mayores de 100 años	2 hogares	Improbables pero no imposibles; se documentan para revisión en la Fase 3
10	Conservación explícita del faltante estructural de tipo de conexión	6.474 hogares (37,88 %)	El vacío significa "no aplica"; imputarlo introduciría información falsa
11	Creación de 6 variables derivadas	17.092 filas	Ver Tabla 9
12	Unión de las 3 tablas por `UPM+NVIVI+NHOGA`	17.092 filas, 0 % sin apareamiento	Clave verificada como única en 2.3; aserción de no duplicación en el código
13	Exportación del dataset limpio	17.092 filas × 21 columnas	Insumo congelado para las Fases 2 y 3

Tabla 11. Bitácora de limpieza. Ningún hogar fue eliminado: las 17.092 filas originales se conservan íntegras en el dataset final.

3.8 Diccionario de datos del conjunto final

Variable	Descripción	Tipo	Unidad	Rango o categorías observadas	% falt.
`UPM, NVIVI, NHOGA`	Clave primaria compuesta del hogar	Identificador	—	Única para 17.092 hogares	0,00
`DPTO` / `DPTO_NOMBRE`	Departamento (código y nombre)	Categórica nominal	—	16 categorías	0,00
`AREA` / `AREA_DESC`	Área de residencia (código y etiqueta)	Categórica binaria	—	Urbana (57,2 %), Rural (42,8 %)	0,00
`TOTAL`	Miembros del hogar	Numérica discreta	personas	1 – 26	0,00
`V23A1`	Tenencia de computadora	Categórica binaria	—	1 = Sí (24,0 %), 6 = No (76,0 %)	0,00
`TIENE_INTERNET`	**Variable objetivo:** el hogar cuenta con	Binaria (0/1)	—	1 = Sí (62,1 %), 0 = No (37,9 %)	0,00

	internet				
`V23C1`, `V23C2`	Tipo de conexión (cable o wifi; módem USB)	Categórica binaria	—	1 = Sí, 6 = No, vacío = no aplica	37,88
`EDAD_JEFE`	Edad del jefe/a de hogar	Numérica discreta	años	15 – 104	0,00
`SEXO_JEFE_DESC`	Sexo del jefe/a	Categórica binaria	—	Hombre (60,9 %), Mujer (39,1 %)	0,00
`ANIOS_ESTUDIO_JEFE`	Años de estudio aprobados del jefe/a	Numérica discreta	años	0 – 18	0,01
`NIVEL_EDUC_JEFE`	Nivel educativo categorizado del jefe/a	Categórica ordinal	—	4 categorías (básica incompleta a superior)	0,01
`CAT_OCUP_JEFE_DESC`	Categoría ocupacional del jefe/a	Categórica nominal	—	6 categorías más "Inactivo/No aplica" (21,9 %)	0,00
`IPCM`	Ingreso per cápita mensual del hogar	Numérica continua	Gs. corrientes	65.433 - 282.911.159	0,00
`QUINTIL_ING` / `DECIL_ING`	Quintil y decil de ingreso per cápita	Categórica ordinal	—	1 – 5 y 1 – 10	0,00
`FACTOR`	Factor de expansión muestral del hogar	Numérica	hogares	7 – 1.080	0,00

Tabla 12. Diccionario del dataset final (`dataset_limpio_internet_hogares.csv`): 17.092 filas × 21 columnas.

4. Etapa 4 — Análisis univariado y bivariado

4.1 Univariado — variables numéricas

Estadístico	IPCM (Gs.)	Edad del jefe/a (años)	Años de estudio del jefe/a	Miembros del hogar
n	17.092	17.092	17.090	17.092
Media	2.564.009	50,73	8,83	3,27
Mediana	1.697.341	50,00	8,00	3,00
Moda	1.500.000	41,00	6,00	3,00
Desvío estándar	5.468.107	16,46	4,84	1,76
Coeficiente de variación	2,13	0,32	0,55	0,54
Mínimo	65.433	15	0	1
Máximo	282.911.159	104	18	26
Percentil 5	509.927	26	2	1
Percentil 25	1.035.616	37	5	2
Percentil 50	1.697.341	50	8	3
Percentil 75	2.852.609	63	12	4
Percentil 95	6.503.367	79	17	6
Rango intercuartílico	1.816.993	26	7	2
Asimetría	30,85	0,20	0,17	1,15
Curtosis	1.353,66	−0,75	−1,07	3,84

Tabla 13. Estadísticos descriptivos de las variables numéricas del dataset final.

¿Es la media un resumen adecuado? Para `IPCM`, claramente **no**: con una asimetría de 30,85 y una curtosis de 1.353,66 la distribución está dominada por una cola derecha extrema. La media supera a la mediana en un 51 %, el desvío estándar es más del doble de la media (CV = 2,13) y el percentil 99 (14,7 millones) está a veinte veces de distancia del máximo. El resumen representativo del hogar típico es la **mediana**. Para **edad** (asimetría 0,20; curtosis −0,75) y **años de estudio** (0,17 y −1,07) la media sí es adecuada: ambas son prácticamente simétricas, aunque platicúrticas —más aplanadas que una normal–, lo que en el caso de la educación anticipa la estructura multimodal visible en la Figura 3. El **tamaño del hogar** presenta asimetría moderada (1,15) con una cola derecha corta: solo 3 hogares tienen 15 o más miembros. Media y mediana son casi iguales (3,27 frente a 3), de modo que ambas informan bien.

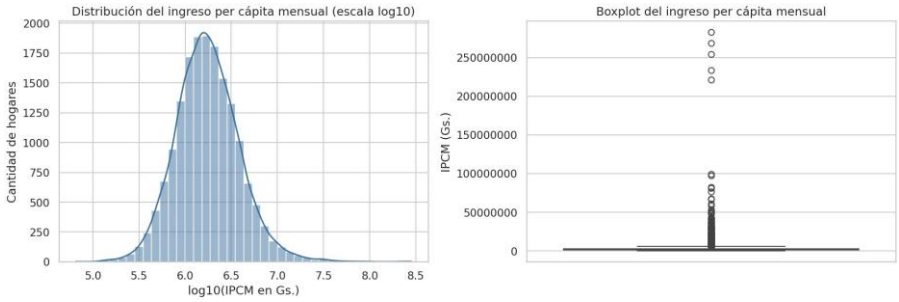
4.2 Univariado — variables categóricas

Variable	Categoría	Frecuencia absoluta	Frecuencia relativa
Tiene internet	Sí	10.618	62,1 %
	No	6.474	37,9 %
Área de residencia	Urbana	9.770	57,2 %
	Rural	7.322	42,8 %
Nivel educativo del jefe/a	2. Básica completa (6-9 años)	5.509	32,2 %
	1. Básica incompleta (0-5 años)	4.328	25,3 %
	4. Superior (13 o más años)	3.838	22,5 %
	3. Media/Bachillerato (10-12 años)	3.415	20,0 %
Sexo del jefe/a	Hombre	10.416	60,9 %
	Mujer	6.676	39,1 %
Categoría ocupacional del jefe/a	Cuenta propia	5.687	33,3 %
	Empleado/a privado/a	4.325	25,3 %
	Inactivo/No aplica	3.739	21,9 %
	Empleado/a público/a	1.360	8,0 %
	Empleador/a	1.040	6,1 %
	Doméstico/a	796	4,7 %
	Familiar no remunerado	145	0,8 %

Tabla 14. Distribución de frecuencias de las principales variables categóricas. Los 2 hogares sin nivel educativo del jefe/a quedan excluidos de esa fila.

Análisis de concentración. La variable con mayor cardinalidad es el departamento (16 categorías). Los tres departamentos más representados —Central (16,0 %, 2.739 hogares), Alto Paraná (11,6 %, 1.977) e Itapúa (8,5 %, 1.457)– concentran el **36,1 %** de la muestra: el 19 % de las categorías explica más de un tercio del total. El menos representado, Pdte. Hayes/Resto, reúne 602 hogares (3,5 %). La concentración sigue la distribución poblacional del país, pero obliga a ser prudentes con las tasas departamentales, porque los departamentos con menos observaciones tienen estimaciones menos precisas. En la ocupación del jefe/a también hay concentración: las dos primeras categorías explican el 58,6 % de los hogares.

4.3 Visualizaciones univariadas



Figuras 1 y 2. Distribución del ingreso per cápita mensual del hogar: histograma con densidad en escala logarítmica (izquierda) y diagrama de caja en escala original (derecha). ***Interpretación:*** en escala logarítmica la distribución se aproxima a una forma simétrica y unimodal, lo que indica que el ingreso sigue aproximadamente una ley log-normal y que la asimetría de la Tabla 13 es de naturaleza multiplicativa, no producto de un error de datos. El diagrama de caja muestra la magnitud del problema en escala original: la caja queda comprimida contra el eje y toda la parte visible del gráfico la ocupan los valores extremos, incluidos unos pocos hogares por encima de los 200 millones de Gs. per cápita.

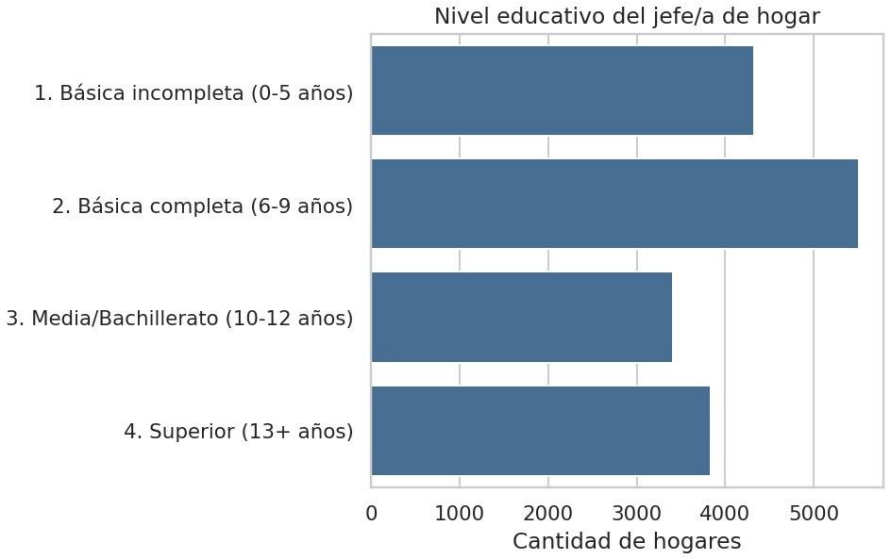


Figura 3. Nivel educativo del jefe/a de hogar, en cantidad de hogares. ***Interpretación:*** la categoría más frecuente es "Básica completa" (5.509 hogares, 32,2 %), seguida de "Básica incompleta" (25,3 %); las dos categorías de mayor nivel reúnen en conjunto el 42,5 %. Llama la atención que "Superior" (22,5 %) supere a "Media/Bachillerato" (20,0 %), lo que sugiere una distribución con dos concentraciones —una amplia base con educación básica y un grupo relevante que completó estudios superiores— y un tramo intermedio comparativamente delgado.

4.4 Bivariado — numérica frente a numérica

Se analizó la relación entre los años de estudio del jefe/a de hogar y el ingreso per cápita del hogar. Los dos coeficientes calculados difieren de manera reveladora:

Coeficiente	Valor	Valor p	Lectura
Pearson (r)	0,171	$7{,}0 \times 10^{-113}$	Mide asociación *lineal* sobre los valores originales; queda fuertemente atenuado por los valores extremos de ingreso
Spearman (ρ)	0,451	$< 10^{-300}$	Mide asociación *monótona* sobre rangos; es el coeficiente apropiado dada la asimetría de `IPCM`

Tabla 15. Correlación entre años de estudio del jefe/a e ingreso per cápita del hogar.

La distancia entre ambos coeficientes (0,171 frente a 0,451) no es un detalle técnico: es la consecuencia directa de la cola extrema documentada en la Etapa 3. Con unos pocos hogares de ingreso altísimo, la recta de mínimos cuadrados se vuelve inestable y Pearson subestima una relación que, en términos de orden, es claramente moderada. **Se adopta Spearman como medida de referencia**, y la misma lógica se aplicará a la elección de pruebas en la Fase 2.

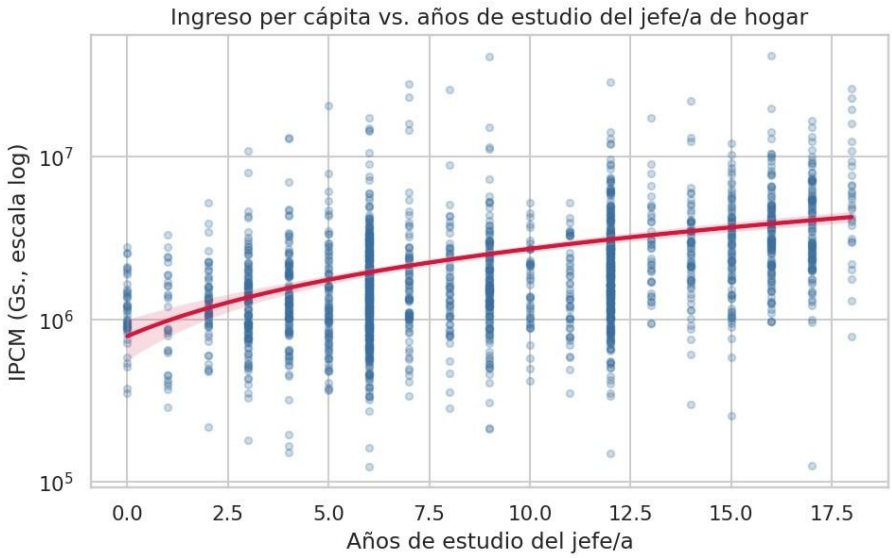


Figura 4. Ingreso per cápita mensual (escala logarítmica) frente a años de estudio del jefe/a de hogar, con recta de ajuste, sobre una submuestra aleatoria de 2.000 hogares (semilla 42) para que la nube resulte legible. *Interpretación:* la tendencia es positiva y de intensidad moderada; el ingreso típico crece de forma sostenida a lo largo de todo el rango educativo, pero la dispersión dentro de cada nivel es muy grande, con hogares de ingresos bajos y altos en prácticamente todas las columnas. Esto es consistente con la literatura sobre retornos a la educación y advierte que educación e ingreso no son factores independientes: la educación es una **potencial variable de confusión** en la relación entre ingreso y acceso a internet, algo que deberá discutirse en la Fase 2.

4.5 Bivariado — numérica frente a categórica

Acceso a internet	n	Mediana de IPCM (Gs.)	Media de IPCM (Gs.)	Desvío estándar (Gs.)	Edad media del jefe/a	Miembros (media)
Sin internet	6.474	1.100.000	1.474.903	3.354.115	54,1	3,19
Con internet	10.618	2.207.393	3.228.058	6.333.195	48,7	3,32

Tabla 16. Estadísticos de las variables numéricas según acceso a internet del hogar.

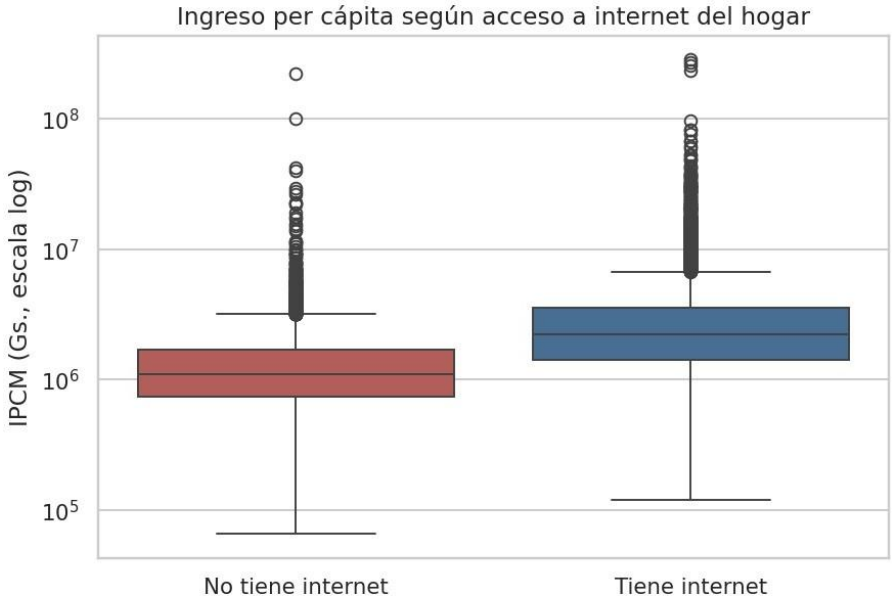


Figura 5. Ingreso per cápita mensual (escala logarítmica) según acceso a internet del hogar. *Interpretación:* la mediana de los hogares conectados duplica a la de los no conectados (2.207.393 frente a 1.100.000 Gs.) y el desplazamiento afecta a toda la distribución, no solo al centro. El solapamiento que persiste entre ambas cajas confirma, sin embargo, que el ingreso no separa perfectamente a los dos grupos: existen hogares de ingreso bajo con conexión y hogares de ingreso alto sin ella. En la Fase 2 se contrastará la diferencia mediante la prueba U de Mann-Whitney, apropiada dada la asimetría de la variable.

Las otras dos comparaciones de la Tabla 16 son igualmente informativas por su contraste. La **edad del jefe/a** difiere de forma apreciable: 48,7 años en promedio en los hogares conectados frente a 54,1 en los no conectados, una brecha de 5,4 años que sugiere un componente generacional en la adopción. En cambio el **tamaño del hogar** es prácticamente idéntico entre ambos grupos (3,32 frente a 3,19 miembros), una diferencia de apenas 0,13 personas que anticipa un efecto irrelevante en la práctica, por más que la prueba formal pueda declararla significativa.

4.6 Bivariado — categórica frente a categórica

Área de residencia	Hogares	Sin internet	Con internet	% sin internet	% con internet
Urbana	9.770	1.992	7.778	20,4 %	79,6 %
Rural	7.322	4.482	2.840	61,2 %	38,8 %
Total	17.092	6.474	10.618	37,9 %	62,1 %

Tabla 17. Tabla de contingencia: acceso a internet según área de residencia, con frecuencias absolutas y relativas por fila.

Nivel educativo del jefe/a	Hogares	% sin internet	% con internet
1. Básica incompleta (0-5 años)	4.328	63,7 %	36,3 %
2. Básica completa (6-9 años)	5.509	44,4 %	55,6 %
3. Media/Bachillerato (10-12 años)	3.415	25,0 %	75,0 %
4. Superior (13 o más años)	3.838	10,8 %	89,2 %

Tabla 18. Tabla de contingencia: acceso a internet según nivel educativo del jefe/a.

Interpretación conjunta. Las dos tablas describen las brechas centrales del trabajo. La **territorial** es de 40,8 puntos porcentuales: prácticamente cuatro de cada cinco hogares urbanos tienen internet, frente a menos de dos de cada cinco rurales. La **educativa** es aún mayor en amplitud total (52,9 puntos entre extremos) y, sobre todo, es **estrictamente monótona**: cada escalón educativo adicional se asocia con un aumento de la proporción de hogares conectados, sin ninguna inversión de la tendencia. El salto más grande se produce al pasar de básica incompleta a básica completa (19,3 puntos).

4.7 Otras asociaciones exploradas

Variable	Categoría	% con internet	Lectura
Categoría ocupacional del jefe/a	Empleado/a público/a	85,3 %	El gradiente ocupacional es amplio (46 puntos entre extremos) y coherente con la estabilidad y formalidad del vínculo laboral: el empleo público y la condición de empleador/a encabezan, el trabajo por cuenta propia queda por debajo del promedio nacional y el trabajo familiar no remunerado, en el extremo inferior.
	Empleador/a	84,9 %	
	Empleado/a privado/a	70,5 %	
	Cuenta propia	52,2 %	
	Familiar no remunerado	39,3 %	
Sexo del jefe/a	Mujer	63,2 %	Diferencia de apenas 1,7 puntos: el sexo del jefe/a **no** discrimina el acceso a internet. Es un hallazgo negativo útil, porque descarta una hipótesis plausible a priori y evita incorporar una variable sin poder explicativo.
	Hombre	61,5 %	
Tenencia de computadora	Con computadora	93,8 %	La asociación es la más fuerte de todo el análisis (41,7 puntos), pero debe interpretarse con cautela: computadora e internet son bienes complementarios que se adquieren de forma conjunta, de modo que la relación es en buena medida tautológica y no informa sobre las causas de la exclusión digital.
	Sin computadora	52,1 %	

Tabla 19. Asociaciones adicionales entre características del hogar y acceso a internet.

5. Etapa 5 — Análisis descriptivo y exploratorio integrado

Nota metodológica sobre la serie temporal. La guía de la Fase 1 solicita al menos una visualización de serie temporal. La EPHC Anual 2025 es un **corte transversal de un único año**: no es un panel ni una secuencia de relevamientos comparables sobre los mismos hogares, y la única variable temporal del conjunto (`AÑO`) es constante. Construir una serie temporal sería metodológicamente incorrecto. En su lugar se incluye una **visualización de tendencia sobre una variable ordinal** (deciles de ingreso, Figura 6), que cumple la misma función analítica: mostrar cómo evoluciona la proporción de hogares conectados a lo largo de una dimensión ordenada. La limitación queda registrada aquí y en la conclusión, y se compensa elevando a nueve la cantidad de visualizaciones distintas presentadas.

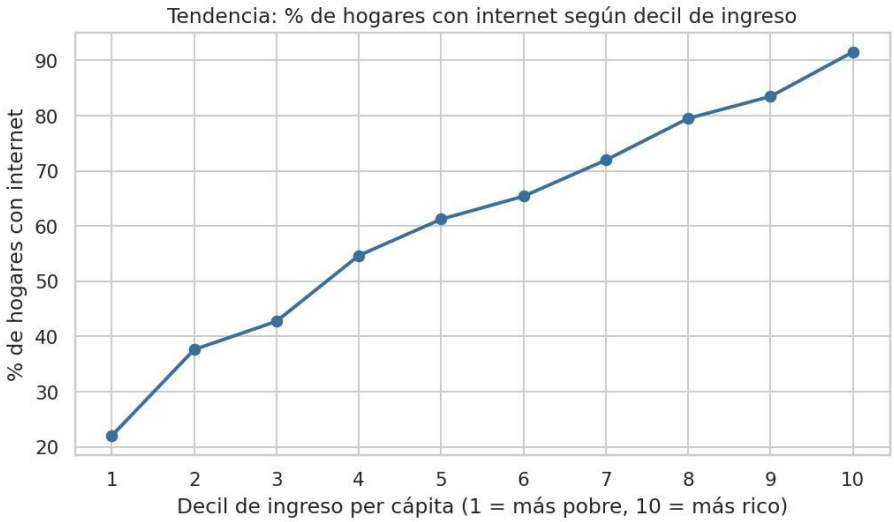


Figura 6. Porcentaje de hogares con internet según decil de ingreso per cápita (1 = decil más pobre, 10 = más rico). *Interpretación:* la relación es creciente y estrictamente monótona: 22,0 % de hogares conectados en el decil más pobre frente a 91,5 % en el más rico, un rango de 69,5 puntos porcentuales. La pendiente es más pronunciada en la primera mitad de la distribución —entre los deciles 1 y 4 la conectividad pasa de 22,0 % a 54,7 %— y se aplana en los deciles superiores, donde el acceso se aproxima a la saturación. Leído por quintiles, el gradiente va de 29,5 % a 87,7 %.

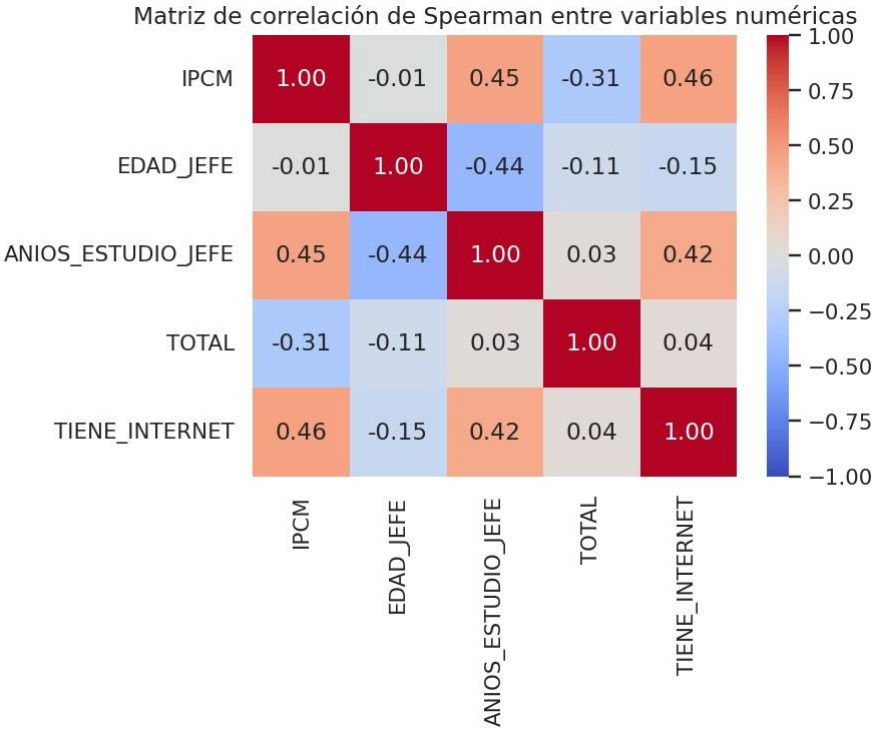


Figura 7. Matriz de correlación de Spearman entre las variables numéricas del dataset. *Interpretación:* la tenencia de internet correlaciona de forma moderada y positiva con el ingreso per cápita ($\rho = 0{,}46$) y con los años de estudio del jefe/a ($\rho = 0{,}42$), y negativamente con la edad del jefe/a ($\rho = -0{,}15$), consistente con la brecha generacional de la Tabla 16. El tamaño del hogar es prácticamente independiente del acceso a internet ($\rho = 0{,}04$) pese a correlacionar negativamente con el ingreso per cápita ($\rho = -0{,}31$), lo cual es aritméticamente esperable porque el ingreso se divide entre los miembros. Las correlaciones entre predictores —educación con ingreso ($\rho = 0{,}45$) y educación con edad ($\rho = -0{,}44$)— advierten sobre la colinealidad que deberá considerarse en el modelado de la Fase 3.

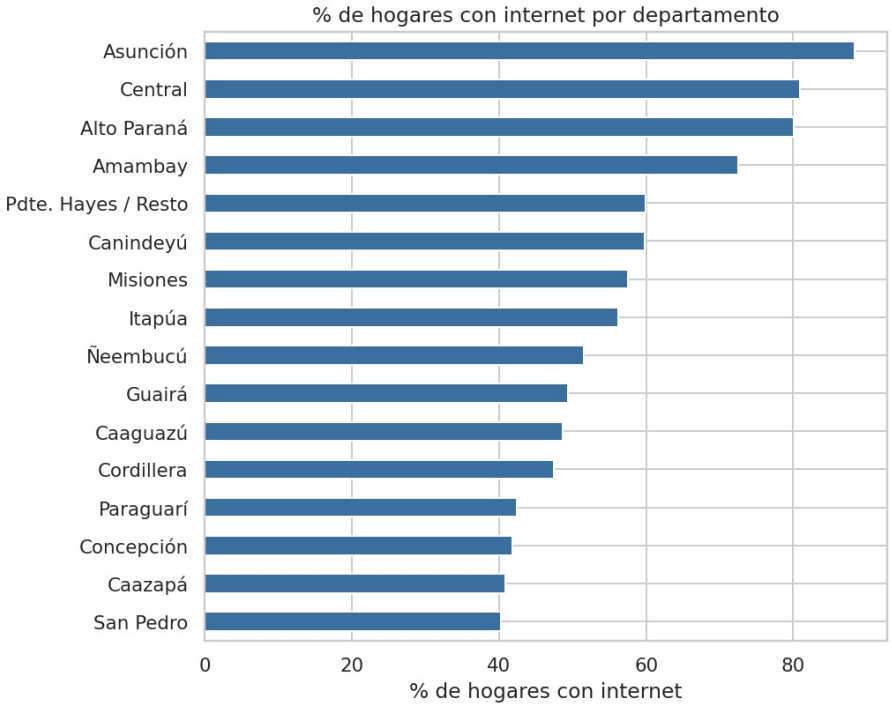


Figura 8. Porcentaje de hogares con internet por departamento, ordenado de mayor a menor. *Interpretación:* Asunción encabeza con 88,3 % de hogares conectados, seguida por Central (80,9 %) y Alto Paraná (80,1 %), los tres territorios más urbanizados del país. En el extremo opuesto, San Pedro (40,2 %), Caazapá (40,8 %), Concepción (41,8 %) y Paraguarí (42,5 %) no alcanzan a conectar a la mitad de sus hogares. La brecha entre el primero y el último departamento es de 48,1 puntos porcentuales y reproduce el patrón urbano-rural de la Tabla 17.

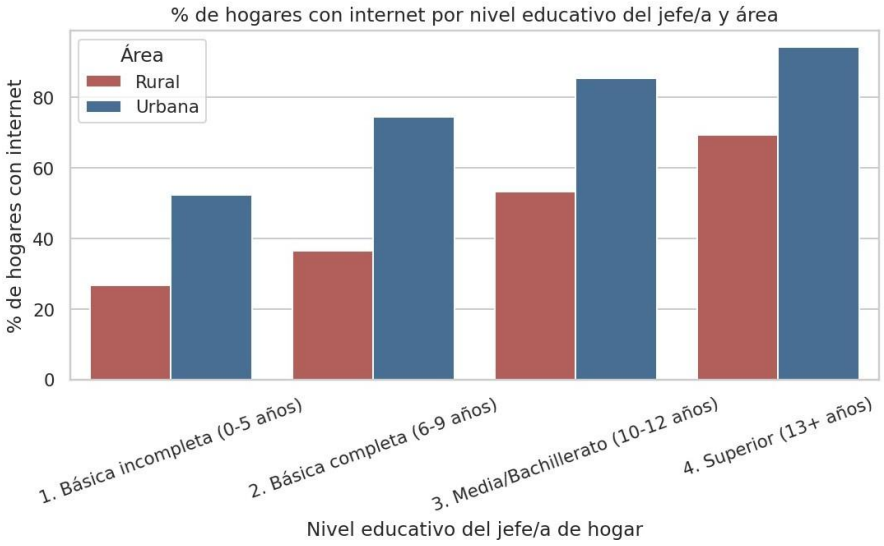


Figura 9. Porcentaje de hogares con internet según nivel educativo del jefe/a, desagregado por área de residencia. *Interpretación:* el gradiente educativo se mantiene **dentro** de cada área (rural: 26,7 % → 36,5 % → 53,2 % → 69,3 %; urbana: 52,5 % → 74,4 % → 85,4 % → 94,2 %), pero el nivel de partida rural es sistemáticamente inferior, con diferencias de entre 24,9 y 37,9 puntos en cada categoría. El dato más elocuente es que un hogar **rural** con jefe/a de nivel superior (69,3 %) sigue por debajo de un hogar **urbano** con jefe/a de educación básica completa (74,4 %): la educación no compensa por completo la desventaja territorial. Ambos factores aportan información propia, lo que justifica incluirlos simultáneamente en el modelo multivariado de la Fase 3.

5.1 Caracterización integrada del fenómeno

Los resultados anteriores describen un fenómeno con una estructura nítida. En la muestra de 17.092 hogares, algo más de seis de cada diez (62,1 %) declaran contar con internet, pero ese promedio esconde situaciones muy distintas. El acceso no se distribuye al azar: se organiza a lo largo de cuatro ejes que además están correlacionados entre sí.

El **eje territorial** es el más visible. La diferencia urbano-rural (79,6 % frente a 38,8 %) se reproduce a nivel departamental con una amplitud de 48,1 puntos, ordenando a los departamentos casi exactamente según su grado de urbanización. El **eje económico** aparece como un gradiente continuo y sin quiebres a lo largo de los deciles de ingreso, más empinado en la parte baja de la distribución, donde cada guaraní adicional parece pesar más. El **eje educativo** es el de mayor amplitud total (52,9 puntos entre extremos) y el único estrictamente escalonado categoría por categoría. A ellos se suma un **eje ocupacional y generacional**: la formalidad del vínculo laboral del jefe/a marca 46 puntos de diferencia entre el empleo público y el trabajo familiar no remunerado, y los jefes/as de hogares conectados son en promedio 5,4 años más jóvenes.

Lo más interesante aparece cuando se cruzan los ejes. La Figura 9 muestra que el efecto educativo persiste dentro de cada área y que la desventaja rural persiste dentro de cada nivel educativo: ninguno de los dos factores absorbe al otro. Al mismo tiempo, la matriz de correlaciones advierte que educación e ingreso están asociados entre sí ($\rho = 0{,}45$), de modo que parte de lo que parece "efecto de la educación" podría ser efecto del ingreso que la educación produce, y viceversa. Separar ambos aportes es

precisamente lo que solo un análisis multivariado puede hacer, y es la tarea que queda planteada para las fases siguientes.

Conviene también registrar lo que *no* aparece. El sexo del jefe/a de hogar no discrimina el acceso (1,7 puntos de diferencia) y el tamaño del hogar tampoco ($\rho = 0{,}04$). Son resultados negativos, pero útiles: descartan dos hipótesis plausibles a priori y evitan que el modelo de la Fase 3 se cargue de variables sin poder explicativo.

5.2 Patrones y anomalías identificados

1. **Brecha urbano-rural de 40,8 puntos porcentuales.** Evidencia: Tabla 17 (79,6 % urbano frente a 38,8 % rural, sobre 9.770 y 7.322 hogares respectivamente) y Figura 8, donde el orden de los departamentos replica su grado de urbanización. Es el contraste más grande entre dos grupos de tamaño comparable.
2. **Gradiente educativo estrictamente monótono.** Evidencia: Tabla 18 (36,3 % → 55,6 % → 75,0 % → 89,2 %) y Figura 9, donde el gradiente se sostiene dentro de cada área. No hay ninguna inversión de tendencia, lo que descarta que se trate de ruido muestral en alguna categoría intermedia.
3. **Asimetría extrema del ingreso per cápita.** Evidencia: asimetría de 30,85 y curtosis de 1.353,66 (Tabla 13), media un 51 % superior a la mediana, percentil 95 de 6,5 millones frente a un máximo de 282,9 millones. Es una anomalía de forma, no de calidad, pero condiciona todas las decisiones estadísticas posteriores y explica por sí sola la diferencia entre los coeficientes de Pearson y de Spearman de la Tabla 15.
4. **El tamaño del hogar no se asocia con la conectividad.** Evidencia: $\rho = 0{,}04$ (Figura 7) y medias de 3,32 frente a 3,19 miembros (Tabla 16), pese a que la variable sí se asocia negativamente con el ingreso per cápita ($\rho = -0{,}31$). Es un resultado contraintuitivo que conviene contrastar formalmente antes de descartar la variable.
5. **Concentración de la muestra en pocos departamentos.** Evidencia: Central, Alto Paraná e Itapúa reúnen el 36,1 % de los hogares, mientras que seis departamentos aportan menos del 4,5 % cada uno. Las tasas departamentales de la Figura 8 tienen, por lo tanto, precisión desigual.
6. **Coherencia interna del formulario como control de calidad.** Evidencia: los 6.474 vacíos de `v23c1` y `v23c2` coinciden exactamente, registro por registro, con los 6.474 hogares sin internet. No es una anomalía sino una verificación: confirma que el filtro del cuestionario se aplicó correctamente y que la variable objetivo es internamente consistente.

5.3 Hipótesis preliminares para la Fase 2

De los patrones anteriores se derivan cinco hipótesis que se contrastarán formalmente en la Fase 2, con un nivel de significancia declarado de antemano de $\alpha = 0{,}05$ y con corrección por comparaciones múltiples, dado que pertenecen a una misma familia.

H1 — Área de residencia

H_0: $p_{urbano} = p_{rural}$, la proporción de hogares con internet es la misma en ambas áreas.
H_1: $p_{urbano} \neq p_{rural}$.
En lenguaje natural: vivir en zona urbana o rural no cambia la probabilidad de que el hogar tenga internet, frente a la alternativa de que sí la cambia.
Prueba prevista: chi-cuadrado de independencia con V de Cramér como tamaño del efecto; complementariamente, prueba z de dos proporciones con intervalo de confianza para la diferencia observada de 40,8 puntos.

H2 — Nivel educativo del jefe/a de hogar

H_0: el acceso a internet es independiente del nivel educativo del jefe/a; las cuatro proporciones son iguales.
H_1: al menos una de las proporciones difiere del resto.
En lenguaje natural: el nivel de estudios del jefe/a no guarda relación con que el hogar esté conectado, frente a la alternativa de que sí la guarda.
Prueba prevista: chi-cuadrado de independencia sobre la tabla 4 × 2, con V de Cramér y análisis de residuos estandarizados para identificar qué categorías se apartan más de lo esperado.

H3 — Ingreso per cápita

H_0: la distribución del ingreso per cápita es la misma en hogares con y sin internet.
H_1: las distribuciones difieren.
En lenguaje natural: conectados y no conectados tienen ingresos equivalentes, frente a la alternativa de que no.
Prueba prevista: U de Mann-Whitney, elegida por la asimetría extrema documentada en la Tabla 13, que invalida el supuesto de normalidad de la prueba t; tamaño del efecto mediante $r = Z/\sqrt{N}$ e intervalo de confianza **por bootstrap** para la diferencia de medianas, comparado con su equivalente clásico.

H4 — Correlación entre educación e ingreso

H_0: $\rho = 0$, no existe correlación monótona entre los años de estudio del jefe/a y el ingreso per cápita del hogar.
H_1: $\rho \neq 0$.
En lenguaje natural: que el jefe/a haya estudiado más años no tiene relación con el ingreso del hogar, frente a la alternativa de que sí la tiene.
Prueba prevista: prueba de significancia sobre el coeficiente de Spearman (estimado en 0,451 en esta fase), con intervalo de confianza. Es la hipótesis que permitirá discutir la **confusión** entre educación e ingreso en la explicación de la conectividad.

H5 — Tamaño del hogar

H_0: la distribución del tamaño del hogar es la misma en hogares con y sin internet.
H_1: las distribuciones difieren.
En lenguaje natural: la cantidad de personas que viven en el hogar no se relaciona con que tenga internet, frente a la alternativa de que sí.
Prueba prevista: U de Mann-Whitney. Se anticipa que, con n = 17.092, la prueba podría resultar significativa pese a que la diferencia observada es de 0,13 miembros y la correlación de apenas 0,04: es el caso testigo para discutir la **diferencia entre significancia estadística y relevancia práctica** y para justificar por qué el tamaño del efecto es obligatorio.

5.4 Decisiones metodológicas que condicionan las fases siguientes

- **Estadística robusta y no paramétrica.** Por la asimetría de `IPCM`, la Fase 2 utilizará mediana, Mann-Whitney y chi-cuadrado en lugar de media y prueba t, salvo que la verificación de supuestos indique lo contrario.
- **Variable objetivo y predictores.** La Fase 3 abordará una **clasificación binaria** sobre `TIENE_INTERNET`, con `AREA`, `IPCM` (o su logaritmo, dada la forma log-normal de la Figura 1), `ANIOS_ESTUDIO_JEFE`, `EDAD_JEFE`, `TOTAL`, `DPTO` y `CAT_OCUP_JEFE_DESC` como predictores candidatos.
- **Exclusiones obligatorias del modelo.** `V23C1` y `V23C2` quedan fuera por fuga de información. `V23A1` (tenencia de computadora) se evaluará con cautela por la misma razón: es un bien complementario, no un determinante. `QUINTIL_ING` y `DECIL_ING` no se usarán junto con `IPCM` por ser transformaciones de la misma variable.
- **Partición aleatoria, no cronológica.** Al no existir componente temporal, la división entrenamiento/prueba será aleatoria estratificada por la variable objetivo, con semilla fijada.
- **Desbalance moderado.** La proporción 62,1 / 37,9 no exige técnicas de remuestreo, pero impide usar la exactitud como métrica única: la línea base de la clase mayoritaria ya alcanza un 62,1 % de aciertos, y ese es el umbral que todo modelo deberá superar.

5.5 El factor de expansión y el alcance de las cifras presentadas

La EPHC tiene un diseño muestral complejo, estratificado y por conglomerados, y cada hogar lleva asignado un factor de expansión (`FACTOR`) que indica cuántos hogares de la población representa. En esta muestra el factor varía entre 7 y 1.080, con una media de 108, y la suma de todos los factores equivale a **1.846.580 hogares** en el país.

Todas las cifras de este informe son proporciones muestrales sin ponderar. Esa decisión es adecuada para describir la muestra y comparar grupos dentro de ella, que es lo que esta fase requiere, pero no es inocua y conviene cuantificar su efecto:

Indicador	Muestral (sin ponderar)	Expandido (ponderado por `FACTOR`)	Diferencia
Hogares con internet, total del país	62,1 %	70,3 %	+8,2 p.p.
Hogares con internet, área urbana	79,6 %	81,7 %	+2,1 p.p.
Hogares con internet, área rural	38,8 %	42,4 %	+3,6 p.p.
Peso del área rural en el total	42,8 %	29,0 %	−13,8 p.p.

Tabla 20. Comparación entre estimaciones muestrales y expandidas.

La última fila explica todo lo demás: el diseño de la encuesta **sobre-representa deliberadamente al área rural** (42,8 % de la muestra frente a 29,0 % de la población de hogares) para garantizar precisión en ese dominio. Como el área rural tiene mucha menos conectividad, la media simple de la muestra *subestima* la conectividad nacional en algo más de ocho puntos. Las conclusiones cualitativas de este informe —el signo, el orden y la magnitud relativa de las brechas— no cambian al ponderar, pero **las cifras absolutas no deben citarse como estimaciones oficiales del INE**. La variable se conservó en el dataset final para poder reportar estimaciones poblacionales en las fases siguientes cuando corresponda.

6. Conclusión de la Fase 1

6.1 Principales resultados

El trabajo partió de tres archivos de microdatos de la EPHC Anual 2025 —17.092 hogares, 55.934 personas y 273 variables— y produjo un dataset analítico de 17.092 filas por 21 columnas, sin pérdida de un solo hogar y con cada decisión registrada en una bitácora de trece entradas. La integración de las tres fuentes por la clave `UPM+NVIVI+NHOGA` resultó completa: 0 % de registros sin apareamiento y 0 duplicados.

Sobre ese conjunto, el análisis exploratorio muestra que el 62,1 % de los hogares de la muestra declara contar con internet (70,3 % al expandir por el factor muestral) y que esa cifra promedio esconde brechas de magnitud considerable: **40,8 puntos porcentuales** entre el área urbana y la rural, **52,9 puntos** entre el nivel educativo más bajo y el más alto del jefe/a, **69,5 puntos** entre el decil de ingreso más pobre y el más rico, **48,1 puntos** entre el departamento mejor y el peor conectado y **46 puntos** entre categorías ocupacionales extremas. Todas apuntan en la misma dirección y se refuerzan entre sí: un hogar rural, de bajo ingreso, con jefatura mayor, sin empleo formal y con educación básica incompleta acumula todas las desventajas a la vez.

6.2 Respuesta parcial a la pregunta de investigación

La pregunta planteada en 1.2 tiene dos partes. Sobre la primera —si el acceso varía según área, ingreso y educación— el análisis descriptivo permite responder **afirmativamente y con evidencia**: la variación existe, es de gran magnitud, es sistemática y, en el caso de la educación y del ingreso, estrictamente monótona. La Figura 9 aporta además un matiz que va más allá de la descripción simple: los factores no son redundantes, ya que el gradiente educativo se sostiene dentro de cada área y la desventaja rural se sostiene dentro de cada nivel educativo.

Sobre la segunda parte —si es posible predecir la condición de conectividad— esta fase ofrece un indicio favorable pero no una respuesta. Las correlaciones moderadas con ingreso ($\rho = 0{,}46$) y educación ($\rho = 0{,}42$) indican que hay señal aprovechable, pero su magnitud también anticipa que ninguna variable aislada bastará y que el modelo deberá superar una línea base ya exigente del 62,1 %. La respuesta definitiva corresponde a la Fase 3.

Es necesario subrayar una limitación de interpretación: **todo lo afirmado es asociación, no causalidad**. Los datos no permiten sostener que el ingreso o la educación *causen* el acceso a internet; es igualmente plausible que operen factores no observados —la disponibilidad de infraestructura de telecomunicaciones en la zona, por ejemplo, que no figura en el conjunto de datos— que expliquen simultáneamente parte de ambos fenómenos.

6.3 Limitaciones detectadas en los datos

- **Corte transversal único.** No permite observar evolución temporal ni establecer secuencia causal; también impide construir una serie temporal genuina.
- **Ausencia de variables de oferta.** El conjunto describe exhaustivamente al hogar (la demanda) pero no contiene ninguna variable sobre disponibilidad de infraestructura, cobertura de red o precio del servicio en la zona. Es probablemente la omisión más relevante: un hogar puede carecer de internet porque no puede pagarlo o porque simplemente no hay servicio disponible, y los datos no distinguen ambos casos.
- **Ingreso como variable derivada.** `IPCM` es calculado por el INE a partir de múltiples fuentes de ingreso declaradas; hereda los supuestos metodológicos de ese cálculo y la subdeclaración habitual en encuestas de hogares.
- **Estimaciones sin ponderar.** Como cuantifica la Tabla 20, las cifras muestrales subestiman la conectividad nacional en 8,2 puntos porcentuales por la sobre-representación del área rural.
- **Precisión desigual por departamento.** Seis departamentos aportan menos del 4,5 % de los casos cada uno, por lo que sus tasas tienen mayor incertidumbre y las comparaciones departamentales deben tomarse como indicativas.
- **Cobertura de la encuesta.** Quedan fuera Boquerón y Alto Paraguay, las comunidades indígenas y las viviendas colectivas, poblaciones en las que cabría esperar niveles de conectividad diferentes.
- **Variable objetivo autodeclarada.** La tenencia de internet es declarada por el informante del hogar, sin verificación técnica, y no se registra la calidad ni la estabilidad de la conexión: "tener internet" agrupa situaciones heterogéneas.
- **El jefe/a como representante del hogar.** Usar su educación, edad y ocupación como atributos del hogar es una simplificación: en un hogar puede haber miembros con mayor nivel educativo que quien fue declarado jefe/a.

6.4 Hipótesis que se llevan a la Fase 2

Se trasladan las cinco hipótesis formuladas en 5.3: **H1** (diferencia de proporciones entre área urbana y rural), **H2** (asociación entre nivel educativo del jefe/a y acceso a internet), **H3** (diferencia de ingreso per cápita entre hogares con y sin conexión), **H4** (correlación entre años de estudio del jefe/a e ingreso del hogar, como vía para discutir la confusión entre ambos factores) y **H5** (diferencia de tamaño del hogar según conectividad, como caso testigo de significancia sin relevancia práctica). El conjunto cubre tres familias distintas de pruebas —asociación entre categóricas, comparación de distribuciones entre dos grupos independientes y significancia de una correlación— y contempla la estimación por bootstrap exigida por la consigna.

7. Declaración de uso de asistentes de inteligencia artificial

Conforme al apartado de integridad académica de la consigna, se declara el uso de asistentes de inteligencia artificial (Claude y Gemini) como herramienta de apoyo en las siguientes tareas:

- Exploración del diccionario oficial de variables de la EPHC para localizar los campos pertinentes entre las más de mil entradas documentadas.
- Depuración de errores en el código de limpieza, unión de tablas y visualización, y consulta de sintaxis de las librerías utilizadas.
- Comentarios explicativos del código y sugerencias sobre la organización del informe conforme a la estructura solicitada, así como mejoras de redacción.

Las decisiones metodológicas del trabajo —elección de la variable objetivo, criterios de limpieza y conservación de atípicos, puntos de corte de la categorización educativa, selección de variables, formulación de las hipótesis e interpretación de los resultados— fueron discutidas y adoptadas por el grupo. Todo el código y todo el texto incorporados fueron revisados y comprendidos por ambos integrantes antes de la entrega.

8. Reproducibilidad y entregables

N.º	Entregable	Estado
1	Documento de comprensión del problema	Sección 1 de este informe, entregada también como PDF independiente
2	Informe de la Fase 1	Este documento
3	Notebook ejecutado y exportación HTML	`Fase1_AccesoInternet.ipynb` y su exportación
4	Diccionario de datos (original y final)	Tablas 2 y 12
5	Dataset limpio	`dataset_limpio_internet_hogares.csv` (17.092 × 21)
6	Repositorio Git	Estructura `/data`, `/notebooks`, `/src`, `/output`, con README de reproducción y archivo de dependencias

Tabla 21. Entregables de la Fase 1.

Condiciones de reproducción: Python 3.10 o superior con pandas, numpy, matplotlib, seaborn y scipy. El notebook detecta automáticamente la raíz del repositorio, usa rutas relativas, crea la carpeta de salida si no existe y fija la semilla aleatoria (42) en la única operación estocástica del análisis, el muestreo del diagrama de dispersión de la Figura 4. Se ejecuta de principio a fin sobre los archivos CSV originales y regenera el dataset final sin intervención manual. Los datos originales no se incluyen en el comprimido de entrega por superar los 25 MB; la fuente se documenta en la sección 2.7.

9. Referencias

- Instituto Nacional de Estadística (INE), Paraguay. *Encuesta Permanente de Hogares Continua (EPHC) — base anual 2025*. Microdatos y diccionario de variables. https://www.ine.gov.py/microdatos/
- Instituto Nacional de Estadística (INE), Paraguay. *Catálogo ANDA — documentación técnica de la EPHC*. https://anda.ine.gov.py
- McKinney, W. *Python for Data Analysis*, 3.ª edición. O'Reilly.
- Tukey, J. W. *Exploratory Data Analysis*. Addison-Wesley.
- Documentación oficial de pandas, matplotlib, seaborn y scipy.stats.