UNIVERSIDAD NACIONAL DE ASUNCION — FACULTAD POLITECNICA
Carrera: Ingeniería Informática | Materia: Data Science

PROYECTO INTEGRADOR DE CIENCIA DE DATOS

Fase 2 — Análisis inferencial

Acceso a Internet en los hogares paraguayos
Encuesta Permanente de Hogares Continua (EPHC) 2025

Formulación y contraste de hipótesis · Verificación de supuestos · Tamaños de efecto · Bootstrap · Corrección por comparaciones múltiples

Integrantes y legajos	Joel Maria Mendieta Candia Gustavo Fabian Carballo Rojas
Fase	Fase 2 de 3 (ponderación: 25 % del proyecto integrador)
Fecha	Octubre de 2026

Índice

1. Correcciones aplicadas a la Fase 1 4

2. Objetivo, datos y decisiones fijadas de antemano 4

2.1 Objetivo de la fase 4

2.2 Datos utilizados 4

2.3 Decisiones metodológicas declaradas antes del análisis 4

3. Formulación de las hipótesis 5

4. Selección y justificación de las pruebas 5

5. Verificación de supuestos 6

Normalidad y homogeneidad de varianzas 6

Otros supuestos 6

6. Resultados de los contrastes 6

6.1 H1 – Área de residencia e Internet 7

6.2 H2 – Nivel educativo del jefe/a e Internet 7

6.3 H3 – Ingreso per cápita e Internet 8

6.4 H4 – Años de estudio e ingreso 9

6.5 H5 – Tamaño del hogar e Internet 9

7. Intervalos bootstrap y comparación con el método clásico 10

8. Corrección por comparaciones múltiples 10

9. Tabla resumen de los contrastes 11

10. Posible variable de confusión y significancia frente a relevancia 11

11. Conclusión de la Fase 2 12

11.1 Hipótesis sostenidas y no sostenidas 12

11.2 Implicaciones para la pregunta de investigación 12

11.3 Limitaciones de la inferencia 12

11.4 Variables que pasan al modelo predictivo de la Fase 3 12

12. Declaración de uso de asistentes de inteligencia artificial 13

13. Reproducibilidad y archivos entregados 13

Resumen. Se contrastaron cinco hipótesis (α = 0,05; corrección de Bonferroni sobre la familia de cinco pruebas) con 17.092 hogares de la EPHC 2025. Las cinco hipótesis nulas se rechazan y la decisión se mantiene tras la corrección. Cuatro de los cinco efectos son de magnitud mediana (V = 0,416, 0,403; r = 0,460; ρ = 0,451); el quinto (tamaño del hogar, r = 0,038) es estadísticamente significativo pero prácticamente irrelevante. Los resultados describen asociaciones, no causalidad, y no incorporan el diseño muestral complejo de la encuesta.

1. Correcciones aplicadas a la Fase 1

La consigna exige listar al inicio del informe los cambios realizados a partir de la devolución docente de la Fase 1. **El grupo no dispone de una devolución docente concreta de la Fase 1 al momento de elaborar este informe**, por lo que no se enumeran correcciones: no se inventan observaciones que no fueron recibidas.

Lo que sí se mantiene de la Fase 1 y sirve de base a esta fase es lo siguiente:

Elemento heredado de la Fase 1	Uso en la Fase 2
Dataset limpio *dataset_limpio_internet_hogares.csv* (17.092 hogares, 21 variables)	Única fuente de datos; se carga sin modificaciones adicionales.
Variable objetivo *TIENE_INTERNET* (1 = el hogar accede a Internet)	Variable de respuesta de H1, H2, H3 y H5.
Cinco hipótesis preliminares derivadas del análisis exploratorio	Formalizadas como H1-H5 en la sección 3.
Limitación declarada: cobertura y precisión desiguales por dominios; diseño muestral complejo	Se conserva como limitación de la inferencia (secciones 5 y 10).

Si el docente entrega observaciones sobre la Fase 1, esta sección es el lugar donde se listan los cambios aplicados.

2. Objetivo, datos y decisiones fijadas de antemano

2.1 Objetivo de la fase

Contrastar formalmente las cinco hipótesis preliminares de la Fase 1 para determinar si los patrones observados en la muestra son compatibles con el azar o si existe evidencia suficiente para sostener que existen más allá de esta muestra, distinguiendo en cada caso la **significancia estadística** de la **relevancia práctica**. Esta fase responde al objetivo específico inferencial del proyecto y entrega la evidencia que seleccionará las variables del modelo predictivo de la Fase 3.

2.2 Datos utilizados

Se trabaja con 17.092 hogares de la EPHC 2025 (unidad de análisis: el hogar). De ellos, 10.618 (62,1 %) declaran acceso a Internet y 6.474 (37,9 %) no. Las variables intervinientes y su completitud se resumen a continuación.

Variable	Descripción	Tipo	Faltantes	Usada en
AREA_DESC	Área de residencia (Urbana / Rural)	Categórica binaria	0	H1
TIENE_INTERNET	Acceso a Internet del hogar (1 = sí; 0 = no)	Binaria (objetivo)	0	H1, H2, H3, H5
NIVEL_EDUC_JEFE	Nivel educativo del jefe/a (4 niveles ordenados)	Categórica ordinal	2	H2
ANIOS_ESTUDIO_JEFE	Años de estudio del jefe/a	Numérica discreta (0-18)	2	H4
IPCM	Ingreso per cápita mensual del hogar (Gs.)	Numérica continua	0	H3, H4
TOTAL	Personas en el hogar	Numérica discreta	0	H5
FACTOR	Factor de expansión muestral	Numérica	0	No utilizado como peso

Los dos registros con nivel educativo y años de estudio faltantes se excluyen únicamente de los contrastes que usan esas variables (H2: n = 17.090; H4: n = 17.090); el resto de los contrastes utiliza los 17.092 hogares.

2.3 Decisiones metodológicas declaradas antes del análisis

Decisión	Valor
Nivel de significancia	α = 0,05 para cada contraste (bilateral)

Decisión	Valor
Corrección por comparaciones múltiples	Bonferroni sobre la familia de 5 contrastes: p ajustado = min(5·p; 1)
Cantidad de contrastes de hipótesis realizados	5 (H1-H5). No se ejecutaron contrastes adicionales. Además se aplicaron 4 pruebas diagnósticas de supuestos (2 Shapiro-Wilk y 2 Levene) que no son contrastes de la pregunta de investigación.
Remuestreo bootstrap	Semilla 42; B = 2.000 (H1, H2), 3.000 (H3, H5) y 1.000 (H4); IC por percentiles al 95 %
Tratamiento del diseño muestral	Pruebas estándar de scipy.stats sin ponderar ni modelar estratos/conglomerados (ver limitaciones)

3. Formulación de las hipótesis

Cada hipótesis deriva del análisis exploratorio de la Fase 1. Se enuncian en lenguaje formal y en lenguaje natural; el nivel de significancia (α = 0,05) se fijó antes de ejecutar las pruebas.

Hip.	Hipótesis nula (H_0)	Hipótesis alternativa (H_1)	En lenguaje natural
H1	$p_{urbana} = p_{rural}$	$p_{urbana} \neq p_{rural}$	La proporción de hogares con Internet es igual en el área urbana y rural, frente a la alternativa de que es distinta.
H2	Nivel educativo e Internet son independientes	Al menos una proporción por nivel educativo difiere	El nivel educativo del jefe/a no guarda relación con tener Internet, frente a la alternativa de que sí.
H3	La distribución de IPCM es igual en hogares con y sin Internet	Las distribuciones de IPCM difieren	Conectados y no conectados tienen la misma distribución de ingresos, frente a la alternativa de que difieren.
H4	$\rho = 0$	$\rho \neq 0$	Años de estudio e ingreso no tienen relación monotónica, frente a la alternativa de que sí la tienen.
H5	La distribución de TOTAL es igual en hogares con y sin Internet	Las distribuciones de TOTAL difieren	El tamaño del hogar no se relaciona con tener Internet, frente a la alternativa de que sí.

4. Selección y justificación de las pruebas

Se cubren tres familias de pruebas del repertorio de la consigna: asociación entre categóricas (chi-cuadrado), comparación de dos grupos independientes (U de Mann-Whitney) y correlación (Spearman).

Hip.	Variables	Prueba	Justificación	Tamaño del efecto
H1	Área (cat.) × Internet (cat.)	Chi-cuadrado de independencia, 2×2, sin corrección de continuidad	Dos variables categóricas; frecuencias esperadas muy altas (mín. 2.773,38). Equivale a comparar dos proporciones.	V de Cramér
H2	Nivel educativo (cat. ord.) × Internet (cat.)	Chi-cuadrado de independencia, 4×2	Tabla de contingencia; frecuencias esperadas muy altas (mín. 1.293,26). Se complementa con residuos estandarizados.	V de Cramér
H3	IPCM (num.) por grupo de Internet	U de Mann-Whitney	IPCM no es normal y presenta varianzas heterogéneas (sección 5); una prueba t no es adecuada.	$r = \|Z\|/\sqrt{N}$ y correlación biserial de rangos
H4	Años de estudio × IPCM (ambas num.)	Correlación de Spearman	Detecta asociación monotónica sin exigir normalidad bivariada; robusta a la fuerte asimetría de IPCM.	ρ de Spearman
H5	TOTAL (num. discreta) por grupo de Internet	U de Mann-Whitney	TOTAL no es normal, es discreta y presenta varianzas heterogéneas.	$r = \|Z\|/\sqrt{N}$

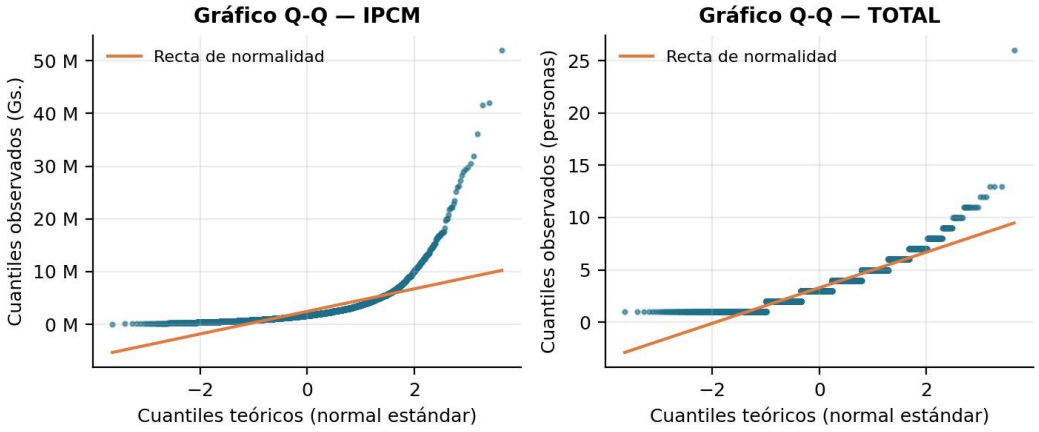
5. Verificación de supuestos

Normalidad y homogeneidad de varianzas

Para las variables numéricas comparadas entre grupos (IPCM y TOTAL) se aplicó Shapiro-Wilk sobre una submuestra aleatoria de 5.000 casos (semilla 42), para evitar la hipersensibilidad de la prueba con muestras muy grandes, junto con gráficos Q-Q. La homogeneidad de varianzas se evaluó con Levene centrado en la mediana (variante de Brown-Forsythe, robusta a la asimetría) entre hogares con y sin Internet.

Variable	Shapiro-Wilk (n = 5.000)	Levene (con vs. sin Internet)	Decisión
IPCM	$W = 0{,}5540$; $p = 1{,}06\times10^{-77}$	$F = 167{,}18$; $p = 4{,}62\times10^{-38}$	No normal y varianzas distintas → Mann-Whitney (H3)
TOTAL	$W = 0{,}8980$; $p = 1{,}52\times10^{-49}$	$F = 29{,}29$; $p = 6{,}30\times10^{-8}$	No normal y varianzas distintas → Mann-Whitney (H5)

Figura 1. Gráficos Q-Q de normalidad para IPCM y TOTAL (submuestra de 5.000 hogares).



Interpretación. *En IPCM los puntos se alejan de la recta con una cola derecha muy pesada (hogares de ingresos extremos); en TOTAL se ven escalones por ser una variable discreta y también hay cola derecha. Ninguna variable es compatible con una normal, lo que confirma el uso de pruebas no paramétricas.*

Otros supuestos

Chi-cuadrado (H1, H2): las frecuencias esperadas mínimas son 2.773,38 y 1.293,26, muy superiores al umbral habitual de 5, por lo que la aproximación asintótica es válida y no se requiere la prueba exacta de Fisher. Shapiro y Levene no aplican a variables categóricas. **Spearman (H4):** exige monotonicidad e independencia, pero no normalidad bivariada; la monotonicidad se constata en la Figura 6. **Mann-Whitney (H3, H5):** como Levene detecta formas de distribución distintas entre grupos, el resultado se interpreta como diferencia entre las distribuciones (dominancia estocástica), no estrictamente como diferencia de medianas; por eso la mediana se informa como medida complementaria.

> **Independencia de las observaciones.** No admite una prueba estadística simple; depende del diseño de observación. La EPHC es una encuesta con muestreo por conglomerados y estratos (UPM), y estas pruebas no modelan ese diseño ni utilizan FACTOR como peso. Es probable que los hogares de una misma UPM sean más parecidos entre sí que dos hogares al azar, lo que tiende a **subestimar la varianza** y a hacer los valores p más pequeños y los IC más angostos de lo que corresponde. Se documenta como la principal limitación de esta fase.

6. Resultados de los contrastes

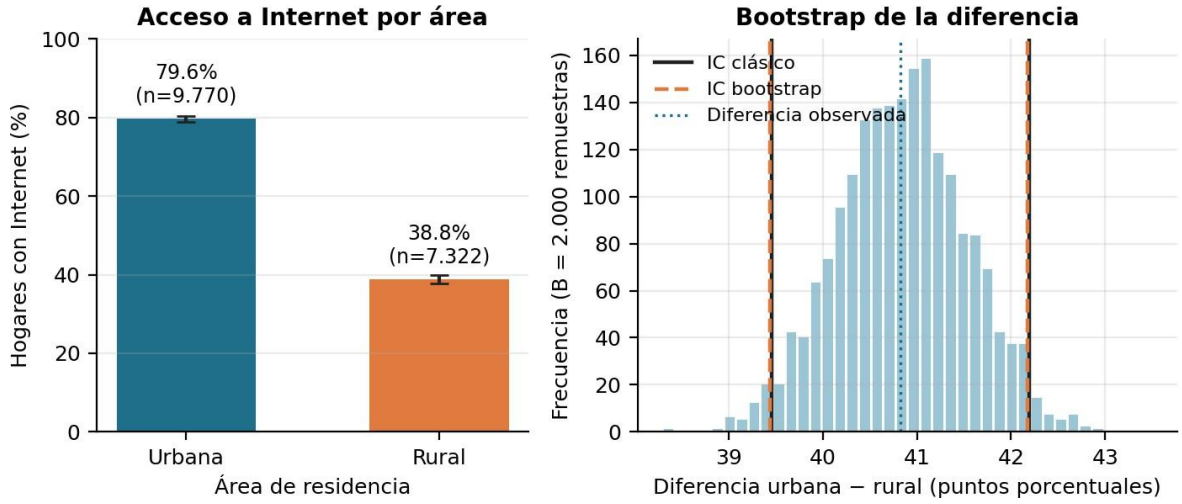
En cada contraste se informa el estadístico, los grados de libertad cuando corresponde, el valor p, el intervalo de confianza y el tamaño del efecto. Los valores p exactos son menores que 10^{-300} en H1-H4: el software los redondea a 0, de modo que se informan como p < 0,001.

6.1 H1 — Área de residencia e Internet

Área	Sin Internet	Con Internet	Total	% con Internet
Urbana	1.992	7.778	9.770	79,61 %
Rural	4.482	2.840	7.322	38,79 %
Total	6.474	10.618	17.092	62,12 %

Resultado. χ^2 = 2.964,35; gl = 1; p < 0,001; V de Cramér = 0,416. Diferencia urbana − rural = 40,82 puntos porcentuales; IC 95 % clásico [39,45 %; 42,20 %]; IC 95 % bootstrap [39,44 %; 42,18 %]. **Decisión: se rechaza H_0.**

Figura 2. Acceso a Internet según área de residencia y distribución bootstrap de la diferencia de proporciones.



Interpretación. *Casi 8 de cada 10 hogares urbanos tienen Internet frente a menos de 4 de cada 10 rurales. Los IC clásico y bootstrap prácticamente coinciden, lo que respalda la precisión de la estimación bajo los supuestos del muestreo simple.*

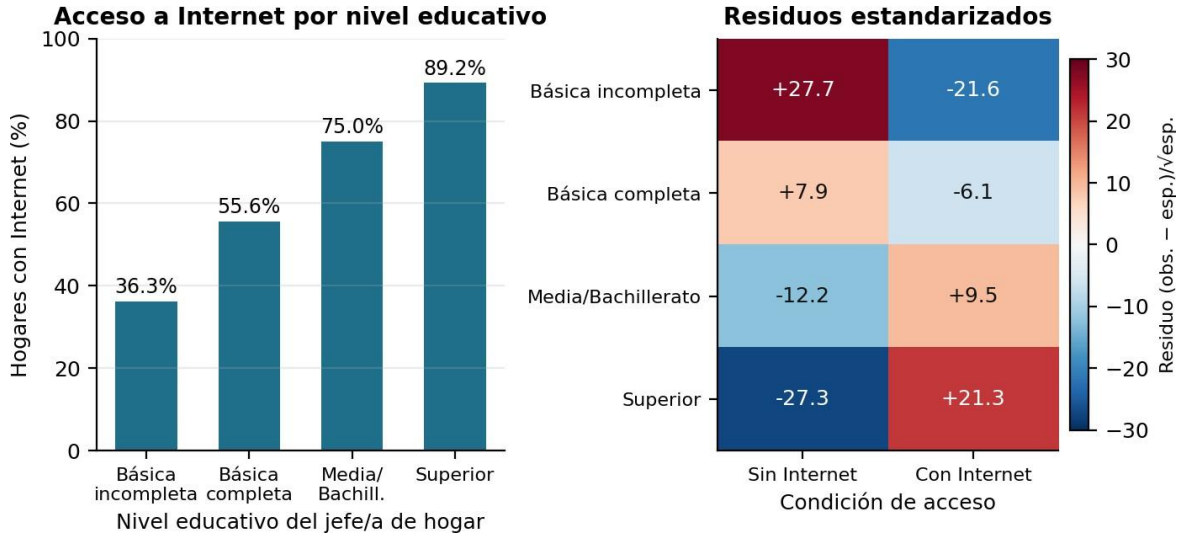
En lenguaje natural: la diferencia de conectividad entre el campo y la ciudad es muy grande y no se explica por azar de la muestra: el acceso urbano supera al rural en alrededor de 41 puntos porcentuales (entre 39 y 42 con 95 % de confianza).

6.2 H2 — Nivel educativo del jefe/a e Internet

Nivel educativo	Sin Internet	Con Internet	% con Internet	Residuo (sin)	Residuo (con)
1. Básica incompleta (0-5 años)	2.759	1.569	36,3 %	+27,7	-21,6
2. Básica completa (6-9 años)	2.446	3.063	55,6 %	+7,9	-6,1
3. Media/Bachillerato (10-12 años)	854	2.561	75,0 %	-12,2	+9,5
4. Superior (13+ años)	413	3.425	89,2 %	-27,3	+21,3

Resultado. χ^2 = 2.770,56; gl = 3; p < 0,001; V de Cramér = 0,403; IC 95 % bootstrap de V [0,390; 0,415]. **Decisión: se rechaza H_0.**

Figura 3. Acceso a Internet por nivel educativo del jefe/a y residuos estandarizados de la prueba chi-cuadrado.



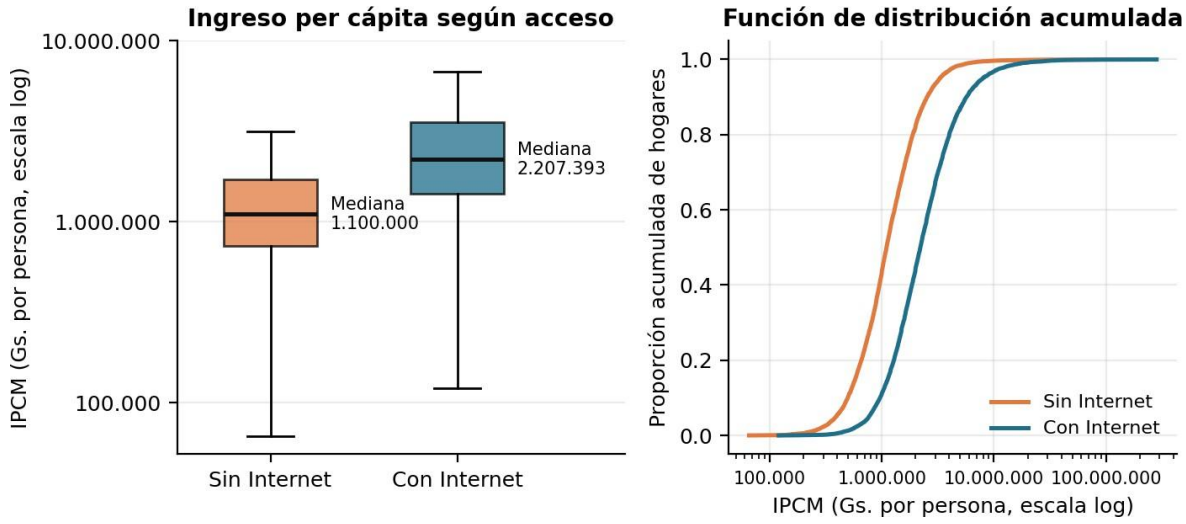
Interpretación. *El acceso crece de forma escalonada con la educación, de 36 % (básica incompleta) a 89 % (superior). Los residuos positivos fuertes en "sin Internet" para niveles bajos y en "con Internet" para niveles altos muestran dónde se concentra la asociación.*

En lenguaje natural: cuanto mayor es la educación del jefe/a del hogar, más probable es que el hogar tenga Internet; la relación es fuerte y no atribuible al azar.

6.3 H3 — Ingreso per cápita e Internet

Resultado. U = 53.178.983; Z = 60,11; p < 0,001; r = 0,460; correlación biserial de rangos = 0,547. Mediana de IPCM: 2.207.393 Gs. (con Internet) frente a 1.100.000 Gs. (sin Internet); diferencia de medianas = 1.107.393 Gs.; IC 95 % bootstrap [1.070.006; 1.146.805] Gs. Probabilidad de superioridad $U/(n_1 \cdot n_2)$ = 0,774: en 77,4 % de los pares conectado-no conectado, el hogar conectado tiene mayor ingreso. **Decisión: se rechaza H_0.**

Figura 4. Distribución del ingreso per cápita mensual (IPCM, escala logarítmica) según acceso a Internet, con diagrama de caja y distribución acumulada.



Interpretación. *La distribución de los hogares conectados está desplazada hacia ingresos mayores en todo su recorrido: la curva acumulada de los no conectados siempre queda por encima. La mediana de los conectados duplica aproximadamente a la de los no conectados.*

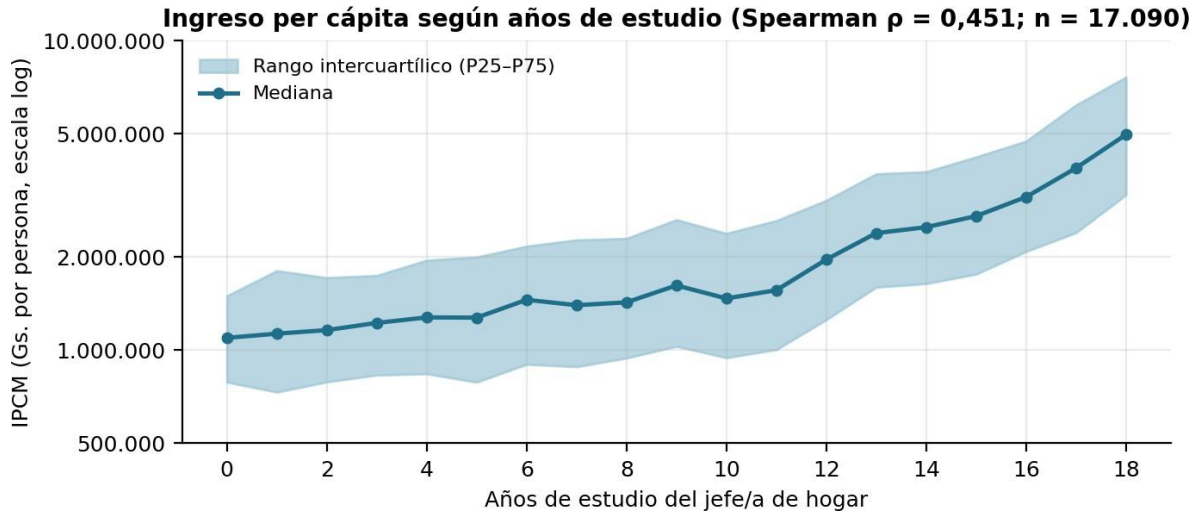
En lenguaje natural: los hogares con Internet tienen, típicamente, ingresos por persona sensiblemente mayores que los que no tienen. La diferencia es relevante en la práctica, no solo

estadística. Esto no significa que Internet cause mayores ingresos: educación, área y otros factores podrían participar.

6.4 H4 — Años de estudio e ingreso

Resultado. n = 17.090; ρ de Spearman = 0,451; p < 0,001; IC 95 % bootstrap [0,439; 0,463]. **Decisión: se rechaza H_0.**

Figura 5. Mediana y rango intercuartílico del ingreso per cápita (IPCM, escala logarítmica) según años de estudio del jefe/a.



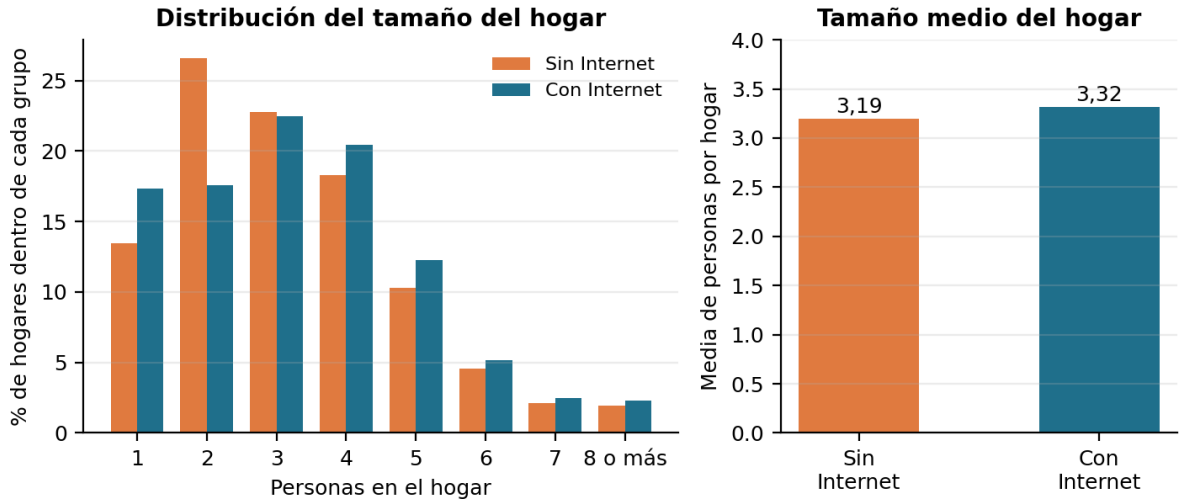
Interpretación. *La mediana de ingresos aumenta de manera sostenida con los años de estudio, con un ascenso más marcado a partir de los 12 años (educación media completa); la dispersión dentro de cada nivel es grande, coherente con una asociación moderada y no perfecta.*

En lenguaje natural: a más años de estudio del jefe/a, tiende a haber más ingreso por persona en el hogar, aunque con mucha variabilidad. Educación e ingreso están relacionados entre sí, por lo que pueden explicar de forma solapada las diferencias de conectividad.

6.5 H5 — Tamaño del hogar e Internet

Resultado. U = 35.881.248; Z = 4,912; p = $9{,}00\times10^{-7}$; r = 0,038. Media de personas: 3,320 (con Internet) y 3,194 (sin Internet); diferencia = 0,127 personas; IC 95 % bootstrap [0,071; 0,180]. Ambas medianas son 3. Probabilidad de superioridad = 0,522. **Decisión: se rechaza H_0**, pero el efecto es prácticamente nulo.

Figura 6. Distribución del tamaño del hogar (porcentaje dentro de cada grupo) y tamaño medio según acceso a Internet.



Interpretación. *Las dos distribuciones son muy parecidas y las medias difieren en apenas 0,13 personas; los hogares sin Internet tienen algo más de hogares de 2 personas y los conectados algo más de unipersonales y de 4-5 miembros. La diferencia no tiene relevancia práctica.*

En lenguaje natural: el tamaño del hogar es prácticamente igual en hogares con y sin Internet. Que la prueba sea significativa se debe al gran tamaño de la muestra, que permite detectar diferencias ínfimas; no debe interpretarse como una relación importante.

7. Intervalos bootstrap y comparación con el método clásico

Se estimaron intervalos de confianza por bootstrap de percentiles (semilla 42) para un parámetro interpretable de cada contraste. Para H1 se calculó además el intervalo clásico (de Wald) sobre el mismo parámetro, la diferencia de proporciones, de modo de compararlos directamente.

Parámetro	Estimación	IC 95 % clásico	IC 95 % bootstrap
H1: Δ proporciones urbana − rural	40,82 pp	[39,45; 42,20]	[39,44; 42,18]
H2: V de Cramér	0,403	—	[0,390; 0,415]
H3: Δ medianas de IPCM (Gs.)	1.107.393	—	[1.070.006; 1.146.805]
H4: ρ de Spearman	0,451	—	[0,439; 0,463]
H5: Δ medias de TOTAL (personas)	0,127	—	[0,071; 0,180]

En H1 los dos métodos difieren en menos de 0,02 puntos porcentuales en cada extremo, porque la muestra es grande y la distribución de la diferencia de proporciones es casi normal. En los demás contrastes el bootstrap es la única forma sencilla de acotar la incertidumbre de parámetros sin fórmula cerrada (diferencia de medianas, V de Cramér, ρ).

8. Corrección por comparaciones múltiples

Los cinco contrastes responden a un mismo conjunto de preguntas sobre los determinantes del acceso a Internet y se evalúan sobre la misma muestra. Si cada uno se realiza con $\alpha = 0{,}05$, la probabilidad de cometer al menos un falso positivo en la familia crece por encima de 5 % (con cinco pruebas independientes, $1 - 0{,}95^5 \approx 22{,}6$ %). Por eso se aplicó la corrección de Bonferroni, que ajusta cada valor p multiplicándolo por el número de pruebas (5), equivalente a exigir $p < 0{,}01$ en cada contraste. El método se fijó antes de interpretar los resultados.

Hipótesis	Prueba	p original	p ajustado (Bonferroni)	Decisión (α = 0,05)
H1 Área ↔ Internet	Chi-cuadrado	$< 10^{-300}$	$< 10^{-300}$	Rechazar H_0
H2 Educación ↔ Internet	Chi-cuadrado	$< 10^{-300}$	$< 10^{-300}$	Rechazar H_0
H3 Ingreso ↔ Internet	Mann-Whitney	$< 10^{-300}$	$< 10^{-300}$	Rechazar H_0
H4 Educación ↔ Ingreso	Spearman	$< 10^{-300}$	$< 10^{-300}$	Rechazar H_0
H5 Tamaño hogar ↔ Internet	Mann-Whitney	9.00×10^{-7}	4.50×10^{-6}	Rechazar H_0

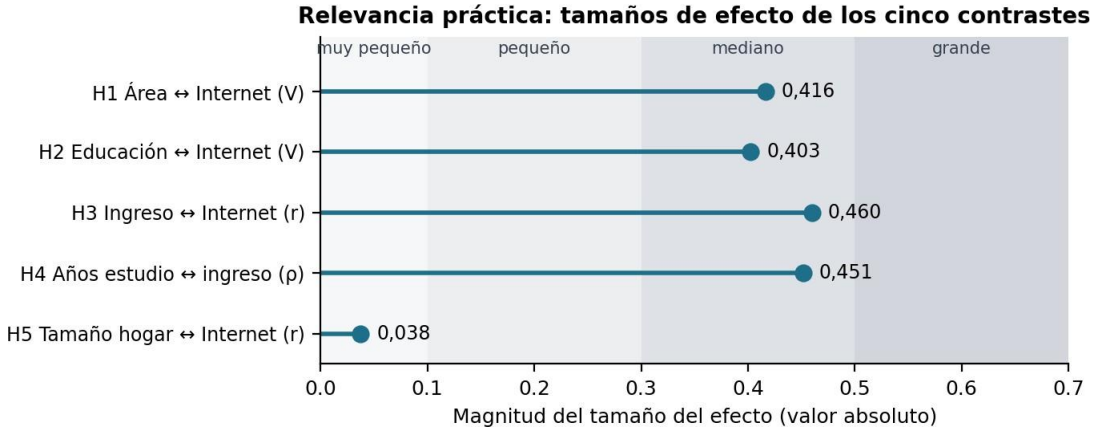
Los valores p de H1–H4 son menores que el mínimo representable en punto flotante, por lo que la corrección no altera su decisión. El único valor p afectado en términos numéricos es el de H5, que pasa de $9{,}00\times10^{-7}$ a $4{,}50\times10^{-6}$ y sigue siendo significativo.

9. Tabla resumen de los contrastes

Hip.	Prueba / supuestos verificados	Estadístico	p (ajustado)	IC 95 %	Tamaño del efecto	Decisión
H1	Chi-cuadrado. Indep.; esperadas ≥ 2.773	χ^2 = 2.964,35; gl = 1	< 0,001	Δ clásico [39,45; 42,20] pp; bootstrap [39,44; 42,18] pp	V = 0,416 (mediano-alto)	Rechazar H_0
H2	Chi-cuadrado. Indep.; esperadas ≥ 1.293	χ^2 = 2.770,56; gl = 3	< 0,001	V bootstrap [0,390; 0,415]	V = 0,403 (mediano-alto)	Rechazar H_0
H3	Mann-Whitney. No normal (Shapiro); Levene heterogéneo; indep.	U = 53.178.983; Z = 60,107	< 0,001	Δ medianas bootstrap [1.070.006; 1.146.805] Gs.	r = 0,460; r_b = 0,547 (mediano-alto)	Rechazar H_0
H4	Spearman. Monotonicidad; indep.	ρ = 0,451; n = 17.090	< 0,001	ρ bootstrap [0,439; 0,463]	ρ = 0,451 (moderado)	Rechazar H_0
H5	Mann-Whitney. No normal; Levene heterogéneo; indep.	U = 35.881.248; Z = 4,912	$4{,}50\times10^{-6}$	Δ medias bootstrap [0,071; 0,180] pers.	r = 0,038 (insignificante)	Rechazar H_0 (irrelevante en la práctica)

Referencias de magnitud (Cohen): efecto pequeño ≈ 0,1; mediano ≈ 0,3; grande ≈ 0,5 para V, r y ρ. Valores p ajustados por Bonferroni (×5).

Figura 7. Tamaños de efecto de los cinco contrastes frente a las referencias de magnitud.



Interpretación. *Cuatro contrastes están en la zona mediana, cerca del límite de efecto grande, mientras que H5 queda en la zona insignificante pese a ser significativo. Este gráfico resume por qué no basta con informar el valor p.*

10. Posible variable de confusión y significancia frente a relevancia

Confusión. El área de residencia (*AREA_DESC*) es un posible confusor de la relación entre educación e Internet: Educación ← Área → Internet. El área puede estar relacionada con el nivel educativo y está claramente relacionada con la conectividad (H1). Se plantea como una posibilidad metodológica, **no como un confusor demostrado**: todos los contrastes son bivariados y no controlan simultáneamente área, educación e ingreso. Además, H4 muestra que educación e ingreso están asociados, de modo que los efectos observados en H2 y H3 no deben leerse como independientes entre sí.

Significancia frente a relevancia. Con n = 17.092, casi cualquier diferencia resulta significativa. H5 lo ilustra: $p = 9{,}00\times10^{-7}$ con una diferencia de 0,13 personas y medianas iguales (3). Los demás contrastes, en cambio, combinan significancia con tamaños de efecto medianos, de modo que sí son relevantes en la práctica.

11. Conclusión de la Fase 2

11.1 Hipótesis sostenidas y no sostenidas

Las cinco hipótesis nulas se rechazan y mantienen esa decisión tras la corrección de Bonferroni; es decir, hay evidencia estadística suficiente de que las cinco asociaciones existen en la población de la que proviene la muestra, bajo los supuestos declarados. No hay hipótesis que quedaran sin evidencia para rechazarse. Rechazar H_0 no demuestra la hipótesis alternativa más allá de lo que mide cada prueba, ni implica causalidad.

11.2 Implicaciones para la pregunta de investigación

Hip.	Implicación
H1	Existe una brecha territorial de conectividad muy grande (≈ 41 pp) entre hogares urbanos y rurales.
H2	Educación y conectividad están asociadas de forma importante y graduada (36 % → 89 %).
H3	Los hogares conectados tienen ingresos per cápita claramente mayores; el efecto es relevante en la práctica.
H4	Educación e ingreso están moderadamente asociadas, por lo que aportan información parcialmente solapada para explicar la conectividad.
H5	El tamaño del hogar tiene un efecto prácticamente nulo; es una variable secundaria.

11.3 Limitaciones de la inferencia

- **Diseño muestral complejo:** no se modelaron estratos, conglomerados ni FACTOR; los valores p tienden a ser demasiado optimistas y los IC demasiado angostos, y las cifras no ponderadas no deben presentarse como estimaciones nacionales definitivas.
- **Tamaño muestral:** con 17.092 hogares se detectan diferencias muy pequeñas; la lectura debe apoyarse en el tamaño del efecto.
- **Representatividad:** la Fase 1 documentó cobertura y precisión desiguales por dominios geográficos.
- **Temporalidad:** corte anual transversal; no hay dependencia temporal que modelar ni secuencia que permita hablar de causalidad.
- **Contrastes bivariados:** pueden estar afectados por confusión entre área, educación e ingreso.

11.4 Variables que pasan al modelo predictivo de la Fase 3

La evidencia de esta fase, para predecir *TIENE_INTERNET*, da prioridad a: (1) **AREA_DESC**; (2) **NIVEL_EDUC_JEFE** y/o **ANIOS_ESTUDIO_JEFE** (se recomienda no incluirlas juntas sin evaluar su redundancia); (3) **IPCM**. **TOTAL** queda como candidata secundaria por su efecto pequeño. Dado que H3 arroja una probabilidad de superioridad de 0,77 usando solo el ingreso, es esperable que el modelo supere con holgura una línea base trivial. La Fase 3 deberá validar estas variables con partición entrenamiento/prueba, línea base, varios modelos, validación cruzada, métricas completas y análisis de errores.

12. Declaración de uso de asistentes de inteligencia artificial

De acuerdo con la sección 11 de la consigna, se declara que se empleó un asistente de IA (Claude, de Anthropic) como herramienta de apoyo para la redacción y maquetación de este informe a partir de los resultados del notebook ejecutado, para la verificación de que las cifras del informe coinciden con las salidas del notebook y para la regeneración de las figuras. Las decisiones metodológicas (hipótesis, α, selección de pruebas, corrección de Bonferroni, bootstrap) provienen del notebook del grupo. El grupo revisó y comprende el contenido, y es responsable de él.

13. Reproducibilidad y archivos entregados

Archivo	Contenido
Fase2_AccesoInternet_EJECUTADO.ipynb	Notebook ejecutado de principio a fin, sin errores; fuente de todas las cifras de este informe.
Fase2_AccesoInternet_FINAL.html	Exportación HTML del notebook.
dataset_limpio_internet_hogares.csv	Dataset limpio de la Fase 1 (entrada del notebook; ruta relativa).
resultados_inferenciales_FINAL.csv	Tabla resumen de contrastes en formato reproducible.

Entorno: Python 3, pandas, numpy, scipy, matplotlib. Semilla aleatoria 42 en todos los remuestreos y submuestreos; ejecución completa sin intervención manual.