UNIVERSIDAD NACIONAL DE ASUNCIÓN — FACULTAD POLITÉCNICA
Carrera: Ingeniería Informática | Materia: Data Science

INFORME DE MODELADO PREDICTIVO

Clasificación binaria y evaluación

Factores asociados al acceso a internet en los hogares paraguayos y predicción de la disponibilidad de conexión

Fuente: Instituto Nacional de Estadística (INE), Paraguay. Encuesta Permanente de Hogares Continua (EPHC), base anual 2025. Portal de microdatos: https://www.ine.gov.py/microdatos/ (carpeta EPHC_2025_ANUAL).
Unidad de análisis: hogar

Integrantes y legajos:
Gustavo Fabián Carballo Rojas
Joel María Mendieta Candia

FASE 3 | 10 de noviembre de 2026

Índice

Resumen ejecutivo y objetivo ····· 3
Correcciones y ajustes respecto de la Fase 2 ····· 3
Datos y preparación ····· 3–4
Diseño experimental y modelos ····· 4
Resultados, línea base y brecha entre particiones ····· 4
Análisis de errores ····· 5–6
Importancia e interpretación ····· 7
Limitaciones, ética y conclusión ····· 7–8
Reproducibilidad y uso de IA ····· 8

Resumen ejecutivo

Se desarrolló un clasificador binario para estimar si un hogar dispone de conexión a internet (TIENE_INTERNET = 1) a partir de ocho variables geográficas, demográficas y socioeconómicas. El conjunto contiene 17.092 hogares. Se compararon regresión logística, Random Forest e HistGradientBoosting, con validación cruzada estratificada y ajuste de hiperparámetros sobre entrenamiento. La línea base fue un clasificador de clase mayoritaria.

HistGradientBoosting fue seleccionado por F1 en validación. En prueba obtuvo accuracy = 0,8023, precision = 0,8238, recall = 0,8672, F1 = 0,8450 y AUC-ROC = 0,8695. Frente a la línea base, el F1 aumentó 0,0786 puntos y el AUC-ROC 0,3695 puntos. La brecha de F1 entre entrenamiento y prueba fue pequeña (0,0062), sin señal de sobreajuste pronunciado en esta partición aleatoria.

Alcance: son métricas internas, no ponderadas y calculadas sobre una partición de la EPHC Anual 2025. No deben interpretarse como precisión garantizada para toda la población paraguaya ni como evidencia causal.

1. Objetivo y definición de la tarea

Pregunta rectora aprobada en la Fase 1: ¿En qué medida el acceso a internet de los hogares paraguayos relevados por la EPHC Anual 2025 varía según el área de residencia, el nivel de ingreso per cápita y el nivel educativo del jefe/a de hogar, y es posible predecir si un hogar cuenta con conexión a partir de esas características?

La pregunta operativa de modelado es: ¿con qué desempeño pueden clasificarse los hogares con y sin conexión a internet usando sus características territoriales, demográficas y socioeconómicas registradas en la EPHC Anual 2025?

2. Devolución docente sobre la Fase 2 y ajustes de modelado

Devolución docente sobre la Fase 2: según lo informado por el grupo, la profesora confirmó que el análisis estaba correcto y que podían continuar con el mismo enfoque. No solicitó correcciones ni cambios adicionales. Por lo tanto, no se atribuyen correcciones inexistentes a la devolución; las decisiones siguientes son ajustes de preparación del modelo, fundamentados en los hallazgos y limitaciones ya documentados en la Fase 2.
Continuidad metodológica y ajustes para el modelado: (1) se priorizaron AREA_DESC e IPCM por sus asociaciones de magnitud relevante con el acceso; (2) se utilizó ANIOS_ESTUDIO_JEFE como representación numérica de la educación, sin incorporar simultáneamente NIVEL_EDUC_JEFE para evitar duplicación de información; (3) TOTAL se mantuvo como predictor secundario, aunque su efecto bivariado en Fase 2 fue muy pequeño (r = 0,038); (4) se conservaron las limitaciones sobre diseño muestral, análisis no causal y cobertura. No se modificaron retroactivamente los resultados inferenciales.

Ajuste incorporado	Cómo se refleja en esta fase
Multiplicidad y lectura de evidencia	Se conserva la corrección Bonferroni para cinco contrastes (α ajustado = 0,01) y se distinguen significancia estadística y magnitud práctica.
Interpretación de Mann–Whitney	Se evita presentar la U como una prueba exclusiva de medianas: se describe la comparación de distribuciones/rangos y se acompañan los resultados con medianas y tamaño del efecto.
Tamaño del hogar	La asociación de Fase 2 fue estadísticamente significativa, pero el efecto fue muy pequeño (r ≈ 0,038); no se presenta como un determinante sustantivo por sí solo.
IPCM extremo	Se conservaron cinco valores superiores a Gs. 100 millones en la ejecución principal, pendientes de verificación documental. Se usa log1p(IPCM); la sensibilidad inferencial previa sin esos cinco casos cambió muy poco los tamaños de efecto.
Variables y fuga de información	Se excluyen identificadores, deciles/quintiles redundantes, variables posteriores o condicionadas al resultado y FACTOR del conjunto de predictores.
Diseño muestral	Se declara que no se incorporaron conjuntamente ponderadores, estratos y conglomerados; las métricas son no ponderadas.

3. Datos y preparación

El archivo dataset_limpio_internet_hogares.csv tiene 17.092 filas y 21 columnas. La etiqueta está completa: 10.618 hogares (62,1 %) tienen internet y 6.474 (37,9 %) no tienen. Cada registro representa un hogar. Fuente de datos: Instituto Nacional de Estadística (INE), Paraguay. Encuesta Permanente de Hogares Continua (EPHC), base anual 2025. Portal de microdatos: https://www.ine.gov.py/microdatos/; dentro del portal, seleccionar la carpeta EPHC_2025_ANUAL. Según la documentación de Fase 1, la base anual 2025 fue provista por la cátedra y la fecha de obtención registrada fue septiembre de 2026. El informe de Fase 1 declara que se trata de microdatos públicos y anonimizados de estadística oficial, bajo la Licencia de Uso de la Información Pública del Gobierno Paraguayo, con uso exclusivamente académico y análisis agregado. Archivos de referencia: REG01_EPHC_ANUAL_2025.csv,

REG02_EPHC_ANUAL_2025.csv, INGREFAM_EPHC_ANUAL_2025.csv y diccionario_EPHC_ANUAL_2025.xls. El modelado de esta fase utiliza el archivo derivado dataset_limpio_internet_hogares.csv (17.092 hogares × 21 variables).

Variable	Tipo	Uso
AREA_DESC	Categórica	Área urbana o rural
DPTO_NOMBRE	Categórica	Departamento
TOTAL	Numérica	Integrantes del hogar
EDAD_JEFE	Numérica	Edad del jefe/a
SEXO_JEFE_DESC	Categórica	Sexo del jefe/a
ANIOS_ESTUDIO_JEFE	Numérica	Años de estudio del jefe/a
CAT_OCUP_JEFE_DESC	Categórica	Categoría ocupacional del jefe/a
IPCM	Numérica	Ingreso per cápita mensual del hogar

Se excluyeron UPM, NVIVI y NHOGA por ser identificadores; V23C1 y V23C2 por describir el tipo de conexión solo entre hogares ya conectados; V23A1 por su relación directa con la construcción del objetivo; NIVEL_EDUC_JEFE por redundancia con años de estudio; DECIL_ING y QUINTIL_ING por derivarse del ingreso; y FACTOR por no incorporarse el diseño muestral complejo en este modelo.

Los faltantes de predictores se imputan dentro del pipeline: mediana para numéricas e ingreso y moda para categóricas. ANIOS_ESTUDIO_JEFE presenta dos faltantes. IPCM se transforma con log1p y luego se estandariza. Los cinco IPCM superiores a Gs. 100 millones se mantienen sin certificar su validez; el máximo ronda Gs. 282,9 millones. Esta decisión queda pendiente de contraste con la documentación y microdatos de origen.

4. Diseño experimental y modelos

La partición fue estratificada y aleatoria, con semilla 42: 10.255 observaciones para entrenamiento (60 %), 3.418 para validación (20 %) y 3.419 para prueba (20 %). No se identificó una dimensión temporal en el conjunto utilizado que exigiera partición cronológica. El conjunto de prueba no se usó para elegir variables, ajustar hiperparámetros ni seleccionar el modelo.

Elemento	Configuración
Línea base	DummyClassifier de clase mayoritaria.
Regresión logística	max_iter = 2500; class_weight = balanced; C ∈ {0,1; 1; 10}.
Random Forest	200 árboles; class_weight = balanced_subsample; búsqueda de max_depth ∈ {None,15} y min_samples_leaf ∈ {2,5}.
HistGradientBoosting	Búsqueda de learning_rate ∈ {0,05; 0,1}, max_leaf_nodes ∈ {15,31} y max_iter = 100.
Validación cruzada	StratifiedKFold de 3 pliegues en entrenamiento; GridSearchCV con F1 como función de selección.
Regla de selección	Mayor F1 en validación; AUC-ROC como desempate.

La imputación, codificación y estandarización están dentro de pipelines de scikit-learn. Así, cada transformación se ajusta únicamente con los datos de entrenamiento de cada pliegue y no observa información de validación o prueba.

5. Resultados y comparación contra la línea base

El F1 medio de validación cruzada fue 0,8407 para HistGradientBoosting, 0,8275 para Random Forest y 0,8122 para regresión logística. En validación independiente, HistGradientBoosting alcanzó F1 = 0,8382 y AUC-ROC = 0,8649, frente a F1 = 0,7663 y AUC-ROC = 0,5000 de la línea base.

Partición	Accuracy	Precision	Recall	F1	AUC-ROC
Entrenamiento	0,8106	0,8317	0,8716	0,8512	0,8867
Validación	0,7926	0,8128	0,8653	0,8382	0,8649
Prueba	0,8023	0,8238	0,8672	0,8450	0,8695

Modelo evaluado en prueba	Accuracy	Precision	Recall	F1	AUC-ROC
Hist. Gradient Boosting	0,8023	0,8238	0,8672	0,8450	0,8695
Línea base mayoritaria	0,6212	0,6212	1,0000	0,7664	0,5000

La línea base tiene recall de 1 porque clasifica todos los hogares como conectados, pero no discrimina entre clases (AUC-ROC = 0,5). El modelo seleccionado la supera en todas las métricas excepto que la línea base maximiza recall por definición. La mejora absoluta de F1 en prueba es aproximadamente 0,0786.

6. Matriz de confusión y análisis de errores

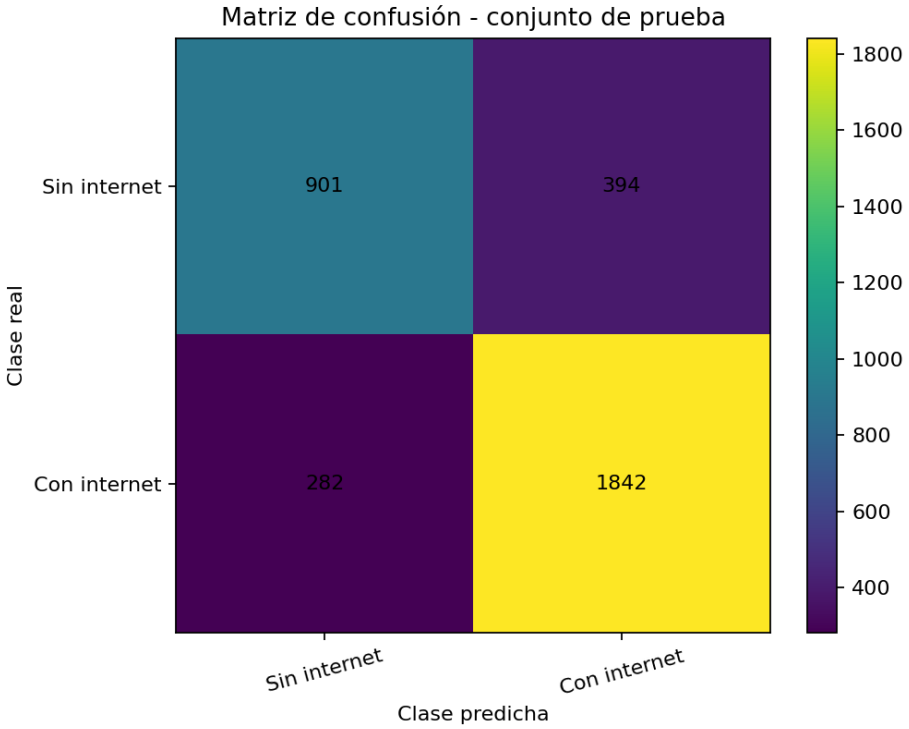


Figura 1. Matriz de confusión del conjunto de prueba (3.419 hogares).

Resultado	Casos	Interpretación
Verdaderos negativos	901	Hogares sin internet correctamente clasificados.
Falsos positivos	394	Hogares sin internet clasificados como conectados.
Falsos negativos	282	Hogares conectados clasificados como no conectados.
Verdaderos positivos	1.842	Hogares conectados correctamente clasificados.
Errores totales	676 (19,8 %)	Suma de falsos positivos y falsos negativos.

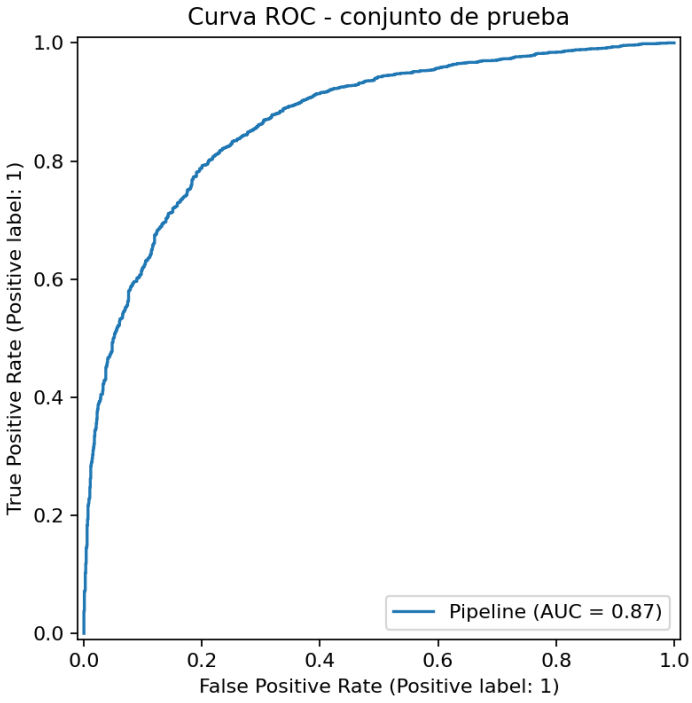


Figura 2. Curva ROC del modelo seleccionado en el conjunto de prueba.

El examen por área muestra tasas de error distintas. Entre los hogares que realmente no tenían internet, el error fue 59,7 % en el área urbana (234 de 392) y 17,7 % en el área rural (160 de 903). Entre los hogares que sí tenían internet, el error fue 39,2 % en el área rural (206 de 526) y 4,8 % en el área urbana (76 de 1.598). Estos resultados sugieren que el modelo tiene especial dificultad para identificar hogares rurales que sí están conectados; también produce falsos positivos urbanos. Es un diagnóstico de esta partición no ponderada, no una estimación poblacional.

Grupo de error	Casos	Patrón observado en el subconjunto de errores
Falsos positivos	394	234 urbanos (59,4 %); mediana de IPCM ≈ Gs. 1.827.877 y mediana de escolaridad del jefe/a = 9 años.
Falsos negativos	282	206 rurales (73,0 %); mediana de IPCM ≈ Gs. 1.000.861 y mediana de escolaridad = 6 años.

Se detectaron 36 falsos positivos con probabilidad estimada de conexión ≥ 0,90 y 14 falsos negativos con probabilidad ≤ 0,10. Al revisar esos casos de mayor confianza en forma agregada, 35 de los 36 falsos positivos correspondieron a hogares urbanos (mediana IPCM ≈ Gs. 2.508.904 y escolaridad mediana = 13 años); 13 de los 14 falsos negativos fueron rurales (mediana IPCM ≈ Gs. 453.176 y escolaridad mediana = 5,5 años; 11 tenían categoría ocupacional cuenta propia). El patrón sugiere que el modelo puede asignar una probabilidad muy baja a hogares rurales conectados con menor ingreso y escolaridad, y una probabilidad alta a hogares urbanos que en realidad no están conectados. Son diagnósticos de una muestra de prueba no ponderada, no una explicación causal ni una estimación poblacional. El archivo predicciones_errores_prueba.csv conserva el detalle técnico; el informe presenta perfiles agregados para evitar exponer registros individuales.

7. Importancia de variables y contraste con fases previas

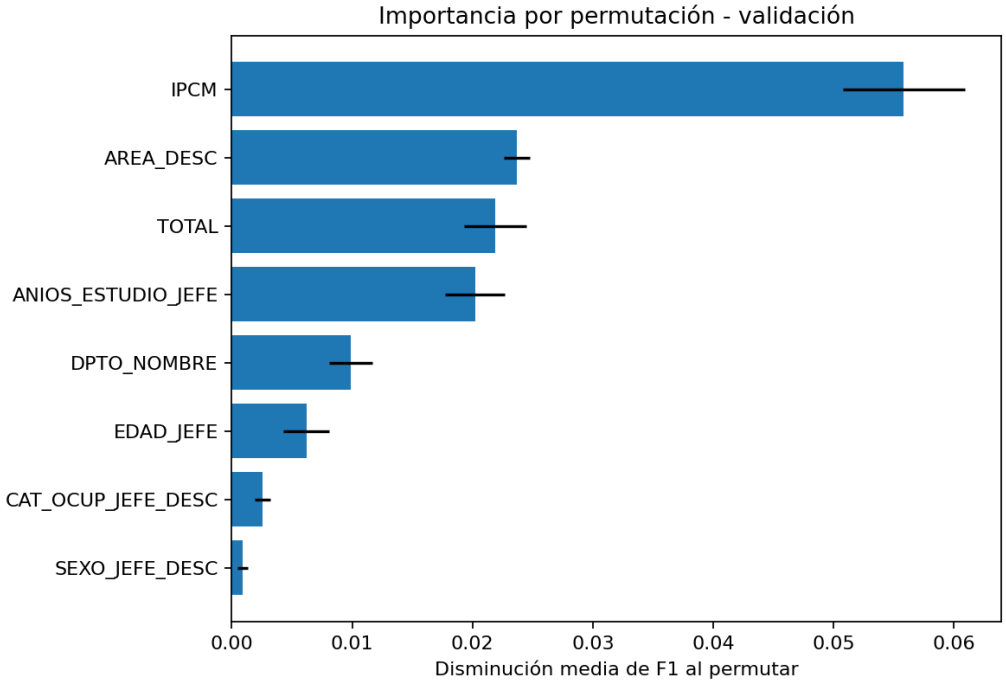


Figura 2. Disminución media de F1 al permutar cada variable en validación.

Variable	Disminución media de F1	Lectura
IPCM	0,0558	Mayor importancia predictiva.
AREA_DESC	0,0237	Segundo aporte predictivo.
TOTAL	0,0219	Aporte conjunto del tamaño del hogar.
ANIOS_ESTUDIO_JEFE	0,0202	Aporte de escolaridad.
DPTO_NOMBRE	0,0099	Información territorial adicional.
EDAD_JEFE	0,0062	Aporte menor.
CAT_OCUP_JEFE_DESC	0,0026	Aporte bajo.
SEXO_JEFE_DESC	0,0009	Aporte bajo en esta ejecución.

La importancia de IPCM y AREA_DESC coincide con los resultados descriptivos e inferenciales: el ingreso presentó una asociación relevante y el acceso observado fue marcadamente mayor en hogares urbanos que rurales. Los años de estudio también coinciden con el gradiente educativo observado y con la correlación de Spearman entre escolaridad e IPCM. TOTAL aporta información predictiva en combinación con otras variables, aunque en la Fase 2 su efecto bivariado fue muy pequeño ($r \approx 0{,}038$); importancia predictiva multivariable no equivale a un efecto causal o grande en una comparación aislada.

8. Sobreajuste, limitaciones y consideraciones éticas

El F1 fue 0,8512 en entrenamiento, 0,8382 en validación y 0,8450 en prueba. La diferencia entrenamiento-prueba es 0,0062 y entrenamiento-validación 0,0129; no se observa una brecha grande en esta partición. No obstante, al provenir los tres subconjuntos de la misma encuesta y del mismo año, esto no demuestra estabilidad en otro período, región o fuente.

- No se incorporaron ponderadores, estratos y conglomerados de la EPHC. Las métricas son no ponderadas y no deben presentarse como estimaciones nacionales representativas.
- La evaluación utiliza una sola edición anual y no cuenta con validación externa ni temporal.
- Los cinco valores extremos de IPCM y las edades de jefes/as superiores a 100 años que fueron señaladas en la revisión previa requieren contraste documental; no se certifica su validez ni se eliminan sin regla de origen.
- El umbral 0,5 se mantuvo por defecto. No fue optimizado según costos diferenciados de falsos positivos y falsos negativos.
- Las tasas de error por área muestran una posible disparidad, especialmente para hogares rurales conectados. Antes de cualquier uso práctico se requiere auditoría de equidad, calibración y evaluación ponderada.
- No usar este clasificador para negar servicios, beneficios o derechos; cualquier aplicación real requiere supervisión humana y auditoría.

9. Conclusión de la Fase 3

HistGradientBoosting superó claramente a la línea base en capacidad de discriminación y F1 y mantuvo un desempeño parecido entre entrenamiento, validación y prueba. Las variables más influyentes fueron IPCM, área, tamaño del hogar y años de estudio, en buena medida coherentes con los patrones descritos e inferidos en las fases anteriores. La evidencia predictiva consolida que la situación económica y el contexto territorial ayudan a diferenciar hogares con y sin internet, pero no permite atribuir causalidad ni afirmar qué política produciría mayor acceso.

El modelo solo sería utilizable como herramienta exploratoria interna, sujeto a verificación de datos, ponderación compatible con el diseño muestral, calibración y validación externa. La disparidad de errores por área y la ausencia de evaluación poblacional impiden recomendarlo para decisiones individuales o asignación de recursos. La respuesta consolidada a la pregunta del proyecto es que el acceso muestra patrones territoriales y socioeconómicos marcados, y que estos permiten una predicción interna razonable, aunque todavía insuficiente para desplegarse en decisiones reales.

10. Reproducibilidad y declaración de uso de IA

La ejecución se reproduce desde la carpeta fase3 instalando requirements.txt y ejecutando python src/modelado_fase3.py. Se entrega una única notebook, ejecutada de principio a fin y con sus salidas guardadas; también se exporta a HTML. El pipeline serializado se guarda en output/modelo_acceso_internet.joblib y se aplica a nuevos datos mediante src/predecir_internet.py.

Declaración de uso de asistentes de IA para revisión del grupo: se emplearon asistentes de IA como apoyo para depuración y comprobación de código, organización de la estructura documental y revisión de consistencia y redacción.