UNIVERSIDAD NACIONAL DE ASUNCIÓN — FACULTAD POLITÉCNICA
Carrera: Ingeniería Informática | Materia: Data Science

INFORME INTEGRADOR

Síntesis consolidada de las tres fases

Factores asociados al acceso a internet en los hogares paraguayos y predicción de la disponibilidad de conexión

Fuente: Instituto Nacional de Estadística (INE), Paraguay. Encuesta Permanente de Hogares Continua (EPHC), base anual 2025. Portal de microdatos: https://www.ine.gov.py/microdatos/ (carpeta EPHC_2025_ANUAL).
Unidad de análisis: hogar

Integrantes y legajos:
Gustavo Fabián Carballo Rojas
Joel María Mendieta Candia

INFORME INTEGRADOR | 10 de noviembre de 2026

Índice

Resumen ejecutivo y pregunta rectora ····· 3
Datos, unidad de análisis y alcance ····· 3
Fase 1: comprensión y análisis exploratorio ····· 3–5
Fase 2: análisis inferencial ····· 5–6
Fase 3: modelado predictivo ····· 6–8
Integración de evidencias y conclusión general ····· 8
Recomendaciones y trabajo futuro ····· 8
Limitaciones, ética y declaración de IA ····· 8
Fuentes y pendientes de edición ····· 8

Resumen ejecutivo

El proyecto estudia factores territoriales, demográficos y socioeconómicos asociados al acceso a internet en los hogares paraguayos y evalúa la posibilidad de predecir la disponibilidad de conexión con datos de la EPHC Anual 2025 del INE. La unidad de análisis es el hogar. En el conjunto limpio se analizaron 17.092 hogares: 10.618 (62,1 %) con internet y 6.474 (37,9 %) sin conexión.

Las tres fases muestran un patrón consistente: el área de residencia, la educación del jefe/a y los ingresos del hogar están vinculados de forma importante con el acceso. La brecha descriptiva entre hogares urbanos y rurales fue de 40,82 puntos porcentuales. Las pruebas inferenciales detectaron asociaciones con tamaños de efecto moderados para área, educación e ingreso; el tamaño del hogar fue estadísticamente significativo, pero con efecto práctico muy pequeño. En la fase predictiva, HistGradientBoosting alcanzó F1 = 0,845 y AUC-ROC = 0,869 en prueba, superando a la línea base. La evaluación es interna y no ponderada, por lo que no debe interpretarse como rendimiento garantizado para la población nacional.

Conclusión central: existen desigualdades territoriales y socioeconómicas claras en el acceso observado, y estas variables permiten una predicción interna razonable; sin ponderación, validación externa y auditoría de errores, el modelo no está listo para decisiones reales.

1. Pregunta rectora, objetivos y alcance

Pregunta rectora (transcripción literal de la Fase 1): ¿En qué medida el acceso a internet de los hogares paraguayos relevados por la EPHC Anual 2025 varía según el área de residencia, el nivel de ingreso per cápita y el nivel educativo del jefe/a de hogar, y es posible predecir si un hogar cuenta con conexión a partir de esas características?

Objetivo general (transcripción literal de la Fase 1): Analizar los factores socioeconómicos, educativos y geográficos asociados al acceso a internet en los hogares paraguayos, a partir de los microdatos de la EPHC Anual 2025, y evaluar en qué medida permiten predecir la disponibilidad de conexión en el hogar.

- Describir la distribución del acceso a internet y su variación por territorio, ingreso y educación.
- Contrastar asociaciones entre la disponibilidad de internet y variables socioeconómicas y demográficas mediante pruebas adecuadas y tamaños de efecto.
- Entrenar y comparar modelos de clasificación con particiones reproducibles, validación cruzada y una línea base.
- Identificar limitaciones de representatividad, calidad de datos, sesgos de error y condiciones responsables de uso.

El alcance se limita a hogares de la EPHC Anual 2025 contenidos en el CSV limpio facilitado para el proyecto. El análisis es observacional y transversal: no estima efectos causales de políticas ni predice la evolución futura de la conectividad.

2. Datos, fuente y unidad de análisis

Fuente de datos: Instituto Nacional de Estadística (INE), Paraguay. Encuesta Permanente de Hogares Continua (EPHC), base anual 2025. Portal de microdatos: https://www.ine.gov.py/microdatos/; dentro del portal, seleccionar la carpeta EPHC_2025_ANUAL. Según la documentación de Fase 1, la base anual 2025 fue provista por la cátedra y la fecha de obtención registrada fue septiembre de 2026. El informe de Fase 1 declara que se trata de microdatos públicos y anonimizados de estadística oficial, bajo la Licencia de Uso de la Información Pública del Gobierno Paraguayo, con uso exclusivamente académico y análisis agregado. Archivos originales: REG01_EPHC_ANUAL_2025.csv, REG02_EPHC_ANUAL_2025.csv, INGREFAM_EPHC_ANUAL_2025.csv y diccionario_EPHC_ANUAL_2025.xls. El modelado utiliza dataset_limpio_internet_hogares.csv (17.092 hogares × 21 variables). La unidad de análisis es el hogar; TIENE_INTERNET codifica 1 = sí y 0 = no.

Aspecto	Descripción
Unidad de análisis	Hogar.
Período	EPHC Anual 2025.
Registros	17.092 hogares.
Variable objetivo	TIENE_INTERNET (binaria).
Predictores usados en Fase 3	Área, departamento, tamaño del hogar, edad y sexo del jefe/a, años de estudio, categoría ocupacional e IPCM.
Factor de expansión	Existe FACTOR en la base, pero no se incorporó al modelado ni a los contrastes estándar documentados.
Fuente y trazabilidad	INE, EPHC Anual 2025; portal de microdatos, carpeta EPHC_2025_ANUAL. Obtención registrada: septiembre de 2026. Condiciones de uso documentadas en Fase 1: datos públicos anonimizados, uso académico y análisis agregado.

3. Fase 1 — Comprensión del problema y análisis exploratorio

La primera fase estableció el hogar como unidad de análisis y caracterizó el acceso a internet mediante resúmenes univariados y comparaciones bivariadas. De los 17.092 hogares, 62,1 % registra conexión y 37,9 % no. El informe original también muestra que la proporción alcanza 70,3 % al aplicar el factor de expansión; la diferencia evidencia que las proporciones muestrales sin ponderar no deben confundirse con estimaciones nacionales. En las fases 2 y 3 las pruebas y métricas se reportan sin modelar integralmente el diseño muestral.

3.1. Brecha territorial

Área	Acceso a internet
Urbana	79,61 %
Rural	38,79 %
Diferencia	40,82 puntos porcentuales

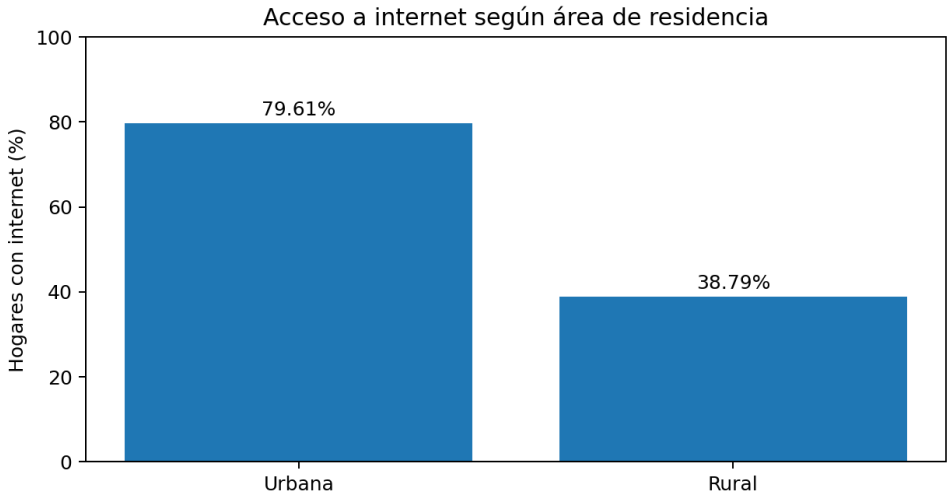


Figura 1. Porcentaje descriptivo de hogares con internet según área.

La diferencia urbano-rural es uno de los hallazgos centrales: el acceso observado es sustancialmente mayor en hogares urbanos. Esta pauta anticipa la relevancia de AREA_DESC en las pruebas de asociación y en el modelo predictivo.

3.2. Gradiente educativo

Educación del jefe/a	Acceso a internet
Básica incompleta	36,3 %
Básica completa	55,6 %
Media / bachillerato	75,0 %
Superior	89,2 %

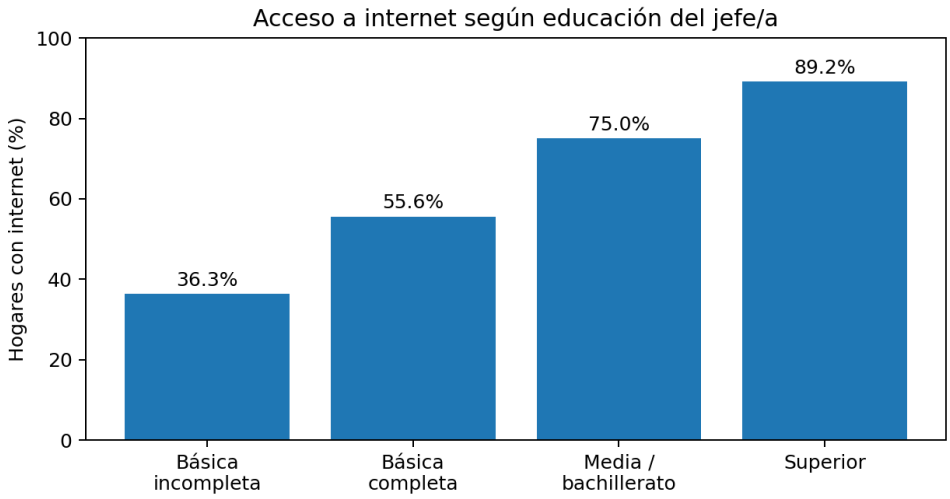


Figura 2. Acceso descriptivo por nivel educativo del jefe/a del hogar.

Se observa un gradiente creciente de acceso a medida que aumenta la educación del jefe/a. Este patrón se retomó en Fase 2 mediante la prueba chi-cuadrado y en Fase 3 mediante años de estudio del jefe/a como predictor.

3.3. Ingreso, distribución y calidad

El acceso aumenta a lo largo de la distribución de ingreso: 22,02 % en el primer decil y 91,51 % en el décimo. El IPCM presenta fuerte asimetría: media aproximada de Gs. 2.564.009, mediana de Gs. 1.697.341 y asimetría cercana a 30,85. Se observan cinco hogares con IPCM superior a Gs. 100 millones y un máximo aproximado de Gs. 282,9 millones. Esos valores requieren verificación contra la documentación y los registros originales, pero no se declararon automáticamente inválidos.

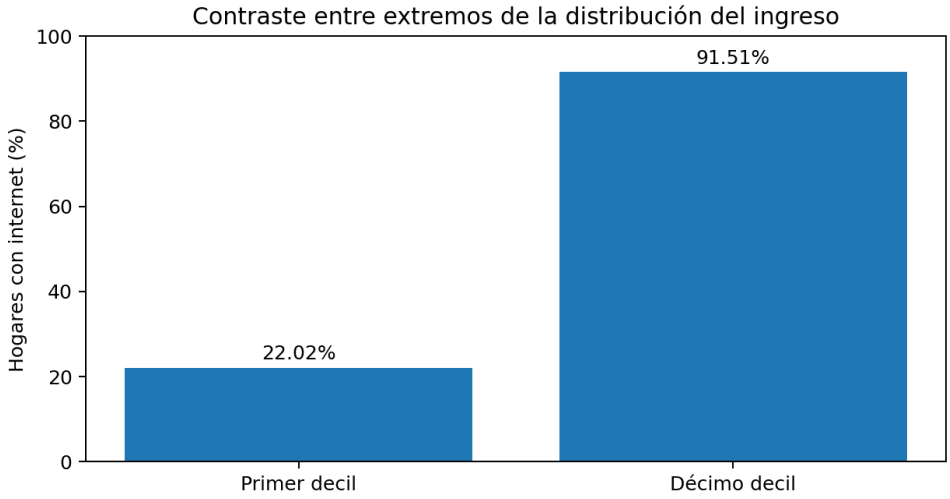


Figura 3. Diferencia descriptiva entre el primer y el décimo decil de ingreso.

La revisión de sensibilidad excluyendo los cinco valores extremos produjo cambios mínimos en los tamaños de efecto inferenciales (por ejemplo, V de Cramér de área: 0,4163 frente a 0,4165; Spearman: 0,4514 frente a 0,4519). También se señalaron dos edades de jefes/as superiores a 100 años (102 y 104) para revisión. Estos controles no certifican la calidad de los registros ni justifican excluirlos sin una regla de origen.

4. Fase 2 — Análisis inferencial

La segunda fase contrastó cinco hipótesis con nivel nominal $\alpha = 0,05$ y corrección Bonferroni para la familia de cinco pruebas (α ajustado = 0,01). Los chequeos de supuestos rechazaron normalidad en IPCM (Shapiro-Wilk $W = 0,553952$; $p = 1,063\times10^{-77}$) y TOTAL ($W = 0,897993$; $p = 1,518\times10^{-49}$), y homogeneidad de varianzas en IPCM

(Levene = 167,176; p = 4,620×10⁻³⁸) y TOTAL (Levene = 29,293; p = 6,304×10⁻⁸). Por ello se emplearon pruebas no paramétricas para comparaciones de distribuciones y chi-cuadrado para asociaciones categóricas.

Hipótesis / relación	Prueba y resultado	Tamaño del efecto	Interpretación
Área × internet	$\chi^2(1) = 2.964{,}350$; $p < 0{,}001$	V = 0,416	Asociación de magnitud moderada; área urbana presenta mayor acceso.
Educación × internet	$\chi^2(3) = 2.770{,}564$; $p < 0{,}001$	V = 0,403	Asociación moderada; niveles educativos más altos muestran más hogares conectados.
IPCM según internet	Mann–Whitney U = 53.178.983; p < 0,001	r = 0,460	Distribuciones de ingreso difieren; mediana conectados Gs. 2.207.393 y no conectados Gs. 1.100.000.
Años de estudio × IPCM	Spearman ρ = 0,451; p < 0,001	ρ = 0,451	Asociación monotónica positiva moderada.
Tamaño del hogar según internet	Mann–Whitney U = 35.881.248; p ≈ 9×10⁻⁷	r = 0,038	Significativo tras Bonferroni, pero con relevancia práctica muy pequeña; mediana = 3 en ambos grupos.

Los cinco contrastes conservaron significancia estadística tras Bonferroni. Sin embargo, el resultado de tamaño del hogar ilustra por qué la significancia no equivale a importancia práctica: con una muestra grande, una diferencia pequeña puede producir un valor p bajo. Tampoco se deduce causalidad de estas asociaciones. La inferencia estándar no incorporó integralmente factores, estratos y conglomerados de la encuesta, por lo que la generalización poblacional debe ser prudente.

Devolución docente sobre la Fase 2: según lo informado por el grupo, la profesora confirmó que el análisis estaba correcto y que podían continuar con el mismo enfoque. No solicitó correcciones ni cambios adicionales. Por lo tanto, no se atribuyen correcciones inexistentes a la devolución; las decisiones siguientes son ajustes de preparación del modelo, fundamentados en los hallazgos y limitaciones ya documentados en la Fase 2.

5. Fase 3 — Modelado predictivo

La variable objetivo fue TIENE_INTERNET, con clasificación binaria a nivel de hogar. Se usaron ocho predictores y se excluyeron identificadores, variables de conexión observadas solo entre hogares conectados, variables directamente vinculadas a la construcción del objetivo y campos redundantes derivados del ingreso o educación. FACTOR no se usó como predictor ni se modeló el diseño complejo.

Se separó la base estratificadamente en 60 % entrenamiento (10.255), 20 % validación (3.418) y 20 % prueba (3.419), con semilla 42. Sobre entrenamiento se aplicó validación cruzada estratificada de tres pliegues y búsqueda en grilla. Se comparó una regresión logística, Random Forest e HistGradientBoosting contra una línea base que predice la clase mayoritaria. El modelo se seleccionó por F1 en validación, con AUC-ROC como desempate; la prueba se reservó para la evaluación final.

Modelo	F1 medio CV	F1 en validación
HistGradientBoosting	0,8407	0,8382
Random Forest	0,8275	0,8262
Regresión logística	0,8122	0,8112
Línea base mayoritaria	—	0,7663

5.1. Métricas de prueba y sobreajuste

Partición	Accuracy	Precision	Recall	F1	AUC-ROC
Entrenamiento	0,8106	0,8317	0,8716	0,8512	0,8867
Validación	0,7926	0,8128	0,8653	0,8382	0,8649
Prueba	0,8023	0,8238	0,8672	0,8450	0,8695

Modelo en prueba	Accuracy	F1	AUC-ROC
HistGradientBoosting	0,8023	0,8450	0,8695
Línea base mayoritaria	0,6212	0,7664	0,5000

El F1 aumenta 0,0786 puntos frente a la línea base y el AUC-ROC aumenta 0,3695. La diferencia de F1 entre entrenamiento y prueba es 0,0062; entre entrenamiento y validación, 0,0129. No se observa una brecha marcada en esta partición, aunque no existe validación externa o temporal.

5.2. Errores y variables influyentes

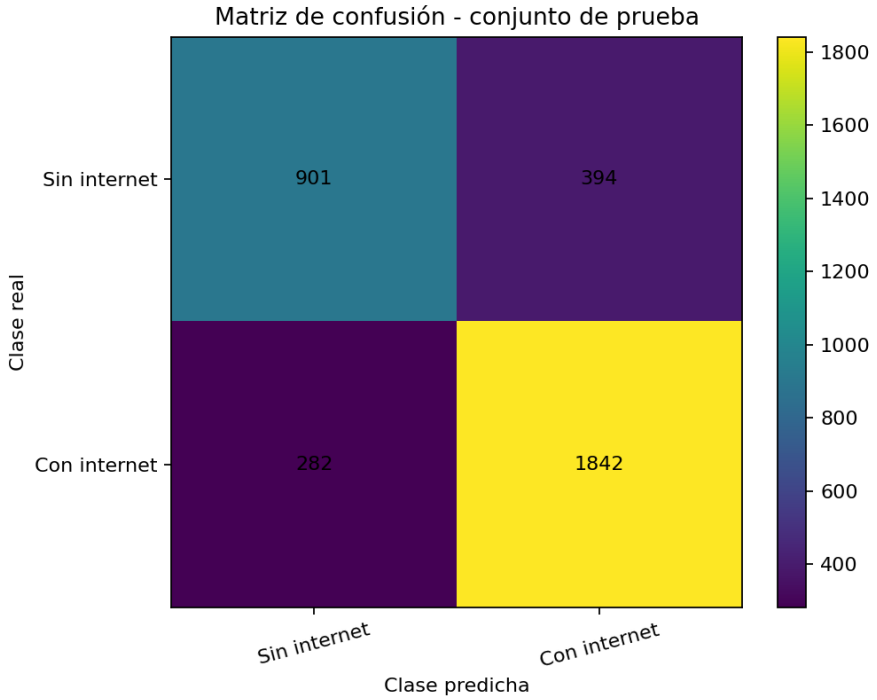


Figura 4. Matriz de confusión del modelo seleccionado en prueba.

La matriz registra 901 verdaderos negativos, 1.842 verdaderos positivos, 394 falsos positivos y 282 falsos negativos: 676 errores (19,8 %) en 3.419 hogares. La tasa de error entre hogares conectados fue 39,2 % en el área rural y 4,8 % en la urbana. Entre hogares sin internet, fue 59,7 % en el área urbana y 17,7 % en la rural. Entre los errores de mayor confianza, 35 de 36 falsos positivos fueron urbanos, mientras que 13 de 14 falsos negativos fueron rurales; este perfil refuerza la necesidad de auditar el sesgo antes de cualquier aplicación y de no usar el modelo para decidir el acceso individual a servicios.

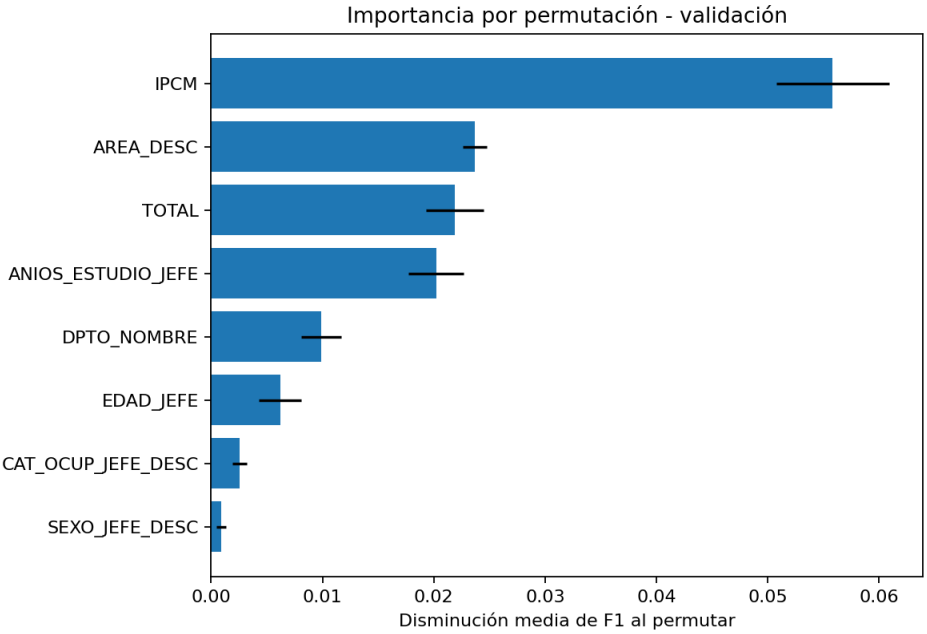


Figura 5. Importancia por permutación calculada en validación.

IPCM fue el predictor más importante (disminución media de F1 = 0,0558), seguido por AREA_DESC (0,0237), TOTAL (0,0219) y ANIOS_ESTUDIO_JEFE (0,0202). El orden coincide en términos generales con las asociaciones

descriptivas e inferenciales de ingreso, territorio y educación. La importancia por permutación es propia del modelo y de la partición; no mide causalidad.

6. Integración de evidencias y conclusión general

Las tres fases convergen en una respuesta consistente. Primero, el análisis exploratorio muestra que el acceso está distribuido de forma desigual por territorio, educación e ingreso: hogares urbanos, con mayor educación y ubicados en deciles de ingreso altos presentan porcentajes de conexión mayores. Segundo, la inferencia respalda asociaciones de magnitud moderada entre acceso y área (V = 0,416), educación (V = 0,403) e ingreso (r = 0,460), además de una asociación positiva entre educación e IPCM (ρ = 0,451). Tercero, el modelo predictivo identifica IPCM, área, tamaño del hogar y años de estudio como variables influyentes, y supera la línea base en la prueba.

La respuesta consolidada a la pregunta rectora es que el acceso a internet en los hogares paraguayos analizados se asocia principalmente con condiciones económicas y territoriales, y también con la educación del jefe/a. Estas variables permiten anticipar la disponibilidad con capacidad discriminante interna razonable. No obstante, no se puede concluir que causen el acceso ni se puede afirmar que el desempeño se mantendrá para toda la población o en otros años sin incorporar el diseño de encuesta y validar con datos externos.

7. Recomendaciones y trabajo futuro

- Priorizar nuevos análisis de brechas territoriales y de hogares rurales, utilizando estimaciones ponderadas compatibles con el diseño muestral.
- Verificar los cinco valores IPCM superiores a Gs. 100 millones y las edades de jefes/as superiores a 100 años en los microdatos y documentación antes de corregir o excluir.
- Incorporar estratos, conglomerados y factores de expansión en análisis descriptivos e inferenciales y evaluar alternativas de modelado/validación compatibles con el diseño de encuesta.
- Repetir el entrenamiento con ediciones anuales posteriores o una fuente independiente, conservando una validación temporal cuando haya varias olas comparables.
- Auditar calibración, falsos positivos, falsos negativos y tasas de error por área, departamento y grupos socioeconómicos; documentar umbrales según los costos reales.
- Mantener el modelo como instrumento académico y exploratorio hasta resolver las limitaciones de representatividad, validación externa y sesgo.

8. Limitaciones, ética y uso de IA

- El análisis estándar y las métricas de Fase 3 son no ponderados y no incorporan de manera completa el diseño muestral de la EPHC.
- La base es transversal y de una sola edición anual; no se realizan inferencias causales ni pronósticos temporales.
- El modelo presenta tasas de error distintas entre áreas. Un falso negativo podría ocultar un hogar conectado; un falso positivo podría sobreestimar la cobertura. Ambos pueden distorsionar decisiones.
- No se recomienda emplear la predicción para negar servicios, subsidios, beneficios o derechos. Cualquier uso con impacto requiere evaluación formal, supervisión humana, transparencia y mecanismos de apelación.

9. Fuentes

Fuente de datos: Instituto Nacional de Estadística (INE), Paraguay. Encuesta Permanente de Hogares Continua (EPHC), base anual 2025. Portal de microdatos: https://www.ine.gov.py/microdatos/; dentro del portal, seleccionar la carpeta EPHC_2025_ANUAL. Según la documentación de Fase 1, la base anual 2025 fue provista por la cátedra y la fecha de obtención registrada fue septiembre de 2026. El informe de Fase 1 declara que se trata de microdatos públicos y anonimizados de estadística oficial, bajo la Licencia de Uso de la Información Pública del Gobierno Paraguayo, con uso exclusivamente académico y análisis agregado. Archivos originales: REG01_EPHC_ANUAL_2025.csv, REG02_EPHC_ANUAL_2025.csv, INGREFAM_EPHC_ANUAL_2025.csv y diccionario_EPHC_ANUAL_2025.xls. El modelado utiliza dataset_limpio_internet_hogares.csv (17.092 hogares × 21 variables).

Documentos de antecedentes contrastados: informe original de Fase 1 (20 páginas) e informe original de Fase 2 (13 páginas), incluidos en informe/antecedentes/. La pregunta y el objetivo se transcribieron de Fase 1. La profesora confirmó que Fase 2 estaba correcta y no pidió cambios.