



Propuesta de Trabajo Práctico

Integrantes:

- Gustavo Fabian Carballo Rojas
- Joel Maria Mendieta Candia

Identificación

Asignatura: Ciencia de Datos (Electiva)
Curso: TQ

Objetivos

Presentar de forma clara y viable una propuesta de proyecto siguiendo el ciclo de un proyecto de Data Science: comprensión del problema, definición de la pregunta, identificación y preparación de datos, análisis/modelado, evaluación y comunicación de resultados.

Actividad

Completar el siguiente formulario:

1. Tema del proyecto

Orientación: Indique el tema o área de aplicación. Debe ser específico y estar vinculado con un problema que pueda abordarse mediante datos.

Tema:

Factores asociados al acceso a internet en los hogares paraguayos y predicción de la disponibilidad de conexión.

Contexto o dominio:

Brecha digital y acceso a Tecnologías de la Información y Comunicación (TIC) en los hogares del Paraguay, a partir de los datos oficiales de la Encuesta Permanente de Hogares Continua (EPHC) del INE.



Breve descripción del problema:

A pesar del crecimiento sostenido del acceso a internet en Paraguay en la última década, persisten brechas importantes entre el área urbana y rural, y entre hogares de distinto nivel socioeconómico. El proyecto busca caracterizar qué factores (ingreso, educación, ubicación geográfica, tipo de vivienda) se asocian con que un hogar cuente o no con conexión a internet, y construir un modelo capaz de predecir esa condición.

2. Pregunta a responder

Orientación: Formule una pregunta principal que el proyecto buscará responder utilizando datos. Debe ser concreta, medible y coherente con los datos que se espera obtener.

Pregunta principal:

¿Qué factores socioeconómicos, educativos y geográficos explican que un hogar paraguayo cuente con acceso a internet, y es posible predecir esa condición a partir de las características del hogar?

¿Por qué es importante responderla?

Conocer los determinantes del acceso a internet permite identificar a la población en situación de exclusión digital y orientar políticas públicas de conectividad. Es relevante para organismos como el MITIC, gobiernos locales, ONGs de desarrollo digital y para entender el avance del país hacia el ODS 17 (fortalecer los medios de implementación, incluida la conectividad).

3. Objetivo general

Orientación: Redacte un único objetivo general. Debe expresar el resultado principal que se desea alcanzar y comenzar, preferentemente, con un verbo en infinitivo (analizar, predecir, identificar, clasificar, estimar, comparar, etc.).

Objetivo general:

Predecir la disponibilidad de acceso a internet en los hogares paraguayos a partir de sus características socioeconómicas, educativas y geográficas.



4. Objetivos específicos

Orientación: Defina entre 3 y 5 objetivos específicos que describan los pasos necesarios para alcanzar el objetivo general. Deben ser observables y verificables.

Objetivo específico 1:

Caracterizar el nivel de acceso a internet de los hogares paraguayos según área urbana/rural, departamento y nivel de ingreso, mediante estadística descriptiva.

Objetivo específico 2:

Contrastar mediante pruebas estadísticas si existen diferencias significativas en el acceso a internet entre grupos (por ejemplo, urbano vs. rural, o por quintil de ingreso).

Objetivo específico 3:

Identificar qué variables del hogar (ingreso, educación del jefe de hogar, cantidad de miembros, tipo de vivienda) están más asociadas al acceso a internet.

Objetivo específico 4 (opcional):

Objetivo específico 5 (opcional):

5. Datos necesarios

Orientación: Describa qué datos serán necesarios para responder la pregunta y alcanzar los objetivos. En esta etapa no es necesario realizar todavía el análisis.

Fuente(s) de datos:



Instituto Nacional de Estadística (INE) del Paraguay — Encuesta Permanente de Hogares Continua (EPHC) Anual 2025, módulo de Tecnologías de la Información y Comunicación (TIC). Microdatos y diccionario de variables disponibles en <https://www.ine.gov.py/microdatos/> (carpeta EPHC_2025_ANUAL). Documentación técnica adicional en el catálogo ANDA del INE (<https://anda.ine.gov.py>).

Variables o atributos principales:

Acceso a internet en el hogar (sí/no) y tipo de conexión (fija/móvil); tenencia de computadora, celular y TV por cable; área de residencia (urbana/rural); departamento; ingreso del hogar; nivel educativo y ocupación del jefe/a de hogar; cantidad de miembros del hogar; tipo de vivienda y material de construcción.

Unidad de análisis:

El hogar (unidad familiar encuestada por la EPHC).

Cantidad aproximada de datos (si se conoce):

Aproximadamente 15.000 a 20.000 hogares (la EPHC Anual 2025 es representativa a nivel nacional, por área urbana/rural y para los 15 departamentos más Asunción, con 31 estratos de muestreo).

Formato de los datos:

Microdatos en formato SPSS/Stata/CSV según el año de descarga, acompañados de diccionario de variables en PDF, descargados directamente del portal de microdatos del INE.

Consideraciones de privacidad, ética o permisos:

Los microdatos de la EPHC son de acceso público y están anonimizados (sin nombres ni datos de identificación individual), publicados bajo la Licencia de Uso de la Información Pública del Gobierno Paraguayo. El uso previsto es exclusivamente académico y el análisis se hará a nivel agregado, sin intentar reidentificar hogares ni personas. Se aclarará que la



EPHC no cubre los departamentos de Boquerón y Alto Paraguay, ni comunidades indígenas ni viviendas colectivas.

6. Metodología propuesta de Data Science

Orientación: Explique brevemente cómo se desarrollará el proyecto. Puede utilizar como guía un proceso similar a CRISP-DM, adaptado a la materia.

a) Comprensión del problema:

Se definirá la pregunta de investigación y los objetivos general y específicos del proyecto, delimitando el alcance a los hogares relevados por la EPHC en el período 2022-2024.

b) Comprensión y exploración de los datos:

Se explorarán los microdatos de la EPHC: se revisará el diccionario de variables del módulo TIC, se evaluará la calidad y completitud de los datos (valores faltantes, cobertura geográfica) y se realizará un perfilado inicial de las variables clave.

c) Limpieza y preparación de los datos:

Se limpiarán y transformarán los datos: tratamiento de valores faltantes, normalización de categorías, creación de variables derivadas (por ejemplo, quintiles de ingreso, tramos etarios del jefe de hogar) y construcción del dataset final para el análisis.

d) Análisis y/o modelado:

Se realizará análisis descriptivo (univariado y bivariado) y análisis inferencial (pruebas de hipótesis) para identificar asociaciones entre variables, y luego se entrenarán modelos de clasificación (por ejemplo, regresión logística y árboles de decisión) para predecir el acceso a internet del hogar.

e) Evaluación de resultados:



Se evaluarán los modelos con métricas de clasificación (exactitud, precisión, exhaustividad, F1, AUC-ROC), comparando el desempeño contra una línea base y analizando la brecha entre entrenamiento y prueba para detectar sobreajuste.

f) Visualización y comunicación de resultados:

Los resultados se comunicarán mediante visualizaciones (mapas o gráficos de barras por departamento, diagramas de caja, matriz de correlación) y un informe/presentación final dirigido a una audiencia no especializada.

7. Técnicas y herramientas previstas

Orientación: Indique las técnicas y herramientas que considera utilizar. Esta selección puede modificarse durante el desarrollo del proyecto.

Técnicas estadísticas / análisis exploratorio:

Estadística descriptiva (medidas de tendencia central y dispersión), tablas de contingencia, pruebas de hipótesis (chi-cuadrado, comparación de proporciones), análisis de correlación.

Técnicas de Machine Learning (si corresponde):

Regresión logística, árboles de decisión y un tercer modelo a elección (por ejemplo, Random Forest), para la tarea de clasificación binaria (hogar con/sin acceso a internet).

Herramientas y lenguajes:

Python (pandas, numpy, matplotlib, seaborn, scipy, statsmodels, scikit-learn) en Jupyter Notebook.

Visualizaciones previstas:



Mapa o gráfico de barras de acceso a internet por departamento, comparación urbano/rural, distribución de ingresos por acceso, matriz de correlación de variables, matriz de confusión del modelo final.

8. Resultado o producto esperado

Orientación: Describa qué se espera obtener al finalizar el proyecto: hallazgos, modelo predictivo, clasificación, segmentación, dashboard, visualizaciones, recomendaciones u otro producto.

Resultado esperado:

Un modelo predictivo (clasificador) que estime la probabilidad de que un hogar tenga acceso a internet, junto con un análisis descriptivo e inferencial de los factores asociados, y recomendaciones orientadas a políticas de conectividad.

¿Cómo se evaluará si el proyecto respondió la pregunta inicial?

Se evaluará comparando las métricas del modelo contra la línea base y verificando si las variables identificadas como significativas en la fase inferencial coinciden con las de mayor importancia en el modelo predictivo, lo que permitirá afirmar con evidencia qué factores explican el acceso a internet en los hogares paraguayos.

9. Lista de verificación antes de entregar

- ☐ El tema está claramente delimitado.
- ☐ Existe una pregunta principal que puede responderse con datos.
- ☐ El objetivo general responde directamente a la pregunta.
- ☐ Los objetivos específicos conducen al logro del objetivo general.
- ☐ Se identificaron fuentes de datos realistas y accesibles.
- ☐ La metodología incluye preparación, análisis/modelado y evaluación.
- ☐ Se consideraron aspectos éticos, de privacidad y calidad de los datos.
- ☐ El resultado esperado permite verificar si se respondió la pregunta.

10. Referencias / fuentes iniciales

Incluya enlaces, artículos, datasets, documentación técnica u otras fuentes utilizadas para formular la propuesta.



1. Instituto Nacional de Estadística (INE) Paraguay – Portal de microdatos:
<https://www.ine.gov.py/microdatos/>
2. INE Paraguay – ¿Cómo está el acceso a las Tecnologías de la Información y Comunicación en el Paraguay?: <https://www.ine.gov.py/ende/contenido.php?c=2037>
3. Catálogo ANDA – documentación técnica EPHC: <https://anda.ine.gov.py>