

PROYECTO INTEGRADOR DE CIENCIA DE DATOS

Del problema de negocio al modelo predictivo — desarrollo en tres fases

Ítem	Detalle
Asignatura	Data Science (grado — Ingeniería Informática)
Modalidad	Grupal, de 2 a 3 integrantes. El grupo se mantiene durante las tres fases.
Estructura	Tres fases acumulativas sobre un mismo conjunto de datos, más una presentación final.
Ponderación total	100 % de la nota del proyecto integrador (Fase 1: 30 % · Fase 2: 25 % · Fase 3: 30 % · Presentación: 15 %)
Condición de aprobación	Entregar las tres fases y realizar la presentación. Cada fase se aprueba con 6 / 10.
Entrega	Campus virtual, hasta las 23:59 h de la fecha indicada. Un solo envío por grupo.

CALENDARIO DE ENTREGAS

Fase	Contenido	Fecha de entrega
Fase 1	Comprensión del problema · Comprensión y selección de los datos · Limpieza y transformación · Análisis univariado y bivariado · Análisis descriptivo y exploratorio	Lunes 15 de septiembre
Fase 2	Análisis inferencial · Formulación y contraste de hipótesis	Viernes 3 de octubre
Fase 3	Análisis predictivo · Modelado y evaluación	Viernes 24 de octubre
Cierre	Presentación oral del proyecto completo	Última semana de clases

1. Fundamentación

Un proyecto de ciencia de datos no consiste en aplicar algoritmos sobre una tabla. Consiste en transformar una pregunta que le importa a alguien en una respuesta respaldada por evidencia, atravesando un ciclo de trabajo que empieza mucho antes del código y termina mucho después del modelo.

Este proyecto integrador reproduce ese ciclo completo. El grupo elegirá un conjunto de datos, formulará su propia pregunta de investigación y la sostendrá durante todo el semestre, profundizando el nivel de análisis en cada fase: primero describir lo que ocurre, luego determinar si lo observado es estadísticamente sostenible y, finalmente, anticipar lo que podría ocurrir.

La secuencia no es arbitraria. No se puede contrastar una hipótesis que no se supo formular, ni se puede predecir con datos cuyo comportamiento no se comprendió previamente. Cada fase se construye sobre la anterior y se corrige con la devolución del docente, tal como sucede en un proyecto real.

2. Objetivos de aprendizaje

Al finalizar el proyecto, el/la estudiante será capaz de:

- Traducir una situación real en una pregunta de investigación responsable con los datos disponibles, con objetivos general y específicos bien delimitados.
- Evaluar críticamente la calidad, la cobertura y las limitaciones de un conjunto de datos antes de utilizarlo.
- Ejecutar un proceso de limpieza y transformación documentado y reproducible.
- Caracterizar los datos mediante análisis univariado, bivariado y exploratorio, con visualizaciones correctas.
- Formular hipótesis estadísticas, seleccionar la prueba adecuada, verificar sus supuestos e interpretar resultados en términos de significancia y de relevancia práctica.
- Construir, validar y evaluar modelos predictivos, reconociendo el sobreajuste y las limitaciones de generalización.
- Comunicar hallazgos y recomendaciones a audiencias técnicas y no técnicas.

3. Metodología de trabajo

El proyecto sigue la lógica de CRISP-DM (Cross Industry Standard Process for Data Mining), el marco metodológico más difundido en la industria, adaptado al calendario académico. Sus etapas se distribuyen en las tres fases del siguiente modo:

Fase	Etapas CRISP-DM	Qué se produce
Fase 1	Comprensión del negocio	Pregunta de investigación, objetivo general y objetivos específicos.
Fase 1	Comprensión de los datos	Diccionario de datos, perfilado, evaluación de calidad y justificación de la selección.
Fase 1	Preparación de los datos	Dataset limpio y transformado, con bitácora de decisiones.
Fase 1	Análisis exploratorio	Análisis univariado, bivariado y visualizaciones con interpretación.
Fase 2	Inferencia estadística	Hipótesis formuladas, pruebas ejecutadas, verificación de supuestos y conclusiones.

Fase	Etapa CRISP-DM	Qué se produce
Fase 3	Modelado y evaluación	Modelo predictivo entrenado, validado y comparado contra una línea base.
Cierre	Despliegue / comunicación	Presentación oral e informe integrador.

Advertencia: CRISP-DM es iterativo, no lineal. Es esperable —y bien valorado— que en la Fase 2 el grupo deba volver a limpiar una variable, o que en la Fase 3 descubra que necesita una transformación que no había previsto. Lo que se evalúa negativamente no es volver atrás, sino no documentar por qué se volvió.

4. Conjuntos de datos disponibles

Cada grupo elige una de las cuatro opciones. La elección debe comunicarse al docente antes del inicio de la Fase 1 y no puede cambiarse después de entregada esa fase. Se admiten como máximo tres grupos por opción, asignados por orden de solicitud.

Ninguna opción es más fácil que otra: todas exigen el mismo recorrido metodológico. La diferencia está en el dominio del problema y en el tipo de dificultades técnicas que presentan.

Opción A — Ventas cruzadas con datos climáticos

Fuente de ventas: https://drive.google.com/drive/folders/1HY62wPa7o-VJEQT9yTzacWud0LqffGD8?usp=drive_link

Los datos climáticos deben obtenerse de una fuente pública: Open-Meteo (API histórica, sin clave de acceso), NASA POWER, NOAA/GHCN-Daily o el servicio meteorológico nacional correspondiente. Variables mínimas: temperatura media, máxima y mínima diaria, precipitación acumulada y una variable adicional a elección.

Desafío técnico central: la integración de dos fuentes con distinta granularidad temporal y geográfica, y la separación del efecto del clima respecto de los efectos de calendario.

Ejemplos de preguntas: ¿en qué medida las condiciones climáticas explican la variación diaria de la facturación? ¿El efecto de la lluvia es homogéneo entre categorías de producto o sucursales? ¿Es posible anticipar la demanda del día siguiente incorporando el pronóstico?

Opción B — Conjunto de datos alternativo de la cátedra

Fuente: https://drive.google.com/drive/folders/1iw_qeJcOjYemg-7EwgPwBcE_PNrGSGUq?usp=drive_link

Conjunto de datos provisto por la cátedra como alternativa. El grupo debe explorarlo, determinar su unidad de análisis y proponer una pregunta de investigación que resulte respondible con la información disponible. Si el conjunto no permitiera sostener las tres fases del proyecto, deberá plantearlo al docente durante la primera semana.

Opción C — Contrataciones públicas del Paraguay (DNCP)

Fuente: <https://www.contrataciones.gov.py/datos/data>

Portal de datos abiertos de la Dirección Nacional de Contrataciones Públicas. Ofrece servicios web y descargas de planificaciones, convocatorias, adjudicaciones, contratos, catálogo de productos, proveedores y protestas o denuncias, publicados bajo el estándar internacional OCDS (Open Contracting Data Standard) y disponibles también como archivos CSV comprimidos por año.

Desafío técnico central: el volumen de datos, la estructura anidada de los archivos OCDS —un proceso contiene lotes, que contienen ítems— y la necesidad de relacionar varias tablas mediante identificadores de proceso.

Ejemplos de preguntas: ¿qué factores se asocian a la diferencia entre el monto estimado en la convocatoria y el monto finalmente adjudicado? ¿Existe relación entre la modalidad de contratación y el nivel de concurrencia de oferentes? ¿Se puede anticipar qué procesos tendrán una única oferta? ¿Cómo se distribuye la concentración de proveedores por entidad convocante?

Opción D — Funcionarios públicos de una institución del Estado paraguayo

Fuentes recomendadas:

- Portal de datos abiertos de la Secretaría de la Función Pública: <https://datos.sfp.gov.py/data/funcionarios> (nómina proveniente del SICCA).
- Portal de datos abiertos del Ministerio de Economía y Finanzas: <https://datos.hacienda.gov.py/data/nomina> (remuneraciones presupuestadas y devengadas).
- Portal nacional de datos abiertos: <https://www.datos.gov.py>

El grupo debe acotar el análisis a una institución o a un conjunto reducido de entidades, y a un período definido. Analizar la nómina completa del Estado sin recorte no es una decisión metodológica válida y será observada.

Desafío técnico central: la variación de la estructura de los archivos entre períodos, la codificación de categorías presupuestarias y objetos de gasto, y la necesidad de construir series comparables en el tiempo.

Ejemplos de preguntas: ¿cómo se distribuyen las remuneraciones dentro de la institución y qué nivel de desigualdad interna presentan? ¿Existen diferencias salariales asociadas al tipo de vínculo (permanente, contratado, comisionado) a igualdad de categoría? ¿Cómo evolucionó la planta de personal y su masa salarial en el período analizado?

Ética y datos personales: las opciones C y D contienen información sobre personas y organizaciones reales, publicada legalmente en el marco de la Ley 5282/2014 de Acceso a la Información Pública. El uso es exclusivamente académico. Están prohibidos los juicios de valor sobre personas identificadas, la insinuación de irregularidades sin evidencia y la difusión de los datos fuera del ámbito de la materia. El análisis se refiere a patrones agregados, nunca a individuos.

5. Fase 1 — Comprensión, preparación y análisis exploratorio

Fecha de entrega: lunes 15 de septiembre | Ponderación: 30 %

5.1. Etapa 1 — Comprensión del problema

Esta etapa se entrega como un documento propio, breve y bien redactado, que abre el informe de la fase. Es la pieza que orienta todo el proyecto: si la pregunta está mal formulada, ninguna técnica posterior lo compensa.

1. **Contexto del problema:** quién genera estos datos, para qué se usan, qué decisión o situación real está en juego. Media página.
2. **Pregunta de investigación:** una sola pregunta principal, redactada en una oración. Debe ser específica, acotada en tiempo y alcance, y responsable con los datos elegidos.
3. **Objetivo general:** formulado con un verbo en infinitivo, expresando el propósito global del proyecto.
4. **Objetivos específicos:** de tres a cinco, cada uno alcanzable y verificable, y en conjunto suficientes para cumplir el objetivo general. Al menos uno debe corresponder a la fase inferencial y otro a la fase predictiva.
5. **Justificación de la relevancia:** por qué vale la pena responder esta pregunta y quién podría usar la respuesta.
6. **Alcance y limitaciones previstas:** qué queda explícitamente fuera del análisis.

Criterio de una buena pregunta: debe poder responderse con evidencia, no con opinión, y debe admitir la posibilidad de que la respuesta sea negativa. "¿Analizar las ventas?" no es una pregunta. "¿La temperatura media diaria se asocia con la facturación de bebidas, una vez controlado el día de la semana?" sí lo es.

5.2. Etapa 2 — Comprensión y selección de los datos

1. Inventario de los archivos disponibles: cantidad, formato, tamaño, período cubierto y relación entre ellos.
2. Diccionario de datos elaborado por el grupo: nombre del campo, descripción, tipo, unidad de medida, rango o categorías observadas y porcentaje de valores faltantes. La cátedra no lo provee; reconstruirlo forma parte de la evaluación.
3. Determinación de la unidad de análisis y de la clave primaria de cada tabla, con verificación empírica de su unicidad.
4. Perfilado inicial: dimensiones, tipos detectados frente a tipos correctos, cardinalidad de las variables categóricas, distribución preliminar de las numéricas.
5. Evaluación de calidad: completitud, consistencia, exactitud aparente, actualidad y trazabilidad de la fuente.
6. **Selección justificada:** qué archivos, qué variables y qué período se conservan para el proyecto, y por qué el resto se descarta. Cada descarte debe estar vinculado a un objetivo específico.
7. Documentación de la fuente: URL exacta, fecha de descarga, versión o corte de los datos, licencia de uso y unidades de medida.

5.3. Etapa 3 — Limpieza y transformación

1. Tratamiento de valores faltantes: cuantificación por columna, análisis del mecanismo de ausencia y estrategia adoptada (eliminación, imputación o conservación explícita), siempre justificada.
2. Detección y tratamiento de duplicados, exactos y parciales.

3. Identificación de valores atípicos e inconsistencias: importes negativos o imposibles, fechas fuera de rango, categorías con la misma semántica escritas de distinta forma, códigos que cambian de significado entre períodos.
4. Normalización de tipos y formatos: fechas a tipo temporal, unificación de mayúsculas y espacios, verificación de separadores decimales, tratamiento de codificación de caracteres.
5. Creación de variables derivadas necesarias para los objetivos: agregaciones, ratios, categorizaciones con puntos de corte justificados, variables de calendario, deflactación de montos si se comparan períodos distintos.
6. Integración de fuentes, si corresponde: definición de la clave de cruce, resolución de granularidades, tipo de unión elegido y auditoría del resultado (filas antes y después, porcentaje de registros no apareados, verificación de no duplicación).
7. **Bitácora de limpieza:** tabla que registre cada decisión tomada, la cantidad de registros afectados y su fundamento.

Regla no negociable: toda transformación debe ser reproducible por código desde los archivos originales. Está prohibido editar los datos a mano en una planilla de cálculo. El notebook debe poder ejecutarse de principio a fin en un entorno limpio y regenerar el dataset final.

5.4. Etapa 4 — Análisis univariado y bivariado

Univariado

- Variables numéricas: media, mediana, moda, desvío estándar, coeficiente de variación, mínimo, máximo, rango intercuartílico y percentiles 5, 25, 50, 75 y 95.
- Forma de la distribución: asimetría y curtosis, con discusión explícita de si la media es un resumen adecuado o si conviene la mediana.
- Variables categóricas: frecuencias absolutas y relativas, y análisis de concentración (por ejemplo, qué porcentaje del total explica el 20 % de las categorías).
- Visualización correspondiente: histograma o densidad, diagrama de caja, gráfico de barras.

Bivariado

- Numérica frente a numérica: diagramas de dispersión, correlación de Pearson y de Spearman, matriz de correlaciones en mapa de calor.
- Numérica frente a categórica: comparación de distribuciones por grupo mediante diagramas de caja o violín, y tabla de estadísticos resumen por categoría.
- Categórica frente a categórica: tablas de contingencia con frecuencias absolutas y relativas por fila y por columna.
- Análisis temporal, si la variable de tiempo es relevante: serie con media móvil, estacionalidad semanal y mensual, identificación de tendencias y quiebres.

5.5. Etapa 5 — Análisis descriptivo y exploratorio

Con los resultados anteriores, el grupo debe construir una caracterización integrada del fenómeno: no una lista de estadísticos, sino una descripción articulada de cómo se comportan los datos y qué patrones emergen.

- Mínimo de ocho visualizaciones distintas, incluyendo al menos una serie temporal, un histograma o densidad, un diagrama de caja, un diagrama de dispersión, un gráfico de barras comparativo y un mapa de calor de correlaciones.
- Cada gráfico debe llevar título descriptivo, ejes rotulados con unidades, leyenda cuando corresponda, escala que no distorsione la comparación y una interpretación escrita de una a tres oraciones inmediatamente debajo. Un gráfico sin interpretación no suma puntaje.

- Identificación de al menos tres patrones o anomalías relevantes, con la evidencia que los respalda.
- **Hipótesis preliminares:** a partir de lo observado, enunciar entre tres y cinco hipótesis que serán contrastadas formalmente en la Fase 2. Este es el puente entre ambas fases y su ausencia se penaliza.

5.6. Conclusión de la Fase 1

Sección obligatoria de cierre, de una a dos páginas, que debe contener: descripción de los principales resultados obtenidos, respuesta parcial a la pregunta de investigación en lo que el análisis descriptivo permite afirmar, limitaciones detectadas en los datos, decisiones que condicionan las fases siguientes y las hipótesis que se llevarán a la Fase 2.

5.7. Entregables de la Fase 1

N.º	Entregable	Especificación
1	Documento de comprensión del problema	PDF de 2 a 3 páginas con contexto, pregunta de investigación, objetivo general, objetivos específicos, justificación y alcance. Se entrega también como primera sección del informe.
2	Informe de la Fase 1	PDF de hasta 20 páginas sin anexos, con las etapas 1 a 5 y la conclusión.
3	Notebook y exportación HTML	Ejecutado de principio a fin, sin errores, con celdas de texto que expliquen cada decisión.
4	Diccionario de datos	En tabla, dentro del informe o como anexo, del conjunto original y del conjunto final.
5	Dataset limpio	Archivo .csv o .parquet resultante de la etapa 3.
6	Repositorio Git	Con README de reproducción, archivo de dependencias y estructura /data, /notebooks, /src, /output. Compartido con la cátedra.

6. Fase 2 — Análisis inferencial

Fecha de entrega: viernes 3 de octubre | Ponderación: 25 %

El análisis descriptivo muestra lo que ocurre en los datos observados. La inferencia responde una pregunta distinta y más exigente: ¿lo observado es compatible con el azar, o hay evidencia suficiente para sostener que el patrón existe más allá de esta muestra?

6.1. Actividades

1. **Retomar y corregir la Fase 1** según la devolución del docente. Los cambios aplicados deben listarse al inicio del informe.
2. **Formular las hipótesis:** mínimo cuatro contrastes, derivados de las hipótesis preliminares de la Fase 1. Cada uno con hipótesis nula y alternativa escritas en lenguaje formal y en lenguaje natural, y con el nivel de significancia declarado de antemano.
3. **Seleccionar y justificar la prueba** adecuada para cada hipótesis, en función del tipo de variables, la cantidad de grupos y el cumplimiento de los supuestos.
4. **Verificar los supuestos antes de aplicar la prueba:** normalidad (Shapiro-Wilk, gráfico Q-Q), homogeneidad de varianzas (Levene), independencia de las observaciones. Si no se cumplen, pasar a la alternativa no paramétrica y documentarlo.
5. **Ejecutar las pruebas e informar** el estadístico, los grados de libertad, el valor p, el intervalo de confianza y el tamaño del efecto.
6. **Aplicar corrección por comparaciones múltiples** (Bonferroni o Benjamini-Hochberg) cuando se realicen varias pruebas sobre la misma familia de hipótesis, y explicar por qué es necesaria.
7. **Interpretar los resultados** distinguiendo significancia estadística de relevancia práctica, y discutiendo al menos una posible variable de confusión.

6.2. Repertorio de pruebas según el tipo de pregunta

El grupo debe cubrir al menos tres familias distintas de las siguientes. Repetir cuatro veces la misma prueba no satisface el requisito.

Tipo de pregunta	Prueba paramétrica	Alternativa no paramétrica
Comparar la media de dos grupos independientes	t de Student para muestras independientes	U de Mann-Whitney
Comparar dos mediciones apareadas	t para muestras relacionadas	Wilcoxon de rangos con signo
Comparar tres o más grupos	ANOVA de un factor, con post hoc de Tukey	Kruskal-Wallis, con post hoc de Dunn
Evaluar el efecto de dos factores y su interacción	ANOVA de dos factores	Modelos por permutación
Asociación entre dos variables categóricas	Chi-cuadrado de independencia (más V de Cramér)	Prueba exacta de Fisher si hay frecuencias bajas
Comparar dos proporciones	Prueba z de proporciones	Fisher
Significancia de una correlación	Prueba sobre r de Pearson, con intervalo por transformación de Fisher	Prueba sobre rho de Spearman
Efecto de una variable controlando otras	Regresión lineal múltiple: prueba t sobre coeficientes y F global	Regresión robusta o por permutación

Tipo de pregunta	Prueba paramétrica	Alternativa no paramétrica
Estimar un parámetro sin supuesto distribucional	—	Intervalo de confianza por bootstrap

6.3. Requisitos de reporte

- Tabla resumen con todas las pruebas realizadas: hipótesis, prueba aplicada, supuestos verificados, estadístico, valor p, intervalo de confianza, tamaño del efecto y decisión.
- **Tamaño del efecto obligatorio** en cada prueba: d de Cohen, eta cuadrado, V de Cramér o el que corresponda. Con muestras grandes, casi cualquier diferencia resulta significativa; el tamaño del efecto es lo que indica si importa.
- Redacción de la conclusión de cada contraste en lenguaje natural, comprensible para alguien sin formación estadística.
- Al menos un intervalo de confianza estimado por bootstrap, comparado con su equivalente clásico.

Errores que se penalizan: aplicar una prueba sin verificar sus supuestos; afirmar que se "acepta la hipótesis nula" en lugar de que no hay evidencia suficiente para rechazarla; derivar causalidad de un resultado significativo; ejecutar múltiples pruebas hasta encontrar una significativa sin declarar cuántas se hicieron; e informar el valor p sin el tamaño del efecto.

6.4. Conclusión de la Fase 2

Sección obligatoria que debe indicar: qué hipótesis se sostuvieron y cuáles no, qué implica cada resultado para la pregunta de investigación, qué limitaciones tiene la inferencia realizada (tamaño muestral, representatividad, dependencia temporal de las observaciones) y qué variables se llevarán al modelo predictivo de la Fase 3 a partir de esta evidencia.

6.5. Entregables de la Fase 2

- Informe de la Fase 2 en PDF, de hasta 15 páginas, incluyendo la lista de correcciones aplicadas a la Fase 1.
- Notebook ejecutado y su exportación en HTML.
- Tabla resumen de contrastes en formato reproducible (dentro del notebook y en el informe).
- Repositorio actualizado, con historial de commits que evidencie el trabajo de todos los integrantes.

7. Fase 3 — Análisis predictivo

Fecha de entrega: viernes 24 de octubre | Ponderación: 30 %

La fase final construye un modelo capaz de predecir sobre datos que no vio durante el entrenamiento. El objetivo pedagógico no es alcanzar la métrica más alta, sino demostrar un procedimiento de modelado y evaluación metodológicamente correcto.

7.1. Actividades

1. **Definir la tarea predictiva:** regresión o clasificación, con la variable objetivo claramente identificada y vinculada a un objetivo específico del proyecto.
2. **Preparar los datos para el modelado:** codificación de variables categóricas, escalado cuando el algoritmo lo requiera, tratamiento del desbalance de clases si corresponde, y selección de variables fundamentada en los hallazgos de las fases anteriores.
3. **Particionar los datos:** entrenamiento y prueba, con semilla fijada. Si hay componente temporal, la partición debe ser cronológica y no aleatoria: entrenar con el futuro para predecir el pasado es un error grave.
4. **Establecer una línea base:** un modelo trivial (la media, la clase mayoritaria, el valor del período anterior). Todo modelo posterior debe justificar su existencia superándola.
5. **Entrenar al menos tres modelos** de familias distintas: uno lineal o logístico, uno basado en árboles y un tercero a elección. Documentar los hiperparámetros utilizados.
6. **Validar con validación cruzada** (k-fold, o su variante temporal) y ajustar hiperparámetros mediante búsqueda en grilla o aleatoria, sin tocar nunca el conjunto de prueba.
7. **Evaluar sobre el conjunto de prueba** una sola vez, al final del proceso.
8. **Analizar los errores:** gráfico de residuos en regresión, matriz de confusión en clasificación, y examen de los casos peor predichos para entender dónde falla el modelo y por qué.
9. **Interpretar el modelo:** coeficientes, importancia de variables o valores SHAP, contrastando si las variables más influyentes coinciden con lo hallado en las fases descriptiva e inferencial.

7.2. Métricas exigidas

Tipo de tarea	Métricas a reportar
Regresión	RMSE, MAE, MAPE cuando la escala lo permita, y R^2 sobre el conjunto de prueba. Comparación explícita contra la línea base.
Clasificación	Matriz de confusión, exactitud, precisión, exhaustividad, F1 y AUC-ROC. En problemas desbalanceados, la exactitud por sí sola no es una métrica aceptable y debe acompañarse de las demás.

Sobre el sobreajuste: el informe debe comparar el desempeño en entrenamiento, en validación y en prueba, y discutir la brecha entre ellos. Un modelo con métricas excelentes en entrenamiento y pobres en prueba, presentado como exitoso, es motivo de desaprobación de la fase. Reconocer y explicar el sobreajuste vale más que ocultarlo.

7.3. Conclusión de la Fase 3

Debe incluir: el desempeño alcanzado y su comparación con la línea base, qué variables resultaron más predictivas y si eso coincide con lo esperado, en qué condiciones el modelo sería utilizable en la práctica y en cuáles no, las limitaciones de generalización, los riesgos éticos o de sesgo del modelo aplicado a decisiones reales, y la respuesta final consolidada a la pregunta de investigación planteada en la Fase 1.

7.4. Entregables de la Fase 3

- Informe de la Fase 3 en PDF, de hasta 15 páginas, con la lista de correcciones aplicadas a la Fase 2.
- Notebook de modelado ejecutado y su exportación en HTML.
- Modelo entrenado serializado (.pkl o .joblib) y script de inferencia que permita aplicarlo a datos nuevos.
- Informe integrador en PDF que consolide las tres fases, con conclusión general del proyecto. Máximo 30 páginas.
- Repositorio final ordenado y documentado.

8. Presentación final

Última semana de clases | Ponderación: 15 %

Exposición oral de 15 minutos por grupo, más 5 minutos de preguntas. Participan obligatoriamente todos los integrantes. La audiencia debe suponerse compuesta por decisores interesados en el problema, no por especialistas en estadística.

Estructura sugerida: el problema y por qué importa (2 min) · los datos y sus limitaciones (2 min) · qué muestran los datos (4 min) · qué se pudo afirmar con evidencia estadística (3 min) · qué predice el modelo y con qué confianza (3 min) · recomendaciones y trabajo futuro (1 min).

- De 12 a 18 diapositivas, con predominio de gráficos sobre texto.
- Sin capturas de pantalla de código ni tablas de salida sin procesar.
- Cada afirmación debe estar respaldada por una evidencia visible en la diapositiva.
- Cualquier integrante puede ser consultado sobre cualquier parte del proyecto.

9. Criterios de evaluación

9.1. Rúbrica de la Fase 1 (30 % del proyecto)

Dimensión	Qué se evalúa	Peso
Comprensión del problema	Pertinencia y precisión de la pregunta; coherencia entre objetivo general, objetivos específicos y datos disponibles.	20 %
Comprensión y selección de datos	Diccionario completo, perfilado riguroso, evaluación de calidad y justificación de los descartes.	20 %
Limpieza y transformación	Fundamentación de cada decisión, bitácora, reproducibilidad íntegra por código.	20 %
Análisis univariado y bivariado	Pertinencia de los estadísticos, corrección de los cálculos, calidad de la interpretación.	20 %
Visualización y conclusión	Corrección técnica y legibilidad de los gráficos; conclusión sustentada e hipótesis para la Fase 2.	20 %

9.2. Rúbrica de la Fase 2 (25 % del proyecto)

Dimensión	Qué se evalúa	Peso
Formulación de hipótesis	Derivación desde la Fase 1, redacción formal correcta, nivel de significancia declarado previamente.	20 %
Selección y justificación de pruebas	Adecuación al tipo de variables y al diseño; variedad de familias de pruebas.	25 %
Verificación de supuestos	Comprobación previa y decisión correcta ante su incumplimiento.	20 %
Interpretación	Distinción entre significancia y relevancia, tamaños de efecto, corrección por comparaciones múltiples, discusión de confusores.	25 %
Conclusión y correcciones	Cierre sustentado y aplicación de la devolución de la Fase 1.	10 %

9.3. Rúbrica de la Fase 3 (30 % del proyecto)

Dimensión	Qué se evalúa	Peso
Diseño del experimento	Definición de la tarea, partición correcta (cronológica si corresponde), línea base establecida.	25 %
Modelado	Variedad de familias, validación cruzada, ajuste de hiperparámetros sin contaminar el conjunto de prueba.	25 %
Evaluación y análisis de errores	Métricas adecuadas al problema, discusión del sobreajuste, examen de los casos mal predichos.	25 %
Interpretación y conclusión	Importancia de variables contrastada con las fases previas, límites de uso, riesgos éticos, respuesta final a la pregunta.	25 %

9.4. Rúbrica de la presentación (15 % del proyecto)

Dimensión	Qué se evalúa	Peso
Claridad del relato	Hilo argumental del problema a la conclusión, adecuación a una audiencia no técnica.	35 %
Calidad visual	Diapositivas legibles, gráficos autoexplicativos, ausencia de código y de tablas crudas.	25 %
Dominio del trabajo	Respuestas a las preguntas, conocimiento de todos los integrantes sobre todas las fases.	30 %
Gestión del tiempo	Ajuste a los 15 minutos y participación equilibrada.	10 %

9.5. Condiciones de desaprobación automática de una fase

- El notebook no ejecuta o arroja errores que impiden reproducir los resultados.
- Se presentan conclusiones que no se derivan de la evidencia mostrada.
- Se afirma causalidad a partir de una correlación, sin discusión de la limitación.
- Se aplican pruebas estadísticas sin verificación de supuestos (Fase 2) o se evalúa el modelo sobre los datos de entrenamiento (Fase 3).
- Falta alguno de los entregables obligatorios de la fase.
- Se detecta plagio o entrega de material no producido por el grupo.

Entregas fuera de plazo: se descuenta un punto por día corrido de atraso, hasta un máximo de tres días. Pasado ese plazo, la fase se califica con cero. La entrega tardía de una fase no modifica la fecha de las siguientes.

10. Requisitos técnicos y de formato

- **Lenguaje:** Python 3.10 o superior. Se admite R con autorización previa del docente.
- **Librerías sugeridas:** pandas, numpy, matplotlib, seaborn, scipy, statsmodels y scikit-learn. Cualquier otra debe declararse en el archivo de dependencias.
- **Reproducibilidad:** rutas relativas, semilla aleatoria fijada, ejecución completa sin intervención manual.
- **Estructura del repositorio:** carpetas /data, /notebooks, /src y /output, con README que explique cómo reproducir el trabajo.
- **Nomenclatura del archivo de entrega:** Fase1_DataScience_Apellido1-Apellido2-Apellido3.zip, y equivalente para las demás fases.
- **Datos originales:** no incluirlos en el comprimido si superan los 25 MB; en ese caso indicar la fuente y el script de descarga.
- **Formato del informe:** PDF con carátula (nombres, legajos, fase, fecha), índice y numeración de páginas.

11. Integridad académica y uso de asistentes de IA

El trabajo debe ser producido por el grupo. Se permite el uso de asistentes de inteligencia artificial como herramienta de apoyo —depuración de código, consulta de sintaxis, mejora de redacción—, bajo tres condiciones:

1. Declarar su uso en un apartado del informe, indicando para qué tareas se empleó.
2. Verificar y comprender todo el código y todo el texto incorporado. En la presentación final, cualquier integrante puede ser consultado sobre cualquier línea del trabajo.
3. No delegar en la herramienta las decisiones metodológicas ni la interpretación de los resultados, que constituyen el núcleo de la evaluación.

El incumplimiento se considera falta de integridad académica y se rige por el reglamento de la Facultad.

12. Anexo — Listas de verificación previas a cada entrega

Fase 1

- La pregunta de investigación está en una sola oración y es respondible con los datos elegidos.
- Cada objetivo específico se corresponde con una sección del análisis.
- El diccionario de datos está completo, incluido el porcentaje de faltantes.
- Cada decisión de limpieza figura en la bitácora con su fundamento.
- El notebook se ejecuta de principio a fin en un entorno limpio y regenera el dataset final.
- Cada gráfico tiene título, ejes con unidades e interpretación escrita.
- La conclusión enuncia las hipótesis que se llevarán a la Fase 2.

Fase 2

- Se aplicaron las correcciones señaladas en la devolución de la Fase 1 y están listadas.
- Cada hipótesis está escrita en forma nula y alternativa, con el nivel de significancia declarado antes de ejecutar la prueba.
- Se verificaron los supuestos de cada prueba y se documentó la decisión resultante.
- Se informa el tamaño del efecto junto a cada valor p.
- Se declaró cuántas pruebas se realizaron y se aplicó corrección por comparaciones múltiples.
- Ninguna conclusión afirma causalidad sin discutir la limitación.

Fase 3

- Se aplicaron las correcciones de la Fase 2 y están listadas.
- La partición es cronológica si los datos tienen componente temporal.
- Existe una línea base y todos los modelos se comparan contra ella.
- El conjunto de prueba se usó una sola vez, al final.
- Se reportan las métricas en entrenamiento, validación y prueba, con discusión de la brecha.
- Se analizaron los errores y los casos peor predichos.
- El informe integrador responde de forma explícita la pregunta de la Fase 1.

13. Bibliografía y recursos

- McKinney, W. — Python for Data Analysis, 3.ª edición. O'Reilly.
- Géron, A. — Hands-On Machine Learning with Scikit-Learn, Keras and TensorFlow, 3.ª edición. O'Reilly.
- James, G., Witten, D., Hastie, T. y Tibshirani, R. — An Introduction to Statistical Learning. Springer (disponible gratuitamente).
- Tukey, J. W. — Exploratory Data Analysis. Addison-Wesley.
- Cairo, A. — How Charts Lie. W. W. Norton.
- Chapman, P. et al. — CRISP-DM 1.0: Step-by-step data mining guide.
- Documentación oficial de pandas, matplotlib, seaborn, scipy.stats, statsmodels y scikit-learn.
- Open Contracting Data Standard — documentación en español: standard.open-contracting.org